

РЕФЕРАТ

Расчетно-пояснительная записка к выпускной квалификационной работе «Метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети» содержит 83 страниц, 4 части, 24 рисунков, 4 таблицы, список используемых источников из 34 наименований и 2 приложения.

Ключевые слова: компьютерное зрение, глубокое обучение, сверточная нейронная сеть.

Объект разработки – метод обнаружения фальсифицированного фрагмента на изображении.

Цель работы: разработка и программная реализация метода автоматизированного определения области фальсифицированного фрагмента изображения с помощью двухпоточной свёрточной нейронной сети.

В первой части работы приведены обзор и сравнение существующих методов обнаружения фальсифицированного фрагмента на изображении.

Во второй части описан метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети, приведены IDEF0-диаграммы метода и схемы его алгоритмов.

В третьей части обоснован выбор средств разработки, приведена структура ПО, реализующий предложенный метод и описано взаимодействие пользователя с программным обеспечением..

В четвертой части выбраны метрики для оценки качества работы метода и приведены результаты исследования их зависимости от конфигурации нейронной сети и объемов передаваемых данных.

Разработанный метод может найти применение в области информационной безопасности и верификации медиаконтента в средствах массовой информации и социальных сетях. Это позволит своевременно выявлять и блокировать распространение дезинформации.

СОДЕРЖАНИЕ

РЕФЕРАТ	5
ВВЕДЕНИЕ	8
1 Аналитический раздел	9
1.1. Фальсификация изображений и задача её обнаружения .	9
1.1.1. Понятие фальсификации изображений	9
1.1.2. Основные трудности и требования к методам обнаружения .	10
1.2. Методы обнаружения фальсифицированного фрагмента на изображении	13
1.2.1. Методы на основе анализа целостности изображений	13
1.2.2. Методы поиска ключевых точек	20
1.2.3. Метод на основе сверточной нейронной сети	26
1.3. Сравнительный анализ методов фальсифицированного фрагмента на изображении	30
1.3.1. Обоснование критериев сравнения методов	30
1.3.2. Таблица сравнения методов	32
1.4. Формализованная постановка задачи	34
2 Конструкторский раздел	36
2.1. Требования и ограничения к разрабатываемому методу .	36
2.2. Описание разрабатываемого метода	36
2.2.1. Декомпозиция разрабатываемого метода	36
2.2.2. Алгоритмы предобработки и извлечения признаков	37
2.2.3. Структура разрабатываемой сверточной нейронной сети . . .	40
2.3. Структура разрабатываемого программного обеспечения	48
2.4. Набор данных для обучения модели	50
3 Технологический раздел	52
3.1. Выбор средств реализации программного обеспечения .	52
3.1.1. Выбор языка программирования	52
3.1.2. Выбор среды программирования	52

3.2.	Формат входных и выходных данных	54
3.3.	Структура разрабатываемого программного обеспечения	55
3.4.	Руководство пользователя	56
3.5.	Интерфейс пользователя	58
4	Исследовательский раздел	61
4.1.	Метрики оценки качества модели	61
4.2.	Технические характеристики	63
4.3.	Влияние слоя внимания на качество модели	63
4.4.	Влияние слоя адаптации признаков на качество модели .	65
4.5.	Влияние объема передаваемых данных на качество рабо- ты метода	66
4.6.	Влияние качества изображения на качество модели . . .	67
	ЗАКЛЮЧЕНИЕ	70
	СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	71
	ПРИЛОЖЕНИЕ А	75
	ПРИЛОЖЕНИЕ Б	83

ВВЕДЕНИЕ

В условиях быстрого развития технологий в последние несколько лет поддельные мультимедиа стали центральной проблемой. Используя передовые инструменты, создание поддельных медиапродуктов, таких как изображения и видео, становится очень простым, если доступны большие объёмы данных. Создание поддельного медиаконтента неэтично и представляет угрозу для общества. Они широко используются в киберпреступности для кражи личных данных, кибервымогательства, фейковых новостей, финансового мошенничества и многого другого. Поэтому больше внимания следует уделять выявлению контрафактной продукции. Обнаружение поддельного контента является серьёзной проблемой и пользуется большим спросом в сфере цифровой безопасности.

Особую сложность среди всех видов поддельных медиа представляют фальсифицированные изображения, а именно те случаи, когда изменён не весь кадр, а лишь отдельный фрагмент. Такие локальные манипуляции сложнее обнаружить, так как большая часть изображения остаётся подлинной. Современные генеративные модели способны создавать высокореалистичные фрагменты, визуально неотличимые от оригинала, что требует разработки новых, более совершенных алгоритмов обнаружения фальсификации.

Цель работы — разработка и программная реализация метода автоматизированного определения области фальсифицированного фрагмента изображения с помощью двухпоточной свёрточной нейронной сети.

Для достижения поставленной цели необходимо выполнить следующие задачи:

- провести обзор и сравнение существующих методов обнаружения фальсифицированного фрагмента на изображении;
- разработать метод обнаружения фальсифицированного фрагмента на изображении с использованием свёрточной нейронной сети, привести IDEF0-диаграммы метода и схемы его алгоритмов;
- разработать программное обеспечение, реализующее данный метод;
- выбрать метрики для оценки качества работы метода и провести исследования качества работы метода.

1 Аналитический раздел

1.1. Фальсификация изображений и задача её обнаружения

1.1.1. Понятие фальсификации изображений

Под фальсификацией (подделкой) цифровых изображений понимается процесс преднамеренного внесения изменений в исходное изображение с целью искажения его визуального содержания или передаваемого смысла. В отличие от стандартной обработки изображений (коррекция яркости, контраста, цветокоррекция, шумоподавление или ретушь в художественных целях), фальсификация всегда преследует цель ввести зрителя в заблуждение, создать ложное представление о реальности, что может использоваться как в личных, так и в профессиональных или политических целях [1].

С развитием доступных инструментов редактирования (Adobe Photoshop, GIMP) и особенно методов искусственного интеллекта возможности создания высококачественных подделок значительно возросли. Современные генеративные модели, позволяют генерировать или модифицировать изображения с уровнем реализма, который часто невозможно отличить невооружённым глазом. В связи с этим задача обнаружения фальсификаций становится особенно актуальной в областях журналистики, криминалистики и социальных медиа [2].

В современной литературе по компьютерному зрению принято выделять несколько основных типов фальсификации изображений [3].

- Копирование-вставка (англ. copy-move) — фрагмент изображения копируется и вставляется в другую область того же изображения, часто для сокрытия объектов или их дублирования.
- Вставка объектов из другого изображения (англ. splicing) — часть одного изображения переносится в другое, создавая сцену, которой не существовало в действительности.
- Ретуширование (англ. inpainting) — удаление или замена элементов с помощью заполнения области (удаление теней, людей, артефактов, ...).
- Генерация полностью синтетических изображений — создание изображений с нуля с использованием генеративно-состязательных сетей (GAN) или диффузионных моделей.

— Deepfake — замена лица или мимики человека на видео и изображениях с использованием нейросетевых методов.

Ниже, на рисунке 1.1, представлены примеры фальсификаций изображений типа копирование-вставка.




Рисунок 1.1 – Пример фальсификаций изображений типа копирование-вставка.

Цифровая фальсификация оставляет определённые статистические и семантические следы. Например, при копировании-вставке возникает повторяющаяся структура блоков, при вставке — нарушение согласованности шума датчика или освещения, а при ретушировании — аномалии в частотной области (артефакты сглаживания, некорректное сохранение JPEG)[4].

Важно отметить, что понятие фальсификации не включает в себя такие изменения, как сжатие с потерями, масштабирование или поворот, если они не направлены на введение в заблуждение зрителя. Однако в реальных условиях поддельное изображение часто подвергается дополнительным операциям (JPEG-сжатие, изменение размера, фильтрация), что усложняет его обнаружение[5].

Таким образом, для обнаружения фальсифицированного фрагмента необходимо учитывать множество потенциальных аномалий на различных уровнях представления изображения: от пиксельного до семантического.

1.1.2. Основные трудности и требования к методам обнаружения

Задача обнаружения фальсифицированного фрагмента на изображении относится к классу задач пассивной судебной экспертизы изображений. В от-

личие от активных методов (цифровая подпись, водяные знаки), пассивные методы не требуют предварительного внедрения вспомогательной информации, однако сталкиваются с рядом принципиальных трудностей, обусловленных как свойствами самих изображений, так и действиями злоумышленника[6].

К числу основных трудностей относятся.

1. Отсутствие эталонного («чистого») изображения. В большинстве практических сценариев (например, при проверке фотографий в СМИ или на интернет-платформах) исходное неизменённое изображение недоступно. Поэтому метод должен выявлять аномалии исключительно на основе статистических и семантических характеристик самого анализируемого файла.
2. Разнообразие типов фальсификаций. Как отмечалось в п. 1.1.1, подделки могут быть выполнены методами *soru-move*, *splicing*, *inpainting*, *deepfake* и др. Каждый тип оставляет различные следы: повторяющиеся блоки, несоответствие шума сенсора, артефакты интерполяции или генеративные контуры. Универсальный метод должен быть устойчивым к нескольким типам подделок [7].
3. Соккрытие следов подделки послеоперационной обработкой. Злоумышленник может применять к поддельному изображению сжатие JPEG, масштабирование, добавление шума, медианную фильтрацию или размытие. Эти манипуляции намеренно затрудняют обнаружение артефактов, разрушая статистические аномалии, внесённые в момент фальсификации.
4. Разнородность исходных изображений. Метод не должен полагаться на фиксированные характеристики (размер, разрешение, цветовое пространство, модель камеры), так как изображения в реальных условиях поступают из самых разных источников [8]. Это требует инвариантности к разрешению, коэффициенту сжатия и уровню шума.
5. Вычислительная сложность и требования к ресурсам и времени. Применение метода в потоковых системах (социальные сети, новостные агрегаторы) требует быстрой обработки (миллисекунды на изображение) и работы с большими объёмами данных. Слишком ресурсоёмкие модели неприменимы в реальном времени.

6. Отсутствие крупных универсальных размеченных наборов данных. Обучение методов на основе глубокого обучения требует большого количества подлинных и фальсифицированных изображений с пиксельной разметкой подделанных областей. Существующие датасеты различаются по типам подделок, размерам и условиям создания, что затрудняет сравнение и обобщение.

В связи с перечисленными трудностями к современным методам обнаружения фальсифицированного фрагмента предъявляются следующие требования [9]:

- Высокая точность: метод должен обеспечивать высокие значения метрик IoU, F1-меры и точности классификации пикселей на тестовых наборах, сбалансированных по типам подделок.
- Устойчивость к постобработке: метод должен сохранять работоспособность после сжатия JPEG, изменения размера, добавления шума и других типов постобработки.
- Обобщающая способность: обученная модель должна корректно работать на изображениях, взятых из датасетов, не участвовавших в обучении, и на неизвестных типах подделок.
- Вычислительная эффективность: время детекции одного изображения должно быть сопоставимо с временем его загрузки или публикации.
- Локализация фрагмента: метод должен не только выносить бинарное решение, но и выдавать карту локализации с указанием границ изменённой области (пиксельная маска).
- Инвариантность к изображению: метод не должен зависеть от конкретной модели камеры, формата и цветовой схемы (RGB, YCbCr).

Таким образом, разработка практического метода обнаружения фальсифицированного фрагмента представляет собой сложную многокритериальную задачу, требующую компромисса между точностью, устойчивостью и скоростью работы.

1.2. Методы обнаружения фальсифицированного фрагмента на изображении

В настоящее время существует множество подходов к решению задачи обнаружения фальсифицированных фрагментов изображений. Все методы можно условно разделить на три основные группы: методы на основе анализа целостности изображений, методы на основе поиска ключевых точек и методы на основе сверточных нейронных сетей. Каждый из них имеет свои сильные и слабые стороны, область применимости и уровень эффективности.

1.2.1. Методы на основе анализа целостности изображений

Методы обнаружения фальсифицированного фрагмента на основе анализа целостности изображений опираются на предположение, что любая модификация исходного изображения нарушает определённые статистические закономерности, присущие естественным изображениям. В отличие от методов поиска ключевых точек, которые ориентированы преимущественно на выявление фальсификации типа копирование-вставка, подходы на основе целостности анализируют непротиворечивость таких физически обоснованных характеристик, как шум датчика (PRNU), артефакты двойного сжатия JPEG и корреляции, вносимые интерполяцией цветных фильтров (CFA). Каждый из этих трёх методов имеет собственную область эффективности и ограничения. На практике эти методы часто применяются в комплексе: например, сначала выполняется анализ PRNU для грубой локализации подозрительных областей, а затем уточнение с помощью CFA-интерполяции. Такой многоэтапный подход позволяет снизить количество ложных срабатываний [2].

Принципиальным преимуществом методов анализа целостности является их независимость от наличия обучающей выборки, что характерно для нейросетевых подходов. Они основаны на фундаментальных физических свойствах процесса формирования цифрового изображения, которые трудно подделать или полностью скрыть без значительной деградации визуального качества. Это делает их особенно ценными в сценариях судебной экспертизы, где требуется предоставить объяснимое и юридически обоснованное заключение о подлинности изображения. Однако, каждый из методов имеет существенные ограничения, связанные с чувствительностью к постобработке, необходимостью апри-

орной информации об устройстве съёмки и сложностью точной локализации границ фальсификации.

Метод на основе анализа шума датчика (PRNU)

Каждая цифровая камера оставляет уникальный «отпечаток» — фото-отклик неравномерности (photo-response non-uniformity, PRNU), возникающий из-за неоднородной чувствительности пикселей [4]. При вставке фрагмента из другого изображения (splicing) в подделанной области нарушается согласованность PRNU: появляется шум другой камеры или его отсутствие. Метод вычисляет PRNU анализируемого изображения (обычно с помощью вейвлет-фильтрации или использования фильтра высоких частот) и оценивает его корреляцию с эталонным шумом предполагаемой камеры. Если фрагмент изображения имеет статистически значимое расхождение в структуре шума, это свидетельствует о фальсификации.

Физическая природа PRNU обусловлена несовершенством полупроводниковой технологии производства матриц: каждый пиксель имеет слегка различную чувствительность к падающему свету, что создаёт уникальный пространственный паттерн, который можно рассматривать как цифровой отпечаток пальца камеры. Этот паттерн остаётся стабильным для данной камеры на протяжении всего срока её службы и не зависит от снимаемой сцены. Для выделения PRNU из изображения применяются методы подавления контентной составляющей, чаще всего с использованием вейвлет-преобразования или фильтрации в частотной области. Наиболее распространённым подходом является использование фильтра высоких частот, который извлекает компоненту шума, содержащую как PRNU, так и другие виды шумов. Для повышения отношения сигнал-шум обычно используют усреднение по нескольким изображениям, снятым одной камерой, чтобы подавить случайную составляющую и выделить стационарный PRNU-компонент.

Ниже, на рисунке 1.2, представлена схема работы метода на основе анализа шума датчика (PRNU).

В работе [10] также показано, что эффективность PRNU-анализа резко падает, если фальсифицированный фрагмент был предварительно обесцвечен или подвергнут нелинейной гамма-коррекции. Для повышения робастности исследователи предлагают использовать вейвлет-преобразование Хаара, которое сохраняет высокочастотную составляющую шума даже при умеренном сжатии.




Рисунок 1.2 – Схема работы метода на основе анализа шума датчика.

Однако при коэффициенте качества JPEG ниже 75% PRNU-следы становятся практически неразличимыми. Кроме того, практическое применение метода требует, чтобы на изображении была как минимум одна область с заведомо неизменённым шумом. Такую область часто выделяют вручную или с помощью алгоритмов поиска однородных текстур. Без этого эталонного фрагмента корреляционный анализ теряет смысл. На практике PRNU-метод наиболее полезен при расследовании единичных целенаправленных фальсификаций, где камера-источник может быть изъята и исследована. В потоковой обработке интернет-изображений практически не применяется из-за отсутствия эталонных шумов.

Несмотря на свою теоретическую привлекательность, PRNU-анализ сталкивается с рядом серьёзных практических ограничений. Во-первых, для вычисления эталонного PRNU камеры требуется доступ к самой камере или серии изображений, снятых ею, что часто невозможно в реальных сценариях расследования. Во-вторых, даже при наличии эталонного PRNU, корреляционный анализ даёт лишь вероятность того, что фрагмент был снят другой камерой, но не позволяет точно определить границы вставки без дополнительных методов сег-

ментации. В-третьих, злоумышленник может сознательно применить к вставленному фрагменту обработку, разрушающую структуру шума: например, повторное сжатие с последующим добавлением синтетического шума или применение дебайзеринга с другой моделью демозаики. Это позволяет эффективно маскировать несоответствие PRNU, сохраняя при этом приемлемое визуальное качество подделки. Кроме того, метод крайне чувствителен к масштабированию: изменение размера фрагмента разрушает пространственную структуру PRNU, делая корреляционный анализ невозможным.

Метод на основе двойного сжатия JPEG (Double JPEG)

Большинство цифровых изображений сохраняются в формате JPEG с потерями. Если злоумышленник редактирует изображение и сохраняет его повторно, возникает так называемое двойное сжатие с возможно разными таблицами квантования. При этом гистограмма коэффициентов дискретного косинусного преобразования (DCT) для отдельных частотных полос приобретает характерные периодические пики. Метод анализирует гистограммы DCT-коэффициентов и выявляет наличие двух различных стадий квантования. В наиболее развитой форме метод не только определяет факт двойного сжатия, но и оценивает параметры первого сжатия [11]. Достоинства: работает без какой-либо априорной информации об исходной камере, устойчив к умеренным атакам. Недостатки: метод даёт в основном бинарный ответ и плохо локализует точную область вставки; кроме того, если злоумышленник сохранил подделку без сжатия (в формате PNG) или использовал тот же коэффициент качества, двойное сжатие может быть не обнаружено.

Основой метода является анализ гистограмм квантованных DCT-коэффициентов для каждого из 64 частотных каналов (8×8 блоков). При однократном сжатии гистограммы имеют характерное распределение, близкое к обобщённому гауссовскому. При повторном сжатии с другими параметрами квантования в гистограммах возникают периодические артефакты — так называемые ”столбчатые” выбросы, обусловленные тем, что значения, кратные шагу квантования второго сжатия, оказываются перераспределены по отношению к значениям, кратным шагу первого квантования. Эти выбросы можно выявить с помощью спектрального анализа гистограмм: например, вычисляя дискретное преобразование Фурье (DFT) от гистограммы и анализируя наличие характерных пиков. Современные варианты метода позволяют не только

бинарно классифицировать изображение как подвергнутое двойному сжатию, но и оценивать параметры первого квантования, что может дать важную информацию об истории обработки изображения.

Ниже, на рисунке 1.3, представлена гистограмма DCT исходного и сжатого изображений.




Рисунок 1.3 – Гистограмма DCT исходного и сжатого изображений.

Важным уточнением является то, что метод двойного сжатия эффективен только для подделок, которые были сохранены в JPEG хотя бы один раз после редактирования. Если оригинал был в формате без потерь, а фальсификация тоже сохранена без потерь, то DCT-гистограммы не покажут аномалий. Для улучшения локализации применяется скользящее окно фиксированного размера. Окно последовательно перемещается по изображению, и для каждой позиции вычисляется вероятность двойного сжатия. Области, где эта вероятность превышает порог, объединяются в итоговую карту подозрительных фрагментов. Такой подход, хотя и вычислительно затратен, позволяет очертить границы вставки с точностью до размера окна. Кроме того, устойчивость метода можно повысить, анализируя не только гистограммы, но и корреляции между DCT-коэффициентами соседних блоков. В подделанных областях эти корреляции часто нарушаются из-за того, что один блок мог быть сжат с одними параметрами, а соседний — с другими. Данный приём, известный как «анализ блоковой когерентности», даёт хорошие результаты даже при повторном сжатии с тем же

коэффициентом качества.

Метод на основе анализа интерполяции цветных фильтров (CFA)

Большинство цифровых камер используют матрицу цветных фильтров Байера, где каждый пиксель регистрирует только один цветовой канал (зелёный, красный или синий), а недостающие цветовые значения восстанавливаются с помощью демозаики. Процесс интерполяции вносит корреляции между соседними пикселями и между цветовыми каналами. При вставке фрагмента из другого изображения или при ретушировании локальная структура CFA-интерполяции нарушается, так как вставленная область имеет свою историю обработки. Метод моделирует ожидаемый процесс интерполяции для данной модели камеры или строит универсальную модель и вычисляет ошибку предсказания пикселя по соседним. В областях, где CFA-интерполяция нарушена, ошибка предсказания статистически значимо выше. Достоинства метода: возможность локализации подделки на уровне пикселей без необходимости знать эталонный PRNU. Недостатки: высокая чувствительность к сжатию JPEG, а также к масштабированию. Метод эффективен только для изображений, поступивших напрямую с камеры и сохранённых в формате без потерь или с минимальным сжатием [12].

Матрица Байера — это наиболее распространённый тип цветного фильтра, используемый в подавляющем большинстве цифровых камер. На каждом пикселе регистрируется только один цвет: зелёный (50% пикселей), красный (25%) или синий (25%). Процесс демозаики восстанавливает два недостающих цветовых канала для каждого пикселя, используя интерполяцию значений соседних пикселей. Существует множество алгоритмов демозаики, от простой билинейной интерполяции до сложных адаптивных методов, учитывающих направление градиентов и текстуру. Независимо от конкретного алгоритма, процесс интерполяции вносит в изображение характерные корреляционные структуры, которые могут быть смоделированы. Если вставленный фрагмент был снят другой камерой или прошёл через иной процесс демозаики (например, через интерполяцию в графическом редакторе), то эти корреляции нарушаются, и ошибка предсказания (разница между предсказанным и реальным значением недостающего цветового канала) становится аномально высокой именно в области вставки.

Ниже, на рисунке 1.4, представлены исходное изображение и изображе-

ние, обработанное с помощью CFA.




Рисунок 1.4 – Исходное изображение и изображение, обработанное с помощью CFA.

На практике CFA-метод часто реализуют через обучение небольшой нейронной сети предсказывать зелёный канал по красному и синему. Такую сеть обучают на заведомо подлинных изображениях, снятых различными камерами. При тестировании для каждого пикселя вычисляется ошибка предсказания; области с аномально высокой ошибкой маркируются как потенциально поддельные. Такой подход не требует явного задания модели интерполяции и частично компенсирует разницу между камерами разных производителей. Однако главное ограничение CFA-метода остаётся неизменным: он практически неработоспособен после сжатия JPEG с качеством ниже 90%. Даже небольшое сжатие разрушает тонкие корреляции, внесённые демозаикой. Более того, если поддельный фрагмент был предварительно масштабирован или повернут, то его собственная CFA-интерполяция уже не соответствует исходной сетке Байера, и метод может дать ложное срабатывание даже на подлинной области.

Важным направлением развития CFA-методов является анализ не только ошибки предсказания отдельного пикселя, но и пространственных паттернов ошибки, которые могут выявлять характерные артефакты, свойственные конкретным алгоритмам демозаики. Также активно исследуются комбинированные подходы, объединяющие CFA-анализ с другими методами целостности (PRNU и Double JPEG) для повышения робастности к постобработке и увеличения точности локализации. Однако, несмотря на все усовершенствования, фундаментальное ограничение CFA-метода — его крайняя чувствительность к сжатию с потерями — остаётся серьёзным препятствием для его применения в условиях анализа изображений из интернета, где большинство файлов хранятся

и передаются в сжатом формате JPEG с коэффициентом качества 70-80%.

1.2.2. Методы поиска ключевых точек

Методы обнаружения фальсификации на основе поиска ключевых точек (англ. keypoint-based methods) являются одним из наиболее эффективных подходов для выявления фальсификации типа «копирование-вставка». Основная идея заключается в том, что при копировании фрагмента изображения и вставке его в другое место того же изображения в подделке появляются две или более области с идентичным или очень похожим содержанием. Ключевые точки представляют собой локальные особенности, инвариантные к масштабу, повороту и частично к изменению освещения, что позволяет обнаруживать дублированные фрагменты даже после их геометрического преобразования [13]. Наибольшее распространение в задачах криминалистики изображений получили масштабно-инвариантное преобразование признаков (англ. Scale-Invariant Feature Transform, SIFT) и устойчивые ускоренные признаки (англ. Speeded-Up Robust Features, SURF) [14].

Математической основой инвариантности ключевых точек является построение масштабного пространства, в котором изображение свёртывается с гауссовым ядром при различных значениях параметра σ . Это позволяет представить изображение в виде пирамиды, где каждый последующий уровень соответствует уменьшенному масштабу или увеличенному размытию. Ключевые точки локализуются как экстремумы разности гауссовых функций в этом трёхмерном пространстве координат и масштаба. Такое представление обеспечивает инвариантность к масштабированию и повороту, поскольку ориентация ключевой точки определяется по гистограмме градиентов в её окрестности, что позволяет нормализовать дескриптор относительно преобладающего направления. Этот математический аппарат делает SIFT и SURF устойчивыми к геометрическим преобразованиям, которые часто применяются злоумышленниками для маскировки копирования.

Метод SIFT

Дескриптор SIFT, предложенный Лоу в 2004 году, стал золотым стандартом для обнаружения фальсификации типа копирование-вставка [15]. Алгоритм включает следующие этапы: построение масштабного пространства, локализацию экстремумов разности гауссия, отбраковку низкоконтрастных и гранич-

ных точек, назначение ориентации на основе градиентов и формирование 128-мерного дескриптора для каждой ключевой точки. При обнаружении подделки вычисляются SIFT-дескрипторы для всего изображения, затем выполняется их попарное сравнение (с использованием отношения расстояний до ближайшего и второго ближайшего соседа). Пары ключевых точек с высокой степенью совпадения дескрипторов группируются в кластеры с помощью алгоритмов иерархической кластеризации или DBSCAN, после чего для каждой группы строится ограничивающий прямоугольник или точный контур подозрительной области[16]. SIFT демонстрирует высокую устойчивость к повороту, масштабированию и небольшому изменению перспективы, а также к сжатию JPEG при коэффициентах качества выше 70%. Однако его вычислительная сложность относительно высока: извлечение дескрипторов и особенно их попарное сравнение может занимать несколько секунд на изображении среднего разрешения [17].

Глубокое понимание этапов алгоритма SIFT позволяет оценить как его сильные стороны, так и критические точки уязвимости. При построении масштабного пространства используется пирамида октав, каждая из которых состоит из нескольких уровней с различной степенью сглаживания. Локализация экстремумов разности гауссовых функций производится путём сравнения каждого пикселя с 26 соседями (8 в текущем масштабе + 9 в предыдущем + 9 в следующем), что обеспечивает высокую точность детектирования характерных точек. Этап отбраковки низкоконтрастных точек основан на анализе второй производной в экстремуме: если значение функции в точке меньше некоторого порога, точка считается неустойчивой и удаляется. Граничные точки, которые плохо локализуются из-за эффекта «края», отсеиваются с помощью анализа кривизны собственных значений матрицы Гессе. Назначение ориентации осуществляется построением гистограммы направлений градиентов в окрестности точки, где пик гистограммы определяет доминирующее направление, а дополнительные пики (если они значимы) создают несколько ключевых точек с разными ориентациями для одного местоположения. Итоговый 128-мерный дескриптор формируется путём разделения окрестности точки на блоки 4×4 , для каждого из которых вычисляется гистограмма градиентов по 8 направлениям, что даёт $4 \times 4 \times 8 = 128$ измерений. Такое избыточное представление обеспечивает высокую различительную способность, но одновременно является причиной высокой вычислительной сложности и чувствительности к изменениям освещения.

Ключевым этапом обнаружения фальсификации является попарное сравнение дескрипторов, которое в наивной реализации имеет квадратичную сложность относительно числа ключевых точек. На изображении среднего разрешения (640×480 пикселей) количество ключевых точек SIFT может достигать нескольких тысяч, что приводит к миллионам сравнений. Для ускорения этого процесса применяются структуры данных для многомерного поиска, которые снижают сложность. Однако даже с такими оптимизациями время обработки остаётся значительным, что ограничивает применение SIFT в системах реального времени. Особенно проблематичным является сравнение дескрипторов на изображениях с повторяющимися текстурами (например, трава, вода, кирпичная кладка), где количество ложных совпадений резко возрастает. Для фильтрации ложных совпадений используется отношение расстояния до ближайшего соседа к расстоянию до второго ближайшего соседа: если это отношение меньше 0.8, совпадение считается достоверным [15]. Этот эвристический критерий, предложенный Лоу, на практике показывает хорошие результаты, хотя и не имеет строгого математического обоснования в терминах вероятности ложного совпадения.

Ниже, на рисунке 1.5, представлен пример ключевых точек SIFT.




Рисунок 1.5 – Пример ключевых точек SIFT.

Метод SURF

Для ускорения обработки был предложен дескриптор SURF, который использует интегральные изображения и приближённые детерминанты матрицы Гессе для быстрого обнаружения ключевых точек [18]. SURF формирует 64-мерный или 128-мерный дескриптор на основе распределения гауссовых вейвлет-ответов в окрестности точки.

Ниже, на рисунке 1.6, представлен пример ключевых точек SURF.




Рисунок 1.6 – Пример ключевых точек SURF.

По сравнению с SIFT, SURF работает в несколько раз быстрее при сопоставимой точности для большинства типов фальсификаций копирования-вставка. Однако SURF уступает SIFT при сильных аффинных искажениях и при низкой освещённости. В задачах обнаружения фальсификаций SURF часто выбирают для систем реального времени или для обработки больших массивов изображений, когда время критичнее максимальной точности[19].

Основное ускорение SURF достигается за счёт использования интегральных изображений, позволяющих вычислять сумму пикселей в произвольном прямоугольнике, независимо от его размера. Это делает возможным быстрое вычисление детерминанта матрицы Гессе с использованием приближённых бокс-фильтров вместо гауссовых свёрток. Детектор SURF использует детерминант матрицы Гессе для локализации точек интереса, где значение детерминанта достигает максимума. Deskриптор SURF вычисляется путём суммирования откликов гауссовых вейвлетов (фильтров Хаара) в окрестности точки, ориентированных согласно основной ориентации, которая определяется по гистограмме откликов Хаара в круговой области. 64-мерный вариант дескриптора содержит значения суммы и суммы абсолютных значений откликов Хаара по четырём направлениям для каждого из 4×4 субрегионов, что даёт $4 \times 4 \times 4 = 64$ измерения. 128-мерный вариант дополнительно разделяет отклики по знаку, что

увеличивает различительную способность за счёт учёта не только величины, но и направления градиента.

На практике разница в скорости становится заметной уже на изображениях размером 1024×768 пикселей: SURF обрабатывает такое изображение за 0.2–0.3 секунды, тогда как SIFT – за 1.5–2 секунды [18]. Для мобильных приложений или веб-сервисов, где требуется ответ менее чем за секунду, SURF оказывается предпочтительнее. Однако при работе с низкоконтрастными изображениями SURF генерирует значительно меньше устойчивых ключевых точек, чем SIFT, что может привести к пропуску фальсификации [20].

Важной особенностью SURF является возможность выбора размера дескриптора: 64-мерный вариант быстрее в сравнении, но даёт больше ложных совпадений на текстурированных фонах. 128-мерный вариант работает медленнее, но обеспечивает точность, близкую к SIFT. При реализации систем обнаружения копирование-вставка часто используют 64-мерный SURF на первом этапе грубого поиска, а затем верифицируют подозрительные кластеры с помощью более точного SIFT-дескриптора. Такой гибридный подход позволяет достичь компромисса между скоростью и точностью [19].

Снижение количества генерируемых ключевых точек на низкоконтрастных изображениях обусловлено тем, что детектор SURF использует фиксированный порог для детерминанта матрицы Гессе. На изображениях с низким динамическим диапазоном значения детерминанта могут не достигать этого порога, даже если визуально присутствуют характерные особенности. Это приводит к тому, что при работе с тёмными или плохо освещёнными изображениями SURF может не обнаружить дублированных областей, которые SIFT с его адаптивным механизмом выделения экстремумов всё ещё способен распознать. С другой стороны, на изображениях с высоким уровнем текстуры SURF генерирует множество точек, что увеличивает вероятность ложных срабатываний. Поэтому выбор между SIFT и SURF в значительной степени зависит от условий съёмки исходных изображений и требуемой скорости обработки.

Кроме того, SURF, как и SIFT, не способен обнаружить фальсификации, если дублированная область была предварительно размыта или к ней применили нелинейную фильтрацию. Даже лёгкое медианное размытие с окном 3×3 снижает количество правильных совпадений на 60–70%. Поэтому при разработке системы, устойчивой к постобработке, дескрипторные методы рекомендуется

дополнять фильтрацией высоких частот или анализом остаточных шумов.

Природа этой уязвимости связана с тем, что ключевые точки по своей сути являются экстремумами в градиентном поле. Размытие (как линейное, так и медианное) сглаживает высокочастотные составляющие изображения, уменьшая амплитуду градиентов и смещая положение экстремумов. В результате многие точки либо исчезают, либо их дескрипторы меняются настолько, что расстояние до соответствующей точки в дублированной области превышает допустимый порог. Особенно критичным является медианное размытие, которое не только сглаживает, но и создаёт ступенчатые артефакты на границах объектов, что дополнительно искажает гистограммы градиентов. Для преодоления этого ограничения исследователи предлагают применять предварительную обработку изображения, направленную на восстановление высокочастотных компонент, например, с помощью фильтрации в частотной области, усиления контуров или вейвлет-декомпозиции с подавлением низкочастотных составляющих. Однако такие методы требуют аккуратной настройки параметров, чтобы не внести дополнительные артефакты, которые сами по себе могут быть ошибочно интерпретированы как признаки фальсификации.

Ограничения методов на основе ключевых точек

При применении SIFT/SURF для анализа больших коллекций изображений важно задать минимальное количество ключевых точек, необходимое для принятия решения о наличии копирования-вставки. Опыт показывает, что порог в 8–12 совпадающих точек достаточно надёжно отсеивает случайные совпадения, но может пропускать подделки с очень маленькими скопированными фрагментами [14]. Для обнаружения мелких вставок порог снижают до 4–5 точек, но при этом резко возрастает число ложных срабатываний на текстурированных фонах. В таких случаях помогает дополнительная проверка формы области: если найденный кластер точек вытянут вдоль границы объекта, вероятность реальной подделки выше, чем для компактного кластера.

Ещё одной практической проблемой является то, что алгоритмы кластеризации требуют задания максимального евклидова расстояния между дескрипторами в пространстве признаков. Это расстояние зависит от степени сжатия изображения и уровня шума. Для JPEG с качеством 95% разумное пороговое значение составляет 0.6–0.7, а для качества 70% порог приходится увеличивать до 0.8–0.9, что ведёт к росту ложных совпадений. Поэтому перед анализом ре-

комендуется оценивать коэффициент качества JPEG и адаптивно подбирать порог. В автоматизированных системах это можно реализовать через предварительный анализ DCT-гистограммы.

Наконец, отметить, что SIFT и SURF дают наилучшие результаты при разрешении входного изображения не ниже 640×480 пикселей. При меньшем разрешении количество ключевых точек падает настолько, что даже очевидные сору-мове подделки могут остаться незамеченными. Для низкоразрешенных изображений более эффективными оказываются методы, основанные на блочном сравнении без ключевых точек, либо сверточные нейронные сети, работающие непосредственно с пикселями [21].

Зависимость от разрешения объясняется тем, что масштабная пирамида SIFT имеет конечное число октав, и при малых размерах изображения на верхних уровнях пирамиды фактически отсутствует достаточное количество пикселей для выделения устойчивых экстремумов. Кроме того, на изображениях с низким разрешением сглаживание, применяемое при построении масштабного пространства, захватывает значительную часть полезного сигнала, что приводит к потере мелких деталей, на которых часто строятся характерные ключевые точки. Это делает дескрипторные методы неприменимыми для обнаружения фальсификаций на изображениях, поступающих из социальных сетей, где многие платформы автоматически сжимают и уменьшают разрешение загружаемых фотографий. В таких сценариях нейросетевые подходы, работающие на уровне пикселей и не требующие явного детектирования ключевых точек, демонстрируют значительно более высокую эффективность, что подтверждает целесообразность разработки гибридных систем, сочетающих быстрые дескрипторные методы для первичного анализа и глубокие нейронные сети для верификации на подозрительных областях.

1.2.3. Метод на основе сверточной нейронной сети

Методы обнаружения фальсифицированных фрагментов на основе сверточных нейронных сетей (CNN) в последние годы заняли доминирующее положение в области компьютерной криминалистики изображений. В отличие от классических подходов (анализ целостности или поиск ключевых точек), которые требуют ручного проектирования признаков, CNN автоматически извлекают иерархические представления из данных, обучаясь различать подлинные

и поддельные области на больших размеченных наборах. Способность сетей выявлять сложные статистические аномалии, невидимые для традиционных детекторов, обусловила их широкое применение для выявления вставки объектов, копирования-вставки и так далее [22].

Фундаментальное преимущество сверточных нейронных сетей заключается в их способности обучаться представлению данных непосредственно из пиксельных значений, без необходимости вручную определять, какие именно признаки являются информативными для задачи обнаружения. В процессе обучения сеть автоматически формирует иерархию признаков: на ранних слоях выделяются простые локальные структуры (края, углы, текстуры), на средних — более сложные комбинации (формы, паттерны), а на глубоких — семантически значимые концепции (объекты, сцены, глобальные корреляции). Для задачи обнаружения фальсификаций это означает, что сеть способна одновременно учитывать как низкоуровневые артефакты (нарушения шумовой структуры, несоответствия в частотных характеристиках), так и высокоуровневые несоответствия (неправильная перспектива, несоответствие освещения, аномалии в текстуре). Такая многоуровневая обработка делает CNN принципиально более гибкими и мощными по сравнению с методами, использующими фиксированные, заранее определённые признаки.

Первые работы по применению CNN для обнаружения подделок использовали простую архитектуру с несколькими свёрточными и полносвязными слоями, работавшую на входных изображениях фиксированного малого размера (например, 64×64 или 128×128). Такие сети классифицировали небольшие патчи как подлинные или поддельные, после чего для локализации фальсификации применялся скользящий оконный метод [23]. Хотя этот подход демонстрировал приемлемую точность на сбалансированных датасетах, он был вычислительно затратным и давал высокую долю ложноположительных срабатываний на границах объектов. Кроме того, сети, обученные на патчах, часто запоминали артефакты конкретного типа фальсификации и плохо обобщались на другие типы фальсификаций.

Патчевый подход имеет несколько фундаментальных ограничений, которые делают его непригодным для практического применения в реальных условиях. Во-первых, фиксированный размер патча означает, что сеть не может использовать контекстную информацию за пределами этого окна, что особенно

критично при обнаружении вставок, где соответствие между вставленным объектом и окружающим фоном является важным признаком. Во-вторых, скользящее окно с шагом, меньшим размера патча, приводит к многократной обработке одних и тех же пикселей, что резко увеличивает вычислительную сложность — для изображения 1024×1024 с патчем 64×64 потребуется выполнить более 200 тысяч классификаций. В-третьих, решение о классификации каждого патча принимается независимо, без учёта пространственной согласованности соседних областей, что приводит к «шумным» маскам с разрозненными ложными срабатываниями. Наконец, сети, обученные на патчах, склонны к переобучению под конкретные артефакты, присутствующие в обучающей выборке (например, определённый тип JPEG-артефактов или характерные границы вставки), и теряют эффективность при появлении новых типов фальсификаций или при изменении условий съёмки.

Прорывом стало появление полностью свёрточных сетей (FCN — Fully Convolutional Networks), которые на входе принимают изображение произвольного размера и на выходе выдают карту локализации той же пространственной размерности. Архитектура типа U-Net (симметричный энкодер-декодер с пропускными соединениями) стала стандартом для пиксельной сегментации подделанных областей [24]. Энкодер последовательно уменьшает пространственное разрешение, извлекая всё более абстрактные признаки, а декодер восстанавливает детализацию и формирует маску подделки. Пропускные соединения позволяют сохранить мелкие гранулярные признаки, которые иначе теряются при многократном субдискретизации [25].

Архитектура энкодер-декодер (U-Net) с пропускными соединениями решает сразу несколько ключевых проблем, характерных для патчевых подходов. Энкодер, состоящий из последовательности свёрточных слоёв с операциями понижения разрешения (субдискретизации), формирует компактное представление изображения, содержащее информацию о глобальном контексте и семантике сцены. Это позволяет сети понимать, какие объекты и структуры являются «нормальными» для данного типа изображения, и выявлять глобальные несоответствия. Декодер, напротив, последовательно восстанавливает пространственное разрешение, используя информацию из энкодера для точной локализации границ подделки. Пропускные соединения между соответствующими уровнями энкодера и декодера обеспечивают передачу детальной пространственной

информации, которая была бы потеряна при многократной субдискретизации. В результате сеть способна одновременно учитывать как глобальный контекст (для понимания того, что вставка семантически не соответствует сцене), так и локальные детали (для точного выделения границ вставленного объекта). Такая архитектура является наиболее эффективной для задач сегментации, где требуется точное попиксельное выделение областей интереса.

Ниже, на рисунке 1.7, представлена архитектура U-Net.




Рисунок 1.7 – Архитектура U-Net.

Важным направлением является использование не RGB-изображений в качестве входа, а так называемых остаточных карт, полученных вычитанием из исходного изображения его сглаженной версии. Такой подход подавляет семантическое содержание и усиливает следы камеры и постобработки. Сеть, обученная на остатках, оказывается более устойчивой к сжатию JPEG и изменениям контента, поскольку вынуждена фокусироваться на статистических аномалиях, а не на форме объектов [26].

Для борьбы с разнообразием типов подделок и усложняющих обработок исследователи разрабатывают многозадачные и многомасштабные архитекту-

ры. Один из подходов – использование параллельных ветвей сети, работающих на разных масштабах, с последующим объединением карт признаков. Другой – применение механизмов внимания, которые позволяют сети динамически взвешивать важность различных пространственных областей и каналов признаков.

Одной из ключевых проблем CNN-методов является их чувствительность к различиям между обучающими и тестовыми датасетами. Сеть, обученная на изображениях с одними камерами и степенями сжатия, может резко терять точность при тестировании на других. Для повышения обобщающей способности применяют методы аугментации, где сеть обучается одновременно на подлинных и сгенерированных подделках, устойчивых к детектированию. В последнее время активно развиваются методы адаптации признаков, которые выравнивают распределения признаков из разных доменов с помощью градиентного реверса слоя или вариационных автоэнкодеров.

Несмотря на высокие показатели качества, CNN-методы имеют и недостатки. Во-первых, они требуют больших размеченных наборов данных с пиксельной маской подделки, создание которых трудоёмко. Во-вторых, многие модели «чёрный ящик»: сложно интерпретировать, на каком именно основании сеть отнесла область к подделанной. В-третьих, вычислительные затраты на обучение глубоких сетей высоки, и для работы в реальном времени часто требуется GPU-ускорение [2].

1.3. Сравнительный анализ методов фальсифицированного фрагмента на изображении

1.3.1. Обоснование критериев сравнения методов

Для объективного и всестороннего сопоставления различных методов обнаружения фальсифицированного фрагмента на изображении необходимо определить систему критериев, отражающих как точность детекции, так и пригодность метода для практического применения в реальных условиях. Выбор критериев должен основываться на требованиях, предъявляемых к современным системам цифровой криминалистики, а также на особенностях задач, возникающих при анализе медиаконтента в социальных сетях, новостных агрегаторах и системах информационной безопасности. В настоящей работе предлагается использовать пять основных критериев, каждый из которых характеризует

определённый аспект эффективности метода.

Первым и наиболее важным критерием является точность локализации подделанного фрагмента. В отличие от бинарной классификации, где требуется лишь определить факт наличия фальсификации, задача локализации требует указать точные границы изменённой области на пиксельном уровне. Высокое значение точности локализации свидетельствует о том, что метод способен не только обнаружить факт вмешательства, но и точно выделить форму вставленного объекта, что критически важно для последующего анализа и использования результатов в качестве доказательной базы. Оценка точности локализации обычно производится с использованием таких метрик, как индекс пересечения над объединением и F1-мера, которые учитывают как полноту обнаружения поддельных пикселей, так и долю ложноположительных срабатываний. Следует отметить, что высокая точность бинарной классификации ещё не гарантирует точной локализации, поэтому данные метрики должны рассчитываться отдельно для каждой тестовой выборки.

Второй критерий — устойчивость к постобработке изображения. В реальных условиях фальсифицированное изображение почти всегда подвергается сжатию с потерями (особенно в формате JPEG), изменению размера, добавлению шума или применению различных фильтров. Злоумышленник может намеренно применять такие операции для маскировки следов фальсификации, стремясь сделать их невидимыми для автоматических детекторов. Поэтому метод должен сохранять высокую точность обнаружения при различных степенях сжатия JPEG, при изменении разрешения и при добавлении различных видов шума. Устойчивость к постобработке является одним из ключевых требований к практическим системам, поскольку в интернете подавляющее большинство изображений хранится и передаётся в сжатом виде. Сравнение методов по данному критерию должно проводиться при разных коэффициентах качества JPEG и при различных типах и уровнях постобработки, что позволяет оценить робастность каждого подхода.

Третий критерий — обобщающая способность на неизвестных типах фальсификации и датасетах. Метод не должен «переобучаться» под конкретный набор данных или под конкретный тип манипуляций. В идеале обученная модель должна корректно работать на изображениях, полученных из других источников, с другими камерами, с другими типами сжатия и с другими

видами фальсификаций. Для оценки обобщающей способности применяется кросс-валидация на различных датасетах: обучение проводится на одном наборе данных, а тестирование — на другом. Этот критерий особенно важен для нейросетевых методов, которые в силу своей высокой ёмкости могут запоминать специфические артефакты обучающей выборки и терять эффективность при переходе к новым данным.

1.3.2. Таблица сравнения методов

На основе обоснованных в п. 1.3.1 критериев (точность, робастность к постобработке и обобщающая способность) проведём сравнительный анализ трёх основных классов методов обнаружения фальсифицированного фрагмента: аналитических методов целостности, дескрипторных методов на основе ключевых точек и методов на основе свёрточных нейронных сетей (включая их расширения с вниманием и адаптацией признаков). Для каждого критерия используется качественная шкала: «высокая», «средняя», «низкая», а также уточняющие комментарии. Результаты сведены в таблицу 1.1.

Таблица 1.1 – Сравнительная таблица методов

<i>Метод</i>	<i>Точность</i>	<i>Устойчивость к постобработке</i>	<i>Обобщающая способность</i>
Методы на основе анализа целостности изображений	Низкая/Средняя	Низкая	Низкая
Методы на основе поиска ключевых точек	Средняя	Средняя	Низкая
Однопоточная свёрточная нейронная сеть	Средняя/Высокая	Средняя	Средняя
Многopotочная свёрточная нейронная сеть	Высокая	Средняя/Высокая	Средняя/Высокая

На основе данных таблицы 1.1 можно сделать следующие выводы.

Методы на основе анализа целостности изображений обладают неоспоримым преимуществом в независимости от обучающих данных. Однако их точность и робастность к постобработке остаются низкими, особенно при сжатии JPEG ниже 80

Методы на основе поиска ключевых точек (SIFT, SURF) показывают высокую точность локализации фальсификации типа «копирование-вставка» (copy-move), поскольку способны выявлять повторяющиеся фрагменты даже после геометрических преобразований. Это делает их наиболее эффективным инструментом для обнаружения дублирования объектов внутри одного изображения. Их главные недостатки — непригодность для выявления других типов фальсификаций (splicing, inpainting), а также вычислительная сложность, ограничивающая применение на высокоразрешенных изображениях (свыше 10 мегапикселей) и в системах реального времени. Кроме того, устойчивость к постобработке у этих методов ограничена: даже умеренное сжатие JPEG или медианная фильтрация могут существенно снизить количество детектируемых ключевых точек и, следовательно, точность обнаружения. Несмотря на это, методы на основе ключевых точек остаются важным инструментом в арсенале специалистов по компьютерной криминалистике, особенно когда требуется быстро проверить изображение на наличие признаков копирования.

Нейросетевые методы на основе свёрточных нейронных сетей демонстрируют наилучшие показатели по точности локализации и робастности к постобработке, а также способны обнаруживать широкий спектр подделок — от copy-move до deepfake и полностью синтетических изображений. Это обусловлено способностью CNN автоматически извлекать иерархические признаки из данных и адаптироваться к разнообразным типам манипуляций. Особенно высокие результаты достигаются при использовании двухпоточных архитектур, которые разделяют анализ низкоуровневых шумовых артефактов и высокоуровневого семантического содержания, а также при применении механизмов внимания и слоёв адаптации признаков для согласования признаков из разных доменов. Однако нейросетевые методы имеют и существенные недостатки: низкая интерпретируемость («чёрный ящик»), высокая зависимость от размера и качества обучающей выборки, а также значительные вычислительные затраты на обучение и инференс. Кроме того, нейросетевые подходы чувствительны к различиям между обучающими и тестовыми датасетами, что требует применения

тщательной аугментации и, в некоторых случаях, доменной адаптации.

Таким образом, проведённый сравнительный анализ позволяет заключить, что для разработки практического метода обнаружения фальсифицированных фрагментов, способного работать в реальных условиях с различными типами подделок и постобработок, наиболее перспективным является подход на основе двухпоточной свёрточной нейронной сети с механизмами внимания и адаптации признаков. Этот подход сочетает высокую точность локализации, хорошую обобщающую способность и устойчивость к сжатию JPEG, что делает его наиболее подходящим для решения поставленной задачи. В то же время необходимо уделять внимание повышению интерпретируемости и снижению вычислительной сложности, что может быть достигнуто путём оптимизации архитектуры и использования методов визуализации активаций.

1.4. Формализованная постановка задачи

В настоящей работе проектируется метод обнаружения фальсифицированного фрагмента на изображении с помощью свёрточной нейронной сети, а именно — двухпоточной архитектуры с слоями вниманий и адаптацией признаков. Набор данных для обучения должен быть подготовлен — должно быть установлено уникальное соответствие между входным изображением и бинарной маской. Набор данных должен быть предварительно обработан и извлечены признаки. Обученная модель используется для распознавания границ фальсифицированного фрагмента и выдачи маски локализации.

Ниже, на рисунке 1.8, представлена IDEF0-диаграмма нулевого уровня.




Рисунок 1.8 – IDEF0-диаграмма нулевого уровня

Вывод

В данном разделе был проведен анализ предметной области. Также был проведен обзор методов обнаружения фальсификаций в изображении. Были сформулировали критерии их сравнения и проведен сравнительный анализ рассмотренных методов. Также в этом разделе была представлена формализованная постановка задачи в виде IDEF0-диаграммы.

2 Конструкторский раздел

В этом разделе сформулируются требования к разрабатываемому методу и разрабатываемому программному обеспечению, описываются этапы работы алгоритма разрабатываемого метода, также рассматриваются структура разрабатываемой сверточной нейронной сети. Также описывается используемый набор данных для обучения модели и рассматривается структура программного обеспечения.

2.1. Требования и ограничения к разрабатываемому методу

К разрабатываемому методу предъявляются следующие требования.

- Метод должен базироваться на использовании сверточных нейронных сетей с необходимыми модификациями.
- Принимать на вход изображения в форматах PNG, JPG, JPEG, BMP с размером от 216×216 до 1024×1024 включительно.
- Метод должен быть применим для работы с различными типами сцен, а также различными освещением.

К разрабатываемому программному обеспечению предъявляются следующие требования.

- Возможность загрузки изображений в формате PNG, JPG, JPEG или BMP.
- Возможность обработки как RGB – изображений.
- Возможность просмотра информации по процессу обучения модели.
- Возможность просмотра значения метрик качества модели.
- Разрабатываемое ПО должно корректно реагировать на любые действия пользователя.

2.2. Описание разрабатываемого метода

2.2.1. Декомпозиция разрабатываемого метода

Ниже, на рисунке 2.1, представлена IDEF0-диаграмма разрабатываемого метода первого уровня.




Рисунок 2.1 – IDEF0-диаграмма первого уровня

Разрабатываемый метод обнаружения фальсифицированного фрагмента на изображении состоит из четырёх последовательных этапов. Первый этап — предобработка, которая включает нормализацию входного изображения, приведение его к единому размеру и подготовку данных для последующего анализа. Второй этап — извлечение признаков — заключается в формировании карты шумовых признаков. Данный этап критически важен, поскольку именно шумовая карта несёт в себе следы неоднородности, возникающие при вставке фрагмента из другого изображения или при повторном сжатии. Алгоритм извлечения признаков спроектирован так, чтобы подчеркнуть высокочастотные составляющие, в которых маскируются артефакты фальсификации. Третий этап — обучение модели — представляет собой процесс настройки параметров двухпоточной свёрточной нейронной сети с использованием подготовленного размеченного набора данных, включая оптимизацию весов, слоёв адаптации признаков и механизмов внимания. Четвёртый этап — обнаружение фальсификации — заключается в применении обученной модели к новым изображениям для получения пиксельной маски локализации подделанного фрагмента. Такая декомпозиция позволяет чётко разделить функциональные обязанности между модулями программного обеспечения и обеспечивает гибкость.

2.2.2. Алгоритмы предобработки и извлечения признаков

Основная цель предварительной обработки изображений перед их подачей в свёрточную нейронную сеть (CNN) — повысить качество и информатив-

ность данных, чтобы улучшить детектирование артефактов, характерных для глубокого подделки. Этот этап помогает устранить шумы, нормализовать изображения, выделить ключевые признаки и минимизировать влияние вариаций освещения, масштаба и ракурса. В результате CNN может более эффективно фокусироваться на различиях между реальными и синтетическими изображениями, повышая точность обнаружения [27].

Кроме того, предобработка включает в себя приведение всех изображений к единому цветовому пространству RGB и масштабирование интенсивности пикселей к диапазону $[0,1]$, что стандартизирует входной сигнал для нейронной сети. Без такой нормализации градиенты могут стать нестабильными, а процесс обучения — замедлиться. Ниже, на рисунке 2.2, представлены шаги предобработки изображения.



Рисунок 2.2 – Шаги предобработка изображения

Для извлечения признаков из изображений используются карты шумовых признаков.

Ниже на рисунку 2.3 показан алгоритм извлечения карты шумовых признаков.



Рисунок 2.3 – Алгоритм извлечения признаков.

После завершения предварительной обработки запускается итеративный алгоритм выделения шумовых признаков. На вход подаётся нормализованное изображение. Оно сжимается с качеством 95% — это создаёт потери, характерные для сжатия. Затем вычисляется попиксельная разность между исходным нормализованным изображением и его сжатой версией. Полученная разность усиливается — значение ошибки увеличивается. После усиления проверяется, достигнут ли заданный порог отображения. Если порог не достигнут, цикл повторяется: снова вычисляется разность. Как только порог оказывается превышен, алгоритм формирует итоговую карту шумовых признаков. Таким образом, метод многократно накапливает и усиливает малые искажения, обусловленные сжатием, что позволяет выделить слабые артефакты, которые в дальнейшем могут служить характерными признаками для обнаружения.

Эта предобработка позволяет CNN сосредоточиться на анализе наиболее значимых для обнаружения подделок областей, повышая точность модели.

2.2.3. Структура разрабатываемой сверточной нейронной сети

Разрабатываемая сверточная нейронная сеть представляет собой многоуровневую архитектуру, специально спроектированную для эффективного извлечения признаков из изображений. Модель сочетает в себе последовательную обработку через блоки свёртки, слои адаптации признаков и механизмы внимания.

Выбор двухпоточной архитектуры обусловлен необходимостью разделить анализ низкоуровневых шумовых артефактов и высокоуровневого семантического содержания. Шумовой поток оперирует картой остаточных ошибок, которая чувствительна к манипуляциям, но бедна по семантике, тогда как RGB-поток сохраняет информацию о форме, цвете и текстуре объектов. Слияние этих двух потоков в глубоких слоях сети позволяет модели выявлять несоответствия, например, когда семантически корректный объект имеет неправильную шумовую характеристику.

Общая структура сети показана на рисунке 2.4.

Структура сети делится на две основные ветви, работающие с разными представлениями входных данных. Первая ветвь обрабатывает карту шумовых признаков изображения, полученную предварительно. Вторая ветвь работает




Рисунок 2.4 – Общая структура сети.

непосредственно с нормализованным исходным изображением. Такое двухпотокное проектирование позволяет сети одновременно учитывать как низкоуровневые шумовые артефакты, так и высокоуровневые семантические особенности изображения. Структура сети включает три ключевых типа компонентов: блоки свёртки, слои адаптации признаков и слои внимания, которые работают в тесной взаимосвязи.

Блок свёртки является базовым строительным элементом сети. Каждый такой блок представляет собой последовательность операций, типичную для современных CNN: свёртку 3×3 , нормализацию пакетную и функцию активации ReLU.

Ниже, на листинге 2.1, показана реализация блока свёртки.

Листинг 2.1 – Реализация блока свёртки

```

1 self.conv1 = nn.Sequential(
2     nn.Conv2d(3, bn, kernel_size=3, padding=1),
3     nn.BatchNorm2d(bn),
4     nn.ReLU(True)
5 )

```

Блоки свёртки отвечают за извлечение иерархических признаков на разных масштабах. Благодаря использованию свёрток с размером ядра 3×3 и дополнением сохраняется пространственное разрешение карт признаков, что важно для последующей точной локализации границ подделки. Нормализация пак-

тов ускоряет обучение и стабилизирует динамику градиентов, а нелинейность ReLU вносит необходимую нелинейность, позволяя сети аппроксимировать сложные функции.

Понижение разрешения выполняется не с помощью стандартных операций пулинга (например, MaxPooling или AveragePooling), а с помощью свёрточных слоёв с шагом больше 1. Это позволяет не только уменьшить пространственные размеры карт признаков, но и одновременно увеличить глубину каналов, а также изучить более информативные признаки, так как свёртка с шагом является обучаемой операцией.

На листинге 2.2 показана реализация слоя уменьшения разрешения.

Листинг 2.2 – Реализация слоя уменьшения разрешения

```
1 self.conv1b = nn.Sequential(  
2     nn.Conv2d(bn, bn, kernel_size=4, padding=1, stride  
3     =2),  
4     nn.BatchNorm2d(bn),  
5     nn.ReLU(True)  
6 )
```

Здесь ядро свёртки имеет размер 4×4 , шаг 2 и дополнение 1, что приводит к уменьшению высоты и ширины карты признаков в два раза. Такой подход обеспечивает лучшее сохранение информации по сравнению с пулингом и способствует формированию инвариантных к мелким смещениям признаков.

В модели используются несколько последовательных блоков downsampling, что позволяет построить пирамиду признаков с различными масштабами (от полного разрешения до $1/8$, $1/16$ и т.д.). Это необходимо для захвата как мелких деталей, так и глобального контекста.

Для восстановления пространственного разрешения до размера входного изображения применяется билинейная интерполяция с последующей свёрткой 1×1 для согласования числа каналов. Такой подход широко используется в энкодер-декодер архитектурах, так как он прост в реализации и не вносит дополнительных обучаемых параметров.

На листинге 2.3 показана реализация слоя увеличения разрешения.

Листинг 2.3 – Реализация слоя увеличения разрешения

```
1 self.deconv4 = nn.Sequential(  
2     nn.Upsample(scale_factor=2, mode='bilinear',  
3     align_corners=True),  
4     nn.Conv2d(bn*4, bn*4, kernel_size=1))
```

Сначала с помощью `nn.Upsample` увеличивается размер карты признаков до нужной высоты и ширины (`bw`, `bh`), затем свёртка 1×1 изменяет количество каналов. После этого часто следуют дополнительные свёрточные слои (3×3), нормализация и активация, которые позволяют уточнить восстановленные признаки.

В модели слой увеличения размерности выполняется на нескольких уровнях, при этом результаты объединяются со остаточными связями с соответствующими картами признаков из энкодерной части. Это позволяет эффективно восстанавливать пространственные детали, которые могли быть потеряны при уменьшения размерности.

Слой адаптации признаков — это специализированные модули, которые обеспечивают эффективное согласование и слияние признаков, поступающих из двух параллельных потоков (шумового и RGB-потока). Каждый такой слой принимает на вход карту признаков из соответствующего потока и применяет к ней ряд преобразований: 1×1 -свёртку для изменения количества каналов, остаточное соединения и нормализацию.

Ниже на рисунке 2.5 представлена структура слоя адаптации признаков.

Основная задача этих слоёв — привести признаки из разнородных доменов (шум и естественное изображение) к единому представлению, минимизируя доменное расхождение и усиливая полезные для задачи обнаружения фальсифицированного фрагмента.

Ниже, на листинге 2.4, показана реализация слоя адаптации признаков.

Листинг 2.4 – Реализация слоя адаптации признаков

```
1 DL4 = self.deconv4(L52)
2 DL4_add = DL4 + L4
3
4 DL44 = self.deconv44(L55)
5 DL44_add = DL44 + L44
6 DL44b = self.deconv44b(DL44_add)
7 DL44bada = DL44b + DL44_add
8
9 DL4_cat = torch.cat([DL4_add, L4c, DL44bada], 1)
10
11 DL4_att = self.att4(DL4_cat)
12 DL4b = self.deconv4b(DL4_att)
```

Слой адаптации признаков спроектированы как остаточные блоки (англ. *residual blocks*) с операциями свёртки 1×1 , нормализации и сложения с исходным тензором. Такая архитектура выбрана для согласования признаков, посту-




Рисунок 2.5 – Слой адаптации признаков.

падающих из двух различных доменов – шумовой карты и RGB-изображения. Поскольку эти два потока имеют существенно разные статистические распределения (высокочастотный шум против семантически насыщенных цветовых текстур), прямое объединение их карт признаков приводит к сильным помехам и размытию границ предсказанной маски. Остаточные блоки позволяют эффективно фильтровать помехи, сохраняя при этом полезную высокочастотную информацию за счёт skip-соединений, которые обеспечивают передачу исходных признаков на выход блока. Это объясняется тем, что остаточные соединения облегчают обучение, позволяя градиентам беспрепятственно проходить через слой, а также дают возможность сети «довычитывать» невязку между разнородными представлениями, что ведёт к более точной локализации даже на сложных текстурах. Таким образом, выбор остаточной архитектуры для адаптации при-

знаков является оптимальным компромиссом между сохранением дискриминативной информации и подавлением междоменных шумов, что подтверждается полученными количественными показателями.

Слой внимания является важнейшим механизмом выделения релевантных признаков сети. Эти слои динамически перевешивают важность различных каналов и пространственных областей, позволяя сети концентрироваться на областях с высокой вероятностью манипуляции. Особенно эффективно слои внимания работают после слияния двух потоков, помогая выделить несоответствия между шумовыми аномалиями и семантическим содержанием. Слой внимания включает глобальный пулинг, два полносвязных слоя с активациями ReLU и Sigmoid, а также операцию масштабирования, что позволяет динамически перераспределять веса по каналам карты признаков. Их структура представлена ниже, на рисунке 2.6.

Слой внимания работает следующим образом: сначала глобальный усредняющий пулинг сжимает пространственную размерность карты признаков, формируя вектор описания каналов. Затем два полносвязных слоя (с уменьшением размерности и последующим восстановлением) вычисляют веса важности для каждого канала. После применения сигмоидной функции эти веса нормализованы в диапазоне $[0,1]$ и умножаются на исходную карту признаков, усиливая значимые каналы и подавляя неинформативные. Такой механизм особенно полезен для обнаружения фальсификаций, так как поддельные области часто активируют лишь небольшое подмножество каналов.

Слой внимания построен по принципу сжатия-возбуждения (англ. Squeeze-and-Excitation, SE), который позволяет динамически перекалибровывать каналные веса карт признаков. Такая архитектура выбрана потому, что при обнаружении фальсифицированных фрагментов решающую роль играют не все каналы одинаково: высокочастотные шумовые артефакты, характерные для подделок, сосредоточены в определённых каналах, тогда как большинство каналов несут информацию о подлинном фоне. Механизм SE, состоящий из глобального усредняющего пулинга, двух полносвязных слоёв с нелинейностями ReLU и Sigmoid, позволяет сети научиться выделять именно те каналы, которые содержат дискриминативные признаки манипуляции. Это особенно важно при сильном дисбалансе классов, когда область подделки занимает менее 5–10 % площади изображения. Таким образом, выбор именно такой структуры внима-




Рисунок 2.6 – Слой внимания.

ния обусловлен её способностью фокусироваться на релевантных артефактах и подавлять фоновый шум, что критически важно для точной локализации границ фальсификации.

На листинге 2.5, показана реализация слоя внимания.

Листинг 2.5 – Реализация слоя внимания

```
1 class SELayer(nn.Module):
2     def __init__(self, channel, reduction=16):
3         super(SELayer, self).__init__()
4         self.avg_pool = nn.AdaptiveAvgPool2d(1)
5         self.fc = nn.Sequential(
6             nn.Linear(channel, channel // reduction,
7             bias=False),
8             nn.ReLU(inplace=True),
9             nn.Linear(channel // reduction, channel,
10            bias=False),
11            nn.Sigmoid()
12        )
13
14    def forward(self, x):
15        b, c, _, _ = x.size()
16        y = self.avg_pool(x).view(b, c)
17        y = self.fc(y).view(b, c, 1, 1)
18        return x * y.expand_as(x)
```

Общая структура сети организована по принципу двух параллельных ветвей с последующим многоуровневым слиянием и декодером. Входные данные поступают в сеть по двум независимым путям. Верхний поток начинается с карты шумовых признаков, полученной предварительно. Этот поток использует блоки свёртки и слои уменьшения размерности, постепенно извлекая характерные шумовые паттерны, возникающие при JPEG-сжатии, копировании-вставке и так далее. На нескольких уровнях глубины из этого потока ответвляются признаки в слои адаптации признаков, где они приводятся в соответствие с признаками из второго потока.

Нижний поток принимает нормализованное RGB-изображение. Он также состоит из последовательности блоков свёртки и downsampling-слоёв, но сохраняет больше информации о цветовом и текстурном содержимом. После нескольких стадий извлечения признаков происходит поэтапное слияние информации из обоих потоков через слои адаптации признаков. После слияния на нескольких масштабах объединённые признаки проходят через последовательность слоёв внимания, которые уточняют представление, подавляя шум и усиливая области с подозрительными артефактами. Далее следует декодирующая часть сети, включающая слои увеличения размерности, skip-соединения с ранними уровнями энкодера и финальные свёрточные блоки. Завершается архитектура выходным слоем, формирующим карту локализации подделки с тем

же пространственным разрешением, что и исходное изображение.

Использование пропущенных связей между энкодером и декодером позволяет восстанавливать мелкие пространственные детали, которые иначе теряются при многократном уменьшении разрешения. Это критически важно для точного определения границ фальсифицированного фрагмента, особенно если он имеет небольшие размеры или сложную форму. В предложенной сети пропущенные связи организованы на четырёх масштабных уровнях, что обеспечивает высокую точность сегментации.

Такое сочетание двухпоточной обработки, модулей адаптации признаков и механизмов внимания позволяет сети эффективно обнаруживать как локальные, так и глобальные манипуляции, сохраняя при этом хорошую обобщающую способность на различных типах подделок и различных источниках изображений. Архитектура является достаточно лёгкой для обучения на современных графического процессора, но при этом обладает высокой выразительной силой благодаря продуманному взаимодействию между шумовым и визуальным доменами. В целом, предложенная структура разрабатываемой сверточной нейронной сети сочетает в себе классические принципы CNN с современными механизмами, что делает её особенно подходящей для сложной и практически значимой задачи обнаружения цифровых фальсификации изображений.

2.3. Структура разрабатываемого программного обеспечения

Разрабатываемое программное обеспечение состоит из двух модулей:

- модуль, реализующий метод обнаружения фальсифицированного фрагмента на изображениях с использованием сверточной нейронной сети;
- пользовательское приложение, производящее обнаружение фальсифицированного фрагмента на изображениях на основе разработанного метода, а так же предоставляющее возможность обучения модели, используемой в предыдущем модуле.

Модуль CNN модели

В данном модуле происходит только обучение и сохранение модели. Модуль должен быть использован либо при первоначальном обучении модели.

Входными данными для модуля является набор данных CASIA v2.0, содержащий пары «исходное изображение – бинарная маска разметки». Результа-

том работы модуля является файл, содержит в себе обученную модель, т.е. ее структуру и весовые коэффициенты соответствующих связей. Это необходимо для того, чтобы не тратить время на обучение модели при повторном использовании, так как процесс обучения может занимать продолжительный период времени в зависимости от некоторых факторов.

На рисунке 2.7 представлена схема работы с модулем CNN модели.




Рисунок 2.7 – Схема работы с модулем CNN модели

Модуль пользовательского приложения

Данный модуль реализует непосредственное обнаружение фальсифицированных фрагментов на изображениях, загружаемых пользователем. Входными данными для модуля является цветное изображение в одном из поддерживаемых форматов (PNG, JPG, JPEG, BMP, TIF), а также заранее обученная модель, сохранённая на предыдущем этапе. Модуль формирует выходные данные: исходное изображение с наложенными полупрозрачными ограничивающими рамками и тепловой картой, а также отдельно бинарную маску подделки. Вся эта информация отображается в пользовательском интерфейсе вместе со служебными данными — процентом и количеством фальсифицированных пикселей и временем обработки. Пользователь может скопировать полученный отчёт или сохранить результат в виде изображения. Таким образом, модуль приложения обеспечивает полный цикл анализа, от загрузки изображения до визуализации и предоставления количественных результатов, делая систему доступной для конечного пользователя.

На рисунке 2.8 представлена схема работы с модулем пользовательского приложения.




Рисунок 2.8 – Схема работы с модулем пользовательского приложения

2.4. Набор данных для обучения модели

Для обучения и оценки модели использовался широко известный в области цифровой криминалистики набор данных CASIA v2.0. Данный датасет был считается одним из наиболее крупных и сложных публичных наборов данных для задач обнаружения и локализации различных типов манипуляций с изображениями[28].

CASIA v2.0 содержит 5123 поддельных изображений и соответственные бинарные маски. Поддельные изображения включают два основных типа манипуляций: *copy-move* (копирование и вставка внутри одного изображения) и *splicing* (вставка объектов из других изображений). Изображения имеют различное разрешение и представлены в нескольких форматах: PNG, JPEG и TIFF. Важной особенностью датасета является наличие постобработки поддельных областей (размытие, сжатие, поворот, масштабирование), что делает задачу локализации значительно более сложной и приближенной к реальным условиям.

Применение CASIA v2.0 позволило модели обучаться на разнообразных сценариях подделок, различных текстурах, освещении и постобработках, что существенно повышает обобщающую способность сети. Перед обучением изображения проходили этап нормализации и предварительной аугментации для повышения устойчивости модели к вариациям условий съёмки и сжатия.

Использование именно этого датасета обеспечивает возможность объективного сравнения результатов предлагаемой модели с существующими современными подходами в области обнаружения цифровой фальсификации изображений.

Ниже, на рисунке 2.9 представлен пример изображений из набора данных CASIA v2.0.



Рисунок 2.9 – Пример изображений из набора данных CASIA v2.0

Вывод

В этом разделе были сформулированы требования к разрабатываемому методу и разрабатываемому программному обеспечению и описаны этапы работы алгоритма разрабатываемого метода, также была рассматривана структура разрабатываемой сверточной нейронной сети. Был описан используемый набор данных для обучения модели и была рассмотрена структура программного обеспечения.

3 Технологический раздел

В этом разделе приводится выбор языка программирования и средства программирования и рассматриваются необходимые библиотеки, которые используются для разработки программного обеспечения. Также описывается формат входных и выходных данных. Также приводятся описание пользовательского интерфейса и руководство пользователя для установки и использования программного обеспечения.

3.1. Выбор средств реализации программного обеспечения

3.1.1. Выбор языка программирования

Для реализации программного обеспечения был использован язык программирования Python[29]. Этот выбор обусловлен следующими причинами:

- это язык программирования высокого уровня, имеет простой синтаксис;
- наличие библиотек с открытым исходным кодом, предоставляющих полный набор инструментов для предварительной обработки изображений и построения сетей СНН;
- имеется навыки использования данного языка программирования, что позволяет сократить время написания программы.

Кроме того, Python является стандартом в области глубокого обучения и компьютерного зрения: подавляющее большинство исследовательских проектов и промышленных решений в этой сфере реализованы именно на Python. Это обеспечивает широкую поддержку сообщества, обилие готовых примеров кода и возможность интеграции с другими инструментами. Ещё одним важным преимуществом является кроссплатформенность: код, написанный на Python, может выполняться на Windows, Linux и macOS без существенных изменений.

3.1.2. Выбор среды программирования

Для разработки программы использовалась среда Visual Studio Code [30] в качестве среды разработки по следующим причинам:

- доступна бесплатная версия;

- имеет множество утилит, упрощающих написание кода;
- интеграция с системой контроля версий Git и инструментами разработки;
- имеются навыки программирования при помощи данной среды, что сокращает время написания программы.

Visual Studio Code также предлагает богатую экосистему расширений: для работы с Python, для форматирования кода, для проверки синтаксиса и для работы с Jupyter Notebooks. Встроенный терминал и отладчик позволяют быстро запускать скрипты и находить ошибки. Благодаря низкому потреблению ресурсов VS Code комфортно работает даже на устройствах с ограниченной памятью.

Библиотека `torch` (PyTorch)[31] используется для создания сверточной нейронной сети, потому что она предоставляет все необходимые инструменты, такие как базовые слои для создания сетевых архитектур, функции активации, оптимизаторы и функции потерь для обучения. В частности, PyTorch поддерживает вычисления на графических процессорах для ускорения обучения и автоматически рассчитывает градиенты, делая процесс обратного распространения простым и гибким. Это помогает сосредоточиться на разработке модели.

Дополнительным преимуществом PyTorch является его динамический вычислительный граф, который позволяет изменять архитектуру сети на лету и упрощает отладку. В отличие от статических графов TensorFlow 1.x, динамический граф делает код более интуитивным и похожим на обычные программы на Python.

Для создания пользовательского интерфейса используется библиотека Streamlit. Streamlit[32] — мощная и простая библиотека Python с открытым исходным кодом для создания пользовательских интерфейсов для приложений Data Science и машинного обучения. Она превращает обычные скрипты Python в интерактивные веб-приложения, не требуя знаний фронтенда. С помощью Streamlit легко создавать виджеты и визуализации данных (таблицы, диаграммы). При каждом взаимодействии пользователя весь скрипт запускается заново, сохраняя логику работы.

Streamlit был выбран также из-за минимального объема кода, необходимого для создания полноценного интерфейса. Для реализации загрузки изображения, отображения результатов и настройки параметров потребовалось менее

200 строк кода, что значительно меньше, чем при использовании традиционных фреймворков (Flask, Django) с отдельной фронтенд-частью. Это ускорило разработку и позволило сосредоточиться на основной функциональности метода.

Для обучения разработанной свёрточной нейронной сети была выбрана облачная платформа Kaggle. Данный выбор обусловлен несколькими ключевыми факторами. Во-первых, Kaggle предоставляет бесплатный доступ к графическим процессорам (GPU) NVIDIA Tesla P100 или T4, что позволяет существенно ускорить процесс обучения по сравнению с использованием центрального процессора. Во-вторых, платформа не требует установки дополнительного программного обеспечения и драйверов — вся среда выполнения уже предварительно настроена и содержит все необходимые библиотеки для глубокого обучения. В-третьих, Kaggle обеспечивает простой и интуитивно понятный интерфейс в виде Jupyter-ноутбуков, что упрощает процесс разработки, отладки и экспериментирования с гиперпараметрами модели. Бесплатный тариф Kaggle включает 30 часов использования GPU в неделю, а максимальная продолжительность одной сессии составляет до 12 часов, что является достаточным для обучения предложенной модели на наборе данных CASIA v2.0. Платформа также предоставляет возможность загрузки пользовательских наборов данных и их непосредственного использования в ноутбуке. Это позволяет легко интегрировать датасет CASIA v2.0 и проводить эксперименты без необходимости беспокоиться о настройке локальной среды или ограничениях аппаратных ресурсов. В целом, использование Kaggle обеспечивает удобство, доступность и эффективность для обучения модели обнаружения фальсифицированных фрагментов на изображениях.

3.2. Формат входных и выходных данных

На этапе обучения модели входными данными является набор данных, представленный парой «исходное изображение — пиксельная маска разметки». Каждое исходное изображение представляет собой цветную фотографию в формате JPG, JPEG, PNG и TIF. Пиксельная маска разметки служит эталоном и представляет собой одноканальное изображение в градациях серого формата PNG. Размер исходного изображения и размер соответствующей пиксельной маски разметки должны быть одинаковыми.

Это требование синхронизации размеров критически важно, поскольку сеть обучается попиксельному сопоставлению: каждый пиксель входного изображения должен иметь соответствующую метку в маске. В случае несовпадения размеров обучение становится невозможным или приводит к ошибкам. Все изображения в используемом датасете CASIA v2.0 удовлетворяют этому условию. Маски представлены в бинарном виде: белый цвет (255) соответствует фальсифицированному фрагменту, чёрный (0) — подлинной области.

После завершения этапа обучения модели обученная модель будет сохранена для использования на этапе распознавания.

На этапе распознавания входными данными являются цветное изображение в формате JPG, JPEG, PNG и TIF размером от 216x216 до 1024x1024 и обученная модель. Возвращаемые результаты представляют собой предсказание об изображении и обрамляющие окна, окружающие измененные области, отображаемые в пользовательском интерфейсе.

Диапазон размеров (от 216×216 до 1024×1024) выбран эмпирически: слишком маленькие изображения (менее 216 пикселей по меньшей стороне) не содержат достаточного количества деталей для надёжной локализации, а слишком большие (свыше 1024×1024) требуют значительных вычислительных ресурсов и могут не поместиться в видеопамять GPU.

3.3. Структура разрабатываемого программного обеспечения

Разрабатываемый программный продукт состоит из следующих частей.

1. Модуль предобработки изображений — отвечает за предварительную обработку и извлечение признаков из изображений. Модуль содержит функции для загрузки изображения из файла, проверки его формата и разрешения, приведения к требуемому размеру (с сохранением пропорций и дополнением до квадрата), а также для вычисления карты шумовых признаков согласно алгоритму, описанному в п. 2.2.2. Модуль реализует также обратную операцию — восстановление исходного разрешения для маски локализации.
2. Модуль обнаружения фальсифицированного фрагмента — отвечает за обнаружение фальсифицированного фрагмента на изображении. Модуль инкапсулирует загрузку обученной модели, выполнение прямого прохода

по сети для заданного изображения, а также пороговую обработку выходной карты вероятностей для получения бинарной маски.

3. Модуль пользовательского интерфейса — отвечает за предоставление пользовательского интерфейса. Модуль построен на основе библиотеки Streamlit и обеспечивает интерактивное взаимодействие с пользователем через веб-интерфейс. Он включает в себя виджеты для загрузки файлов, ползунки для настройки порога интенсивности тепловой карты, а также области отображения входного изображения, предсказанной маски и наложенных рамок.
4. Модуль сохранения и загрузки модели — отвечает за сохранение обученной модели и загрузку сохраненной модели для использования на этапе обнаружения.

На рисунке 3.1 представлена диаграмма структуры разрабатываемого программного обеспечения.




Рисунок 3.1 – Структура разрабатываемого программного обеспечения.

3.4. Руководство пользователя

Для запуска разработанного программного обеспечения требуется установить интерпретатор для Python и используемые библиотеки. Используемые

в разработке библиотеки, которые необходимы для запуска ПО, приведены в файле `requirements.txt`, который находится в корневом каталоге проекта. С помощью пакетного менеджера `pip` все зависимости можно установить или обновить, запустив в терминале команду, приведенную в листинге 3.1.

Листинг 3.1 – Установка всех необходимых библиотек

```
1 pip install -r requirements.txt
```

Для обучения модели на наборе данных, необходимо запустить скрипт `training.py` через интерфейс среды разработки или выполнив команду в терминале, как показано в листинге 3.2.

Листинг 3.2 – Команда для запуска обучения модели

```
1 python training.py
```

Обучение модели может выполняться как на локальной машине с поддержкой GPU, так и в облачной среде Kaggle. Для локального запуска с использованием графического процессора необходимо предварительно установить CUDA-совместимую версию PyTorch и драйверы NVIDIA.

Если локальный GPU отсутствует или его производительность недостаточна, рекомендуется использовать платформу Kaggle, которая предоставляет бесплатный доступ к GPU (NVIDIA P100 или T4). Для этого нужно загрузить проект в виде Kaggle Notebook, включить в настройках ускоритель GPU, загрузить датасет CASIA v2.0 (например, как отдельный Dataset или через добавление файлов) и выполнить ту же команду в ячейке ноутбука. Kaggle автоматически управляет средой, поэтому нет необходимости вручную настраивать драйверы. После завершения обучения полученная модель может быть скачана и использована в локальном приложении. Такой подход особенно полезен при ограниченных вычислительных ресурсах или при необходимости быстрого экспериментирования с гиперпараметрами.

После обучения модели пользователь может использовать ее через пользовательский интерфейс, используя команды, представленные в листинге 3.3.

Листинг 3.3 – Команда для запуска приложения

```
1 python -m streamlit run app.py
```

После выполнения этой команды в терминале появится локальный URL (обычно `http://localhost:8501`), который необходимо открыть в веб-браузере. Приложение будет работать до тех пор, пока терминал не будет закрыт или

не будет прервано выполнение (Ctrl+C). Streamlit автоматически перезагружает приложение при изменении исходного кода, что удобно для отладки. Для остановки сервера достаточно нажать Ctrl+C в терминале.

В результате разработанное программное обеспечение может предсказывать об изображении и показать фальсифицированные фрагменты в изображении.

3.5. Интерфейс пользователя

Пользовательский интерфейс, который представлен на рисунке 3.2, был разработан с помощью библиотеки streamlit.




Рисунок 3.2 – Интерфейс пользователя.

Интерфейс разделен на две основные части: панель настроек и область загрузки изображений. В разделе настроек пользователи могут настроить интенсивность цвета тепловой карты. Основная часть приложения сосредоточена на функции загрузки изображений, поддерживая перетаскивание файлов или ручной выбор в различных форматах для анализа и визуального отображения областей с искажениями в виде тепловых карт, бинарных масок.

После выбора пользователем файла изображения модель обработает его и выдаст результат. Если изображение не содержит фальсифицированного фрагмента, будет выдано сообщение, как показано на рисунке 3.3.

Если загруженный файл изображения содержит фальсифицированные фрагменты, результатом будет изображение, содержащее ограничивающие рамки, указывающие области изображения, которые могут быть сфальсифицированы.




Рисунок 3.3 – Пример обнаружения при загрузке оригинального файла изображения

ны, процент сфальсифицированные пикселей и координаты этих ограничивающих рамок.

Ниже, на рисунке 3.4, приведён пример файла изображения, который имеет сфальсифицированные фрагменты.




Рисунок 3.4 – Пример обнаружения при загрузке файла изображения, который содержит фальсифицированные фрагменты

Кроме того отображения маски, также показывается дополнительная информация: процент и количество пикселей, классифицированных как поддель-

ные; и время обработки каждого изображения. Эти данные отображаются и могут быть скопированы пользователем.

Вывод

В этом разделе были приведены выбор языка программирования и средства программирования и рассмотрены необходимые библиотеки, которые используются для разработки программного обеспечения. Также был описан формат входных и выходных данных. Также были приведены описание пользовательского интерфейса и руководство пользователя для установки и использования программного обеспечения.

4 Исследовательский раздел

4.1. Метрики оценки качества модели

Поскольку задача обнаружения фальсифицированного фрагмента на изображении формулируется как задача сегментации на уровне пикселей, оценка качества модели должна учитывать как классификационную точность, так и пространственное соответствие предсказанных и истинных областей сфальсифицированного. В связи с этим для оценки качества метода используется комплекс метрик, специализированных для задач локализации аномалий.

Базой для вычисления всех показателей служат следующие понятия, определяемые на уровне каждого пикселя тестовой выборки:

- TP (англ. True Positive) — количество пикселей, корректно классифицированных как принадлежащих области сфальсифицированных;
- TN (англ. True Negative) — количество пикселей, корректно классифицированных как принадлежащих фону;
- FP (англ. False Positive) — количество пикселей, ошибочно отнесённых к области сфальсифицированных;
- FN (англ. False Negative) — количество пикселей области сфальсифицированных, пропущенных моделью.

Точность на уровне пикселей отражает долю правильно классифицированных пикселей от общего числа пикселей в тестовой выборке:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}. \quad (4.1)$$

Данная метрика удобна для общей оценки, однако при сильном дисбалансе классов (область подделки обычно занимает менее 5-10 % площади изображения) она может давать завышенные результаты за счёт доминирования класса фона.

Для более объективной оценки качества выделения целевой области используются точность (Precision) и полнота (Recall):

$$Precision = \frac{TP}{TP + FP}. \quad (4.2)$$

$$Recall = \frac{TP}{TP + FN}. \quad (4.3)$$

На основе этих показателей вычисляется F1-мера, представляющая собой гармоническое среднее точности и полноты:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{2TP}{2TP + FP + FN}. \quad (4.4)$$

F1-мера устойчива к дисбалансу классов и широко применяется в задачах обнаружения локальных артефактов, поскольку учитывает как пропущенные ложные пиксели, так и ложные срабатывания на фоне.

Ключевой метрикой пространственного соответствия является индекс Жаккара или коэффициент пересечения над объединением (англ. Intersection over Union, IoU):

$$IoU = \frac{TP}{TP + FP + FN}. \quad (4.5)$$

Индекс Жаккара измеряет степень перекрытия предсказанной маски подделки с эталонной разметкой и является стандартом де-факто в задачах сегментации. Значение индекса Жаккара = 1 указывает на идеальное совпадение границ, а IoU=0 — на полное отсутствие пересечения.

В отличие от F1-меры, индекс Жаккара более строго штрафует за плохое совпадение границ: например, если предсказанная маска полностью покрывает истинную, но при этом значительно больше её по площади, F1-мера может оставаться высокой, а индекс Жаккара резко падает. Поэтому в задачах точной локализации фальсифицированных фрагментов рекомендуется использовать обе метрики совместно. В настоящем исследовании итоговая оценка качества модели производится по средним значениям F1 и индекса Жаккара на тестовой выборке.

Все метрики вычисляются на уровне пикселей для каждой тестовой пары «изображение – маска», после чего усредняются по всей тестовой выборке. Такой комплексный подход (F1-мера и индекс Жаккара) обеспечивает всестороннюю оценку способности сверточной нейронной сети локализовывать фальсифицированные фрагменты при различных объёмах и конфигурациях входных данных. В дальнейшем эти две метрики будут использоваться как основные для анализа результатов всех экспериментов.

4.2. Технические характеристики

Технические характеристики устройства, на котором выполнялись исследования разработанного метода:

- операционная система Window 10 Home Single Language [33];
- память 8 Гб;
- процессор 11th Gen Intel(R) Core(TM) i5-1135G7 2.42 ГГц, 4 ядра [34].

Во время выполнения исследований устройство было подключено к сети электропитания, нагружено приложениями окружения и самой системой замера.

Для проведения исследований разработанного метода используются выборки из набора данных Casia v2. Количество изображений в каждой раз используется одинаковое. Исходная выборка разбивается на обучающую (80% объема) и тестовую (20%) выборки.

Как отмечалось раньше, метрики F1-меры и индекса Жаккара используются в качестве метрики для оценки качества классификатора.

4.3. Влияние слоя внимания на качество модели

Целью данного исследования является изучение эффективности использования слоев внимания в реализованной модели сверточной нейронной сети.

Для проведения этого исследования было выполнено сравнительное тестирование двух конфигураций модели: с использованием слоев внимания и без них. Все остальные компоненты архитектуры оставались неизменными. Эксперимент проводился на одной и той же тестовой выборке, что обеспечило объективность сравнения. Результаты эксперимента представлены в таблице 4.1.

Таблица 4.1 – Зависимость точности от конфигураций

<i>Конфигурация</i>	<i>Значение F1</i>	<i>Значение IoU</i>
С использованием слоев внимания	0.9042	0.8252
Без использования слоев внимания	0.6784	0.5133

Примеры результатов обнаружения модели при различных конфигурациях слоев внимания представлены на рисунке 4.1.



Рисунок 4.1 – Зависимость качества модели от конфигураций слоев внимания.

На основании полученных результатов можно сделать вывод, что добавление слоев внимания приводит к существенному приросту обеих ключевых метрик. Данный результат подтверждает высокую эффективность механизма внимания для задачи обнаружения фальсифицированных фрагментов. Поскольку область подделки обычно занимает малую долю изображения, большинство каналов признаков содержит информацию о нормальном фоне. Без механизма внимания модель «размазывает» внимание по всем каналам, что приводит к высокому уровню ложноположительных срабатываний (FP) и пропуску мелких деталей подделки (FN). Слой внимания позволяет модели фокусироваться на высокочастотных артефактах, характерных для фальсифицированных областей. Это особенно важно при решении задачи сегментации с сильным дисбалансом классов. Таким образом, использование слоев внимания значительно повышает качество модели, делая её более чувствительной к локальным артефактам подделки.

4.4. Влияние слоя адаптации признаков на качество модели

Целью данного исследования является изучение эффективности использования слоев адаптации признаков в реализованной модели сверточной нейронной сети.

Для проведения этого исследования было выполнено сравнительное тестирование трёх конфигураций модели: без использования слоев адаптации признаков, со слоями адаптации в виде единых блоков свёртки и со слоями адаптации в виде остаточных блоков. Все остальные компоненты архитектуры оставались неизменными. Эксперимент проводился на одной и той же тестовой выборке. Результаты эксперимента представлены в таблице 4.2.

Таблица 4.2 – Зависимость точности от конфигураций

<i>Конфигурация</i>	<i>Значение $F1$</i>	<i>Значение IoU</i>
Без использования слоев адаптации признаков	0.6829	0.6011
Слои адаптации признаков как единые блоки свёртки	0.7653	0.7139
Слои адаптации признаков как остаточные блоки	0.9042	0.8252

Примеры результатов обнаружения модели при различных конфигурациях слоев адаптации признаков представлены на рисунке 4.2.

На основании полученных результатов можно сделать вывод, что отказ от слоев адаптации признаков приводит к значительному снижению качества, использование простых сверточных блоков даёт умеренное улучшение, наилучшие результаты достигаются при реализации слоев адаптации в виде остаточных блоков. Основная причина такого различия заключается в природе признаков, поступающих из ветви извлечения признаков. Эти признаки содержат высокочастотные детали, которые при прямом объединении с семантическими картами основной ветви создают значительные помехи. Это приводит к размытию границ предсказанной маски и высокому уровню ложноположительных результатов на фоне. При использовании единых сверточных блоков качество улучшается, но всё ещё наблюдается потеря мелких деталей. Остаточные блоки обеспечивают чёткие, точные границы маски и минимальное количество ложных сра-



Рисунок 4.2 – Зависимость качества модели от конфигураций слоев адаптации признаков.

бываний даже на сложных текстурах фона. Таким образом, слои адаптации признаков, реализованные в виде остаточных блоков, являются оптимальным решением. Они эффективно фильтруют помехи, сохраняют важную высокочастотную информацию и обеспечивают наилучшее качество локализации фальсифицированных фрагментов при сильном дисбалансе классов.

4.5. Влияние объема передаваемых данных на качество работы метода

Целью данного исследования является изучение зависимости точности метода обнаружения фальсифицированного фрагмента от объема передаваемых данных. Поскольку в рамках используемой архитектуры сверточной нейронной сети основным фактором, определяющим объем обрабатываемой информации, выступает пространственное разрешение входного изображения, в эксперименте рассматривались изображения различных размеров: 384×256 , 640×480 и 800×600 пикселей. Большее число пикселей соответствует большему объему данных, поступающих на вход сети.

Тестирование проводилось на единой тестовой выборке. Все компоненты модели, включая слои внимания и адаптации признаков, оставались неизменными. В качестве оцениваемых показателей использовались усредненные по

каждой размерной группе значения F1-меры и IoU. Результаты эксперимента представлены ниже в таблице 4.3.

Таблица 4.3 – Зависимость точности от размеров входного изображения

<i>Размер изображения</i>	<i>Значение F1</i>	<i>Значение IoU</i>
384×256	0.9305	0.8887
640×480	0.9270	0.8792
800×600	0.5834	0.5190

На основании полученных результатов можно сделать вывод, что при умеренном объеме передаваемых данных (разрешения 384×256 и 640×480) модель демонстрирует стабильно высокое качество локализации: средняя F1-мера превышает 0,92, а средний IoU — 0,87. Это свидетельствует о том, что в пределах исследованного диапазона, характерного для многих практических сценариев, эффективность метода практически не зависит от объема данных. Однако при переходе к изображениям большего размера 800×600, то есть при значительном увеличении объема передаваемой информации, наблюдается резкое падение обеих метрик: средняя F1-мера снижается до 0,5834, а средний IoU — до 0,5190. Такое ухудшение объясняется тем, что текущая архитектура сети ориентирована на определенный пространственный масштаб признаков, и при избыточном объеме данных высокочастотные артефакты подделки либо маскируются обилием фоновых деталей, либо требуют более глубокого анализа, не обеспеченного существующей конфигурацией.

Таким образом, проведенный эксперимент подтверждает, что реализованный метод сохраняет высокую эффективность для объемов передаваемых данных, соответствующих разрешениям приблизительно до 640×480. Дальнейшее повышение качества на данных большего объема может быть достигнуто путем модификации архитектуры с целью адаптации к высокоразрешающим изображениям.

4.6. Влияние качества изображения на качество модели

Целью данного исследования является изучение влияния качества изображений на точность разработанного метода.

Для проверки устойчивости модели был проведен эксперимент по сжатию входных изображений по стандарту JPEG. Поскольку в реальных услови-

ях изображения часто подвергаются сжатию, важно оценить, как изменение коэффициента качества влияет на точность локализации. Исследование проводилось при варьировании качества от 0.85 до 1, а результаты по метрикам F1-score и IoU представлены на рисунке 4.3.




Рисунок 4.3 – Зависимость качества модели от качества изображений.

На основании полученных результатов можно сделать вывод, что точность разработанного метода существенно зависит от уровня сжатия JPEG входного изображения. При высоком качестве изображения (коэффициент JPEG равен 100) модель демонстрирует наилучшие результаты. Однако с увеличением степени сжатия (уменьшением коэффициента качества JPEG) наблюдается устойчивое снижение обеих метрик. Данная зависимость свидетельствует о достаточной чувствительности модели к потерям информации, вызванным JPEG-компрессией, которая является одним из наиболее распространённых видов постобработки в реальных условиях. Тем не менее, даже при сильном сжатии модель сохраняет приемлемый уровень точности локализации, что подтверждает её определённую робастность. Полученные результаты указывают на необходимость дальнейшего совершенствования архитектуры, в частности, путём введения дополнительных механизмов устойчивости к JPEG-артефактам.

Вывод

В ходе исследования разработанной сверточной нейронной сети были выбраны и обоснованы основные метрики оценки качества локализации фальсифицированного фрагмента — F1-мера и IoU. Эксперименты показали, что ис-

пользование слоя внимания значительно повышает точность модели. Наилучшие результаты достигаются при применении слоёв адаптации признаков в виде остаточных блоков, которые эффективно фильтруют шум и сохраняют важную информацию. Исследование влияния объема передаваемых данных показало стабильные высокие результаты на изображениях разрешений до 640×480 и заметное снижение качества при переходе к большим объемам (800×600). Кроме того, установлено, что качество работы модели сильно зависит от степени сжатия JPEG: при коэффициенте 100 достигаются максимальные значения метрик, однако даже при сильном сжатии (JPEG = 80) модель сохраняет приемлемую точность. Полученные результаты подтверждают эффективность предложенного подхода и указывают на необходимость дальнейшего повышения робастности к постобработке изображений.

ЗАКЛЮЧЕНИЕ

В рамках настоящей работы был разработан, реализован и исследован метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети. Все поставленные задачи были выполнены.

Был проведен анализ предметной области. Были приведены обзор и сравнение существующих методов обнаружения фальсифицированного фрагмента на изображении. Была представлена формализованная постановка задачи в виде IDEF0-диаграммы.

Были описан метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети, приведены IDEF0-диаграммы метода и схемы его алгоритмов.

Были приведены выбор языка программирования и средства программирования и рассмотрены необходимые библиотеки, которые используются для разработки программного обеспечения. Также был описан формат входных и выходных данных. Также были приведены описание пользовательского интерфейса и руководство пользователя для установки и использования программного обеспечения.

Были описаны технические характеристики устройства для проведения исследований и приведены исследования разработанного метода

Для реализованного метода можно предложить следующие развития:

- ускорение работы метода.
- добавление возможности обнаружения разных областей фальсификации.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Farid H.* Digital Image Forensics // Scientific American. — 2008. — Июнь. — Т. 298. — С. 66—71. — DOI: 10.1038/scientificamerican0608-66.
2. *Verdoliva L.* Media Forensics and DeepFakes: An Overview // IEEE Journal of Selected Topics in Signal Processing. — 2020. — Т. 14, № 5. — С. 910—932. — DOI: 10.1109/JSTSP.2020.3002101.
3. *Birajdar G., Mankar V.* Digital image forgery detection using passive techniques: A survey // Digital Investigation. — 2013. — Окт. — Т. 10. — С. 226—245. — DOI: 10.1016/j.diin.2013.04.007.
4. *Lukás J., Fridrich J., Goljan M.* Detecting digital image forgeries using sensor pattern noise // Proceedings of SPIE - The International Society for Optical Engineering. — 2006. — Февр. — Т. 6072. — С. 362—372. — DOI: 10.1117/12.640109.
5. *Qureshi M. A., Deriche M.* A bibliography of pixel-based blind image forgery detection techniques // Signal Processing: Image Communication. — 2015. — Т. 39. — С. 46—74. — ISSN 0923-5965. — DOI: <https://doi.org/10.1016/j.image.2015.08.008>. — Режим доступа, URL: <https://www.sciencedirect.com/science/article/pii/S0923596515001393>.
6. *Piva A.* An Overview on Image Forensics // International Scholarly Research Notices. — 2013. — Т. 2013, № 1. — С. 496701. — DOI: <https://doi.org/10.1155/2013/496701>. — Режим доступа, URL: <https://onlinelibrary.wiley.com/doi/abs/10.1155/2013/496701>.
7. *Cozzolino D., Verdoliva L.* Noiseprint: a CNN-based camera model fingerprint // CoRR. — 2018.
8. Detection of GAN-Generated Fake Images over Social Networks / F. Marra [и др.] // — 04.2018. — С. 384—389. — DOI: 10.1109/MIPR.2018.00084.
9. Deep Learning for Multimedia Forensics / I. Amerini [и др.] // Foundations and Trends in Computer Graphics and Vision. — 2021. — Авг. — Т. 12. — С. 309—457. — DOI: 10.1561/06000000096.
10. Determining Image Origin and Integrity Using Sensor Noise / M. Chen [и др.] // IEEE Transactions on Information Forensics and Security. — 2008. — Т. 3, № 1. — С. 74—90. — DOI: 10.1109/TIFS.2007.916285.

11. *Bianchi T., Piva A.* Detection of Nonaligned Double JPEG Compression Based on Integer Periodicity Maps // IEEE Transactions on Information Forensics and Security. — 2012. — Т. 7, № 2. — С. 842—848. — DOI: 10.1109/TIFS.2011.2170836.
12. Image Forgery Localization via Fine-Grained Analysis of CFA Artifacts / P. Ferrara [и др.] // IEEE Transactions on Information Forensics and Security. — 2012. — Т. 7, № 5. — С. 1566—1577. — DOI: 10.1109/TIFS.2012.2202227.
13. *Lowe D.* Distinctive Image Features from Scale-Invariant Keypoints // International Journal of Computer Vision. — 2004. — Ноябрь. — Т. 60. — С. 91—110. — DOI: 10.1023/B%3AVISI.0000029664.99615.94.
14. An Evaluation of Popular Copy-Move Forgery Detection Approaches / V. Christlein [и др.] // IEEE Transactions on Information Forensics and Security. — 2012. — Дек. — Т. 7. — С. 1841—1854. — DOI: 10.1109/tifs.2012.2218597.
15. *Lowe D.* Object Recognition from Local Scale-Invariant Features // Proceedings of the IEEE International Conference on Computer Vision. — 2001. — Янв. — Т. 2.
16. Geometric tampering estimation by means of a SIFT-based forensic analysis / I. Amerini [и др.] //. — 04.2010. — С. 1702—1705. — DOI: 10.1109/ICASSP.2010.5495485.
17. Copy-Move Forgery Detection: Survey, Challenges and Future Directions / N. Abd Warif [и др.] // Journal of Network and Computer Applications. — 2016. — Сент. — Т. 75. — DOI: 10.1016/j.jnca.2016.09.008.
18. *Bay H., Tuytelaars T., Van Gool L.* SURF: Speeded up robust features //. Т. 3951. — 07.2006. — С. 404—417. — DOI: 10.1007/11744023_32.
19. Going deeper into copy-move forgery detection: Exploring image telltales via multi-scale analysis and voting processes / E. Silva [и др.] // JOURNAL OF VISUAL COMMUNICATION AND IMAGE REPRESENTATION. — 2015. — Т. 29. — С. 16.
20. *Kaura W. C. N., Dhavale S.* Analysis of SIFT and SURF features for copy-move image forgery detection // 2017 International Conference on Innovations in Information, Embedded and Communication Systems (ICIIECS). — 2017.

21. *Huang H., Guo W., Zhang Y.* Detection of copy-move forgery in digital images using SIFT algorithm // Т. 2. — IEEE Computer Society. 2008. — С. 272—276.
22. *Bayar B., Stamm M. C.* A Deep Learning Approach to Universal Image Manipulation Detection Using a New Convolutional Layer // — Association for Computing Machinery, 2016. — С. 5—10. — DOI: 10.1145/2909827.2930786.
23. *Zhang R., Isola P., Efros A. A.* Colorful Image Colorization // — Springer International Publishing, 2016. — С. 649—666.
24. *Ronneberger O., Fischer P., Brox T.* U-Net: Convolutional Networks for Biomedical Image Segmentation // — Springer International Publishing, 2015. — С. 234—241.
25. Learning Rich Features for Image Manipulation Detection / P. Zhou [и др.] // — 2018. — С. 1053—1061. — DOI: 10.1109/CVPR.2018.00116.
26. *Fridrich J., Kodovsky J.* Rich Models for Steganalysis of Digital Images // IEEE Transactions on Information Forensics and Security. — 2012. — Т. 7, № 3. — С. 868—882. — DOI: 10.1109/TIFS.2012.2190402.
27. Customized Convolutional Neural Network for Accurate Detection of Deep Fake Images in Video Collections / D. Gura [и др.] // Computers, Materials & Continua. — 2024. — Т. 79. — С. 1—10.
28. *Jing D., Wei W.* CASIA Image Tampering Detection Evaluation Database // — 2013.
29. Welcome to Python.org [Электронный ресурс]. — Режим доступа URL: <https://www.python.org/> (дата обращения: 23.11.2025).
30. Visual Studio Code. — Режим доступа URL: <https://code.visualstudio.com/> (дата обращения: 23.11.2025).
31. Библиотека torch. — Режим доступа URL: <https://pytorch.org/> (дата обращения: 24.10.2025).
32. Библиотека streamlit. — Режим доступа URL: <https://streamlit.io/> (дата обращения: 24.11.2025).

33. Windows 10 «Домашняя для одного языка». — Режим доступа URL: <https://tehnichka.pro/windows-10-home-for-one-language/> (дата обращения: 23.04.2026).
34. Intel Core i5-1135G7. — Режим доступа URL: <https://www.notebookcheck.ru/Intel-Core-i5-1135G7-Testirovanie-processora.507554.0.html> (дата обращения: 23.04.2026).

ПРИЛОЖЕНИЕ А

Листинг А.1 – Реализация структуры сверточной нейронной сети

```
1 class MyCNN(nn.Module):
2     def __init__(self, data_size):
3         super(MyCNN, self).__init__()
4
5         bh = data_size[0]
6         bw = data_size[1]
7
8         bn = 32
9
10        self.conv1 = nn.Sequential(
11            nn.Conv2d(3, bn, kernel_size=3, padding=1),
12            nn.BatchNorm2d(bn),
13            nn.ReLU(True)
14        )
15        self.conv1b = nn.Sequential(
16            nn.Conv2d(bn, bn, kernel_size=4, padding=1,
17            stride=2),
18            nn.BatchNorm2d(bn),
19            nn.ReLU(True)
20        )
21        self.conv1c = nn.Conv2d(3, bn, kernel_size=1,
22        padding=0, stride=1)
23        self.conv1l = nn.Sequential(
24            nn.Conv2d(3, bn, kernel_size=3, padding=1),
25            nn.BatchNorm2d(bn),
26            nn.ReLU(True)
27        )
28        self.conv1lb = nn.Sequential(
29            nn.Conv2d(bn, bn, kernel_size=4, padding=1,
30            stride=2),
31            nn.BatchNorm2d(bn),
32            nn.ReLU(True)
33        )
34        self.conv1lada = nn.Sequential(
35            nn.Conv2d(bn, bn, kernel_size=1, padding=0,
36            stride=1),
37            nn.BatchNorm2d(bn),
38            nn.ReLU(True)
39        )
40        self.conv2 = nn.Sequential(
41            nn.Conv2d(2 * bn, 2 * bn, kernel_size=3,
```

Продолжение листинга A.1

```

1         nn.Conv2d(2 * bn, 2 * bn, kernel_size=4,
2         padding=1, stride=2),
3         nn.BatchNorm2d(2 * bn),
4         nn.ReLU(True)
5     )
6     self.conv2c = nn.Conv2d(3, bn, kernel_size=2,
7     padding=0, stride=2)
8     self.conv22 = nn.Sequential(
9         nn.Conv2d(bn, bn, kernel_size=3, padding=1)
10    ,
11    nn.BatchNorm2d(bn),
12    nn.ReLU(True)
13    )
14    self.conv22b = nn.Sequential(
15        nn.Conv2d(bn, bn, kernel_size=4, padding=1,
16        stride=2),
17        nn.BatchNorm2d(bn),
18        nn.ReLU(True)
19    )
20    self.conv22ada = nn.Sequential(
21        nn.Conv2d(bn, bn, kernel_size=1, padding=0,
22        stride=1),
23        nn.BatchNorm2d(bn),
24        nn.ReLU(True)
25    )
26    self.conv3 = nn.Sequential(
27        nn.Conv2d(3 * bn, 4 * bn, kernel_size=3,
28        padding=1),
29        nn.BatchNorm2d(4 * bn),
30        nn.ReLU(True)
31    )
32    self.conv3b = nn.Sequential(
33        nn.Conv2d(4 * bn, 4 * bn, kernel_size=4,
34        padding=1, stride=2),
35        nn.BatchNorm2d(4 * bn),
36        nn.ReLU(True)
37    )
38    self.conv3c = nn.Conv2d(3, bn, kernel_size=4,
39    padding=0, stride=4)
40    self.conv33 = nn.Sequential(
        nn.Conv2d(bn, bn, kernel_size=3, padding=1)
    ,
        nn.BatchNorm2d(bn),
        nn.ReLU(True)
    )
    self.conv33b = nn.Sequential(
        nn.Conv2d(bn, bn, kernel_size=4, padding=1,
        stride=2),
        nn.BatchNorm2d(bn),
        nn.ReLU(True)
    )

```

Продолжение листинга A.1

```

1         )
2         self.conv33ada = nn.Sequential(
3             nn.Conv2d(bn, bn, kernel_size=1, padding=0,
4                 stride=1),
5             nn.BatchNorm2d(bn),
6             nn.ReLU(True)
7         )
8         self.conv4 = nn.Sequential(
9             nn.Conv2d(5 * bn, 8 * bn, kernel_size=3,
10                 padding=1),
11             nn.BatchNorm2d(8 * bn),
12             nn.ReLU(True)
13         )
14         self.conv4b = nn.Sequential(
15             nn.Conv2d(8 * bn, 8 * bn, kernel_size=4,
16                 padding=1, stride=2),
17             nn.BatchNorm2d(8 * bn),
18             nn.ReLU(True)
19         )
20         self.conv4c = nn.Conv2d(3, bn, kernel_size=8,
21             padding=0, stride=8)
22         self.conv44 = nn.Sequential(
23             nn.Conv2d(bn, bn, kernel_size=3, padding=1)
24             ,
25             nn.BatchNorm2d(bn),
26             nn.ReLU(True)
27         )
28         self.conv44b = nn.Sequential(
29             nn.Conv2d(bn, bn, kernel_size=4, padding=1,
30                 stride=2),
31             nn.BatchNorm2d(bn),
32             nn.ReLU(True)
33         )
34         self.conv44ada = nn.Sequential(
35             nn.Conv2d(bn, bn, kernel_size=1, padding=0,
36                 stride=1),
37             nn.BatchNorm2d(bn),
38             nn.ReLU(True)
39         )
40         self.conv5 = nn.Sequential(
41             nn.Conv2d(9 * bn, 8 * bn, kernel_size=3,

```

Продолжение листинга A.1

```

1         nn.ReLU(True)
2     )
3     self.conv55ada = nn.Sequential(
4         nn.Conv2d(bn, bn, kernel_size=1, padding=0,
5         stride=1),
6         nn.BatchNorm2d(bn),
7         nn.ReLU(True)
8     )
9     self.deconv4 = nn.Sequential(
10        nn.Upsample(size=(bw, bh), mode='bilinear')
11    ,
12        nn.Conv2d(9 * bn, 8 * bn, kernel_size=1),
13    )
14    self.att4 = SELayer(channel=10*bn, reduction
15    =16)
16    self.deconv4b = nn.Sequential(
17        nn.Conv2d(10 * bn, 8 * bn, kernel_size=3,
18        padding=1),
19        nn.BatchNorm2d(8 * bn),
20        nn.ReLU(True)
21    )
22    self.deconv44 = nn.Sequential(
23        nn.Upsample(size=(bw, bh), mode='bilinear')
24    ,
25        nn.Conv2d(bn, bn, kernel_size=1),
26    )
27    self.deconv44b = nn.Sequential(
28        nn.Conv2d(bn, bn, kernel_size=3, padding=1)
29    ,
30        nn.BatchNorm2d(bn),
31        nn.ReLU(True)
32    )
33    self.deconv44ada = nn.Sequential(
34        nn.Conv2d(bn, bn, kernel_size=1, padding=0,
35        stride=1),
36        nn.BatchNorm2d(bn),
37        nn.ReLU(True)
38    )
39    self.deconv3 = nn.Sequential(
40        nn.Upsample(size=(2 * bw, 2 * bh), mode='
41        bilinear'),
42        nn.Conv2d(8 * bn, 4 * bn, kernel_size=1),
43    )
44    self.att3 = SELayer(channel=6 * bn,
45    reduction=16)
46    self.deconv3b = nn.Sequential(
47        nn.Conv2d(6 * bn, 4 * bn, kernel_size

```

Продолжение листинга A.1

```

1         =3, padding=1),
2             nn.BatchNorm2d(4 * bn),
3             nn.ReLU(True)
4         )
5         self.deconv33 = nn.Sequential(
6             nn.Upsample(size=(2 * bw, 2 * bh),
mode='bilinear'),
7             nn.Conv2d(bn, bn, kernel_size=1),
8         )
9         self.deconv33b = nn.Sequential(
10             nn.Conv2d(bn, bn, kernel_size=3, padding=1)
11         ,
12             nn.BatchNorm2d(bn),
13             nn.ReLU(True)
14         )
15         self.deconv33ada = nn.Sequential(
16             nn.Conv2d(bn, bn, kernel_size=1, padding=0,
stride=1),
17             nn.BatchNorm2d(bn),
18             nn.ReLU(True)
19         )
20         self.deconv2 = nn.Sequential(
21             nn.Upsample(size=(4 * bw, 4 * bh), mode='
bilinear'),
22             nn.Conv2d(4 * bn, 2 * bn, kernel_size=1),
23         )
24         self.att2 = SELayer(channel=4 * bn, reduction
=16)
25         self.deconv2b = nn.Sequential(
26             nn.Conv2d(4 * bn, 2 * bn, kernel_size=3,
padding=1),
27             nn.BatchNorm2d(2 * bn),
28             nn.ReLU(True)
29         )
30         self.deconv22 = nn.Sequential(
31             nn.Upsample(size=(4 * bw, 4 * bh), mode='
bilinear'),
32             nn.Conv2d(bn, bn, kernel_size=1),
33         )
34         self.deconv22b = nn.Sequential(
35             nn.Conv2d(bn, bn, kernel_size=3, padding=1)
36         ,
37             nn.BatchNorm2d(bn),
38             nn.ReLU(True)
39         )
40         self.deconv22ada = nn.Sequential(
41             nn.Conv2d(bn, bn, kernel_size=1, padding=0,
stride=1),
42             nn.BatchNorm2d(bn),
43             nn.ReLU(True)

```

Продолжение листинга A.1

```

1         )
2         self.deconv1 = nn.Sequential(
3             nn.Upsample(size=(8 * bw, 8 * bh), mode='
bilinear'),
4             nn.Conv2d(2 * bn, bn, kernel_size=1),
5         )
6         self.att1 = SELayer(channel=3 * bn, reduction
=16)
7         self.deconv1b = nn.Sequential(
8             nn.Conv2d(3 * bn, bn, kernel_size=3,
padding=1),
9             nn.BatchNorm2d(bn),
10            nn.ReLU(True)
11        )
12        self.deconv1l = nn.Sequential(
13            nn.Upsample(size=(8 * bw, 8 * bh), mode='
bilinear'),
14            nn.Conv2d(bn, bn, kernel_size=1),
15        )
16        self.deconv1lb = nn.Sequential(
17            nn.Conv2d(bn, bn, kernel_size=3, padding=1)
18        ,
19            nn.BatchNorm2d(bn),
20            nn.ReLU(True)
21        )
22        self.deconv1lada = nn.Sequential(
23            nn.Conv2d(bn, bn, kernel_size=1, padding=0,
stride=1),
24            nn.BatchNorm2d(bn),
25            nn.ReLU(True)
26        )
27        self.conv_end = nn.Conv2d(bn, 2, kernel_size=3,
padding=1, bias=False)
28        self.conv_end_label_edge = nn.Conv2d(bn, 2,
kernel_size=3, padding=1, bias=False)
29        self.conv_end_img_edge = nn.Conv2d(bn, 1,
kernel_size=3, padding=1, bias=False)
30
31        def forward(self, data, label=None):
32            L1 = self.conv1(data)
33            L1b = self.conv1b(L1)
34            L1c = self.conv1c(data)
35            L1l = self.conv1l(data)
36            L1lb = self.conv1lb(L1l)
37            L1la = self.conv1lada(L1lb)
38            L1lada = L1la + L1lb
39            L1b2 = torch.cat([L1b, L1lada], 1)
40
41            L2 = self.conv2(L1b2)

```

Продолжение листинга А.1

```

1      L2b = self.conv2b(L2)
2      L2c = self.conv2c(data)
3      L22 = self.conv22(L11b)
4      L22b = self.conv22b(L22)
5      L22a = self.conv22ada(L22b)
6      L22ada = L22a+L22b
7      L2b2 = torch.cat([L2b, L22ada], 1)
8
9      L3 = self.conv3(L2b2)
10     L3b = self.conv3b(L3)
11     L3c = self.conv3c(data)
12     L33 = self.conv33(L22b)
13     L33b = self.conv33b(L33)
14     L33a = self.conv33ada(L33b)
15     L33ada = L33a + L33b
16     L3b2 = torch.cat([L3b, L33ada], 1)
17
18     L4 = self.conv4(L3b2)
19     L4b = self.conv4b(L4)
20     L4c = self.conv4c(data)
21     L44 = self.conv44(L33b)
22     L44b = self.conv44b(L44)
23     L44a = self.conv44ada(L44b)
24     L44ada = L44a + L44b
25     L4b2 = torch.cat([L4b, L44a], 1)
26
27     L5 = self.conv5(L4b2)
28     L55 = self.conv55(L44b)
29     L55a = self.conv55ada(L55)
30     L55ada = L55a + L55
31     L52 = torch.cat([L5, L55ada], 1)
32
33     DL4 = self.deconv4(L52)
34     DL4_add = DL4 + L4
35     DL44 = self.deconv44(L55)
36     DL44_add = DL44 + L44
37     DL44b_add = self.deconv44b(DL44_add)
38     DL44bada = DL44b + DL44b_add
39     DL4_cat = torch.cat([DL4_add, L4c, DL44bada],
1)
40     DL4_att = self.att4(DL4_cat)
41     DL4b = self.deconv4b(DL4_att)
42
43     DL3 = self.deconv3(DL4b)
44     DL3_add = DL3 + L3
45     DL33 = self.deconv33(DL44b)
46     DL33_add = DL33 + L33
47     DL33b_add = self.deconv33b(DL33_add)
48     DL33ba = self.deconv33ada(DL33b_add)
49     DL33bada = DL33ba + DL33b

```

Продолжение листинга A.1

```

1      DL3_cat = torch.cat([DL3_add, L3c, DL33bada],
2      1)
3      DL3_att = self.att3(DL3_cat)
4      DL3b = self.deconv3b(DL3_att)
5
6      DL2 = self.deconv2(DL3b)
7      DL2_add = DL2 + L2
8      DL22 = self.deconv22(DL33b)
9      DL22_add = DL22 + L22
10     DL22b = self.deconv22b(DL22_add)
11     DL22ba = self.deconv22ada(DL22b)
12     DL22bada = DL22ba + DL22_add
13     DL2_cat = torch.cat([DL2_add, L2c, DL22bada],
14     1)
15     DL2_att = self.att2(DL2_cat)
16     DL2b = self.deconv2b(DL2_att)
17
18     DL1 = self.deconv1(DL2b)
19     DL1_add = DL1 + L1
20     DL11 = self.deconv11(DL22b)
21     DL11_add = DL11 + L11
22     DL11b = self.deconv11b(DL11_add)
23     DL11ba = self.deconv11ada(DL11b)
24     DL11bada = DL11ba + DL11b
25     DL1_cat = torch.cat([DL1_add, L1c, DL11bada],
26     1)
27     DL1_att = self.att1(DL1_cat)
28     DL1b = self.deconv1b(DL1_att)
29
30     end = self.conv_end(DL1b)
31     end_label_edge = self.conv_end_label_edge(DL1b)
32     end_img_edge = self.conv_end_img_edge(DL11b)
33
34     output = torch.argmax(end, dim=1)
35     output2 = torch.argmax(end_label_edge, dim=1)
36     output3 = end_img_edge
37     if not self.training:
38         return output
39     return end, end_label_edge, end_img_edge,
40     output, output2, output3

```

ПРИЛОЖЕНИЕ Б

Презентация к выпускной квалификационной работе на тему «Метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети» состоит из 16 слайдов.