

РЕФЕРАТ

Расчетно-пояснительная записка к выпускной квалификационной работе «Метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети» содержит ?? страниц, 4 части, 0 рисунков, 1 таблиц, список используемых источников из ?? наименований и 1 приложений.

Ключевые слова: компьютерное зрение, глубокое обучение, сверточная нейронная сеть.

Объект разработки – метод обнаружения фальсифицированного фрагмента на изображении.

Цель работы: разработка и программная реализация метода автоматизированного определения области фальсифицированного фрагмента изображения с помощью двухпоточной свёрточной нейронной сети.

В первой части работы приведены обзор и сравнение существующих методов обнаружения фальсифицированного фрагмента на изображении.

Во второй части описан метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети, приведены IDEF0-диаграммы метода и схемы его алгоритмов.

В третьей части обоснован выбор средств разработки, приведена структура ПО, реализующий предложенный метод и описано взаимодействие пользователя с программным обеспечением..

В четвертой части выбраны метрики для оценки качества работы метода и приведены результаты исследования их зависимости от конфигурации нейронной сети и объемов передаваемых данных.

Разработанный метод может найти применение в области информационной безопасности и верификации медиаконтента в средствах массовой информации и социальных сетях. Это позволит своевременно выявлять и блокировать распространение дезинформации.

СОДЕРЖАНИЕ

РЕФЕРАТ	5
ВВЕДЕНИЕ	7
1 Аналитический раздел	8
1.1. Фальсификация изображений и задача её обнаружения .	8
1.1.1. Понятие фальсификации изображений	8
1.1.2. Основные трудности и требования к методам обнаружения .	9
1.2. Методы обнаружения фальсифицированного фрагмента на изображении	11
1.2.1. Методы на основе анализа целостности изображений	11
1.2.2. Методы поиска ключевых точек	14
1.2.3. Методы на основе сверточной нейронной сети	16
1.3. Сравнительный анализ методов фальсифицированного фрагмента на изображении	18
1.3.1. Обоснование критериев сравнения методов	18
1.3.2. Таблица сравнения методов	20
1.4. Формализованная постановка задачи	21
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	22
ПРИЛОЖЕНИЕ А	23

ВВЕДЕНИЕ

В современном информационном обществе огромное количество новостей и статей публикуется каждый день. Чтобы эффективно обрабатывать и анализировать этот объем информации, важно иметь систему классификации новостей. Классификация позволяет автоматически определять тематику новости, ее важность, тональность и другие характеристики. Задача классификации новостей является актуальной и интересной задачей в области обработки естественного языка и машинного обучения. Она имеет широкий спектр применений, начиная от организации и ранжирования новостных потоков до автоматического анализа общественного мнения и выявления трендов.

Решение задачи классификации новостей может иметь большое практическое применение, включая создание интеллектуальных новостных агрегаторов, систем мониторинга общественного мнения, фильтрацию и организацию информации для пользователей. Это способствует улучшению доступа к информации, оптимизации процессов принятия решений и повышению качества новостных сервисов.

Однако, классификация новостей может быть сложной задачей из-за разнообразия тематик, стилей и тональностей новостных статей. Нередко встречаются случаи смешения нескольких тем в одной статье или субъективной интерпретации информации. Поэтому выбор правильного алгоритма и подхода, а также качество и разнообразие обучающих данных играют важную роль в достижении высокой точности классификации.

Цель работы — разработать метод классификации новостных текстов по тематикам с использованием опорных векторов. Для достижения поставленной цели необходимо выполнить следующие задачи:

- провести анализ предметной области, проанализировать предметную область и основные методы классификации текстов;
- разработать метод классификации новостных текстов по тематикам с помощью опорных векторов;
- разработать программное обеспечение, реализующее данный метод;
- оценить результаты работы метода в зависимости от различных параметров программного обеспечения.

1 Аналитический раздел

1.1. Фальсификация изображений и задача её обнаружения

1.1.1. Понятие фальсификации изображений

Под фальсификацией (подделкой) цифровых изображений понимается процесс внесения преднамеренных изменений в исходное изображение с целью искажения визуального содержания или смысла, который оно передаёт. В отличие от обычной обработки (коррекция яркости, цветокоррекция, шумоподавление), фальсификация направлена на создание ложного представления о реальности, что может использоваться как в личных, так и в профессиональных или политических целях [1].

С развитием доступных графических редакторов (Adobe Photoshop, GIMP и др.) и методов глубокого обучения возможности по созданию реалистичных подделок значительно расширились. В связи с этим задача обнаружения фальсификаций становится особенно актуальной в областях журналистики, криминалистики и социальных медиа[2].

В современной литературе по компьютерному зрению принято выделять несколько основных типов фальсификации изображений[3].

- Копирование-вставка (copy-move) — фрагмент изображения копируется и вставляется в другую область того же изображения, часто для сокрытия объектов или их дублирования.
- Вставка объектов из другого изображения (splicing) — часть одного изображения переносится в другое, создавая сцену, которой не существовало в действительности.
- Ретуширование (inpainting) — удаление или замена элементов с помощью заполнения области (например, удаление теней, людей, артефактов).
- Генерация полностью синтетических изображений — создание изображений с нуля с использованием генеративно-состязательных сетей (GAN) или диффузионных моделей.
- Deepfake — замена лица или мимики человека на видео и изображениях с использованием нейросетевых методов.

Цифровая фальсификация оставляет определённые статистические и семантические следы. Например, при копировании-вставке возникает повторяющаяся структура блоков, при вставке — нарушение согласованности шума датчика или освещения, а при ретушировании — аномалии в частотной области (артефакты сглаживания, некорректное сохранение JPEG)[4].

Важно отметить, что понятие фальсификации не включает в себя такие изменения, как сжатие с потерями, масштабирование или поворот, если они не направлены на введение в заблуждение зрителя. Однако в реальных условиях поддельное изображение часто подвергается дополнительным операциям (JPEG-сжатие, изменение размера, фильтрация), что усложняет его обнаружение[5].

Таким образом, для обнаружения фальсифицированного фрагмента необходимо учитывать множество потенциальных аномалий на различных уровнях представления изображения: от пиксельного до семантического.

1.1.2. Основные трудности и требования к методам обнаружения

Задача обнаружения фальсифицированного фрагмента на изображении относится к классу задач пассивной судебной экспертизы изображений. В отличие от активных методов (цифровая подпись, водяные знаки), пассивные методы не требуют предварительного внедрения вспомогательной информации, однако сталкиваются с рядом принципиальных трудностей, обусловленных как свойствами самих изображений, так и действиями злоумышленника[6].

К числу основных трудностей относятся.

1. Отсутствие эталонного («чистого») изображения. В большинстве практических сценариев (например, при проверке фотографий в СМИ или на интернет-платформах) исходное неизменённое изображение недоступно. Поэтому метод должен выявлять аномалии исключительно на основе статистических и семантических характеристик самого анализируемого файла.
2. Разнообразие типов фальсификаций. Как отмечалось в п. 1.1.1, подделки могут быть выполнены методами copy-move, splicing, inpainting, deepfake и др. Каждый тип оставляет различные следы: повторяющиеся блоки,

несоответствие шума сенсора, артефакты интерполяции или генеративные контуры. Универсальный метод должен быть устойчивым к нескольким типам подделок [7].

3. Соккрытие следов подделки послеоперационной обработкой. Злоумышленник может применять к поддельному изображению сжатие JPEG, масштабирование, добавление шума, медианную фильтрацию или размытие [5]. Эти манипуляции намеренно затрудняют обнаружение артефактов, разрушая статистические аномалии, внесённые в момент фальсификации.
4. Разнородность исходных изображений. Метод не должен полагаться на фиксированные характеристики (размер, разрешение, цветовое пространство, модель камеры), так как изображения в реальных условиях поступают из самых разных источников [8]. Это требует инвариантности к разрешению, коэффициенту сжатия и уровню шума.
5. Ограничения по вычислительным ресурсам и времени. Применение метода в потоковых системах (социальные сети, новостные агрегаторы) требует быстрой обработки (миллисекунды на изображение) и работы с большими объёмами данных. Слишком ресурсоёмкие модели неприменимы в реальном времени.

В связи с перечисленными трудностями к современным методам обнаружения фальсифицированного фрагмента предъявляются следующие требования [9]:

- Высокая точность: метод должен обеспечивать высокие значения метрик IoU, F1-меры и точности классификации пикселей на тестовых наборах, сбалансированных по типам подделок.
- Робастность (устойчивость): метод должен сохранять работоспособность после сжатия JPEG, изменения размера, добавления шума и других типов постобработки.
- Обобщающая способность: обученная модель должна корректно работать на изображениях, взятых из датасетов, не участвовавших в обучении, и на неизвестных типах подделок.

- Вычислительная эффективность: время детекции одного изображения должно быть сопоставимо с временем его загрузки или публикации (целевые значения – не более 0,5 секунды на изображение разрешением 512×512 на современном GPU).
- Локализация фрагмента: метод должен не только выносить бинарное решение, но и выдавать карту локализации с указанием границ изменённой области (пиксельная маска).
- Инвариантность к изображению: метод не должен зависеть от конкретной модели камеры, формата (JPEG, PNG, BMP) и цветовой схемы (RGB, YCbCr).

Таким образом, разработка практического метода обнаружения фальсифицированного фрагмента представляет собой сложную многокритериальную задачу, требующую компромисса между точностью, устойчивостью и скоростью работы.

1.2. Методы обнаружения фальсифицированного фрагмента на изображении

1.2.1. Методы на основе анализа целостности изображений

Методы обнаружения фальсифицированного фрагмента на основе анализа целостности изображений (integrity-based methods) опираются на предположение, что любая модификация исходного изображения нарушает определённые статистические закономерности, присущие естественным («честным») изображениям. В отличие от методов поиска ключевых точек, которые фокусируются на локальных геометрических и текстурных особенностях, подходы на основе целостности анализируют непротиворечивость таких характеристик, как шум датчика (PRNU – photo-response non-uniformity), корреляция между цветовыми каналами, артефакты интерполяции при демозаике Байера, а также двукратное сжатие JPEG [1].

Одним из наиболее известных методов целостности является анализ шума датчика (sensor pattern noise). Каждая цифровая камера оставляет уникальный «отпечаток» – PRNU, который возникает из-за неоднородной чувствительности пикселей [2]. При вставке фрагмента из другого изображения (splicing)

в области вставки нарушается согласованность PRNU: в подделанной области присутствует шум другой камеры. Метод вычисляет PRNU для анализируемого изображения (обычно с помощью вейвлет-фильтрации) и оценивает его корреляцию с эталонным шумом предполагаемой камеры. Если фрагмент изображения имеет статистически значимое расхождение в структуре шума, это свидетельствует о подделке [3]. Основное ограничение данного подхода – необходимость знать эталонный шум камеры, что в реальных условиях не всегда возможно.

Другое направление анализа целостности связано с детектированием двойного сжатия JPEG (double JPEG detection). Большинство цифровых изображений сохраняются в формате JPEG с потерями. Если злоумышленник редактирует изображение и сохраняет его повторно, возникает так называемое двойное сжатие с возможно разными таблицами квантования [4]. Статистический анализ гистограммы коэффициентов дискретного косинусного преобразования (DCT) позволяет выявить характерные периодические паттерны, возникающие при повторном квантовании. В частности, наличие двух пиков в распределении DCT-коэффициентов для отдельных частотных полос является сильным индикатором модификации. Этот метод особенно эффективен для обнаружения операций копирования-вставки (copy-move), однако он не локализует точную область подделки, а лишь даёт бинарный ответ о вмешательстве [5].

К методам целостности также относится анализ согласованности освещения (illumination consistency). При вставке объекта из другого изображения часто возникает несоответствие направлений, интенсивности или цветовой температуры источников света на вставленном фрагменте и на окружающей области [6]. Ранние методы оценивали направление света по бликам на сферических объектах, современные – используют глубокие нейросети для моделирования карты освещения всего изображения. Например, сеть может предсказывать нормали поверхности и параметры освещения, после чего сравниваются статистические распределения освещённости в разных блоках. Несмотря на концептуальную привлекательность, этот подход чувствителен к форме объектов, текстуре и наличию теней, что ограничивает его практическое применение [7].

Отдельную группу составляют методы анализа корреляции между цветовыми каналами (color filter array – CFA). Большинство цифровых камер используют матрицу цветных фильтров (например, шаблон Байера), где каждый

пиксель регистрирует только один цветовой канал (обычно зелёный, красный или синий), а недостающие значения восстанавливаются с помощью интерполяции (демозаики) [8]. Процесс интерполяции вносит корреляции между соседними пикселями и между цветовыми каналами. При вставке фрагмента из другого изображения (или при ретушировании) локальная структура CFA-интерполяции нарушается, так как вставленная область имеет свою историю обработки. Анализ локальной корреляции каналов (например, с помощью моделирования CFA-интерполяции и вычисления ошибки предсказания) позволяет выявить границы подделки. Данный метод хорошо локализует фрагменты, но теряет эффективность после сжатия JPEG или масштабирования, которые разрушают тонкие интерполяционные зависимости [9].

В последние годы методы анализа целостности всё чаще комбинируют с машинным обучением. Например, вместо явного моделирования шума датчика или CFA-интерполяции исследователи обучают свёрточные нейронные сети (CNN) на разности между исходным изображением и его фильтрованной версией (high-pass filtering) [10]. Сеть учится выделять неявные следы камеры или постобработки, которые являются признаками нарушения целостности. Такие гибридные подходы демонстрируют более высокую робастность к сжатию и изменению размера по сравнению с классическими аналитическими методами, однако требуют больших размеченных наборов данных и вычислительных ресурсов.

Таким образом, методы на основе анализа целостности изображений предлагают прозрачную интерпретацию обнаружения подделок через физически обоснованные аномалии (шум, интерполяция, освещение, сжатие). Их главными преимуществами являются объяснимость и устойчивость к некоторым видам постобработки, а недостатками – зависимость от параметров исходной камеры (для PRNU и CFA) и снижение точности при сильном JPEG-сжатии. В рамках настоящей работы разрабатываемый метод заимствует идею анализа статистических аномалий на уровне признаков, извлекаемых свёрточной сетью, что частично наследует достоинства подходов целостности без их жёстких ограничений.

1.2.2. Методы поиска ключевых точек

Методы обнаружения фальсификации на основе поиска ключевых точек (keypoint-based methods) относятся к числу наиболее распространённых подходов для выявления атак типа «копирование-вставка» (copy-move). Идея заключается в том, что при копировании одного фрагмента изображения и вставке его в другое место того же самого изображения в подделке появляются две (или более) области с идентичным или очень похожим содержанием. Ключевые точки представляют собой локальные особенности, инвариантные к масштабу, повороту и частично к изменению освещения, что позволяет обнаруживать дублированные фрагменты даже после их геометрического преобразования [1].

Наиболее популярным дескриптором для таких задач является SIFT (Scale-Invariant Feature Transform), предложенный Лоу. SIFT-алгоритм выделяет характерные точки в масштабном пространстве, описывая каждую точку 128-мерным вектором, устойчивым к аффинным искажениям и изменению яркости [2]. При обнаружении copy-move подделки алгоритм сначала вычисляет SIFT-дескрипторы для всего изображения, после чего выполняет их попарное сравнение. Если два набора ключевых точек имеют высокую степень совпадения дескрипторов и при этом расстояния между соответствующими парами точек превышают некоторый порог (иначе дубликатом ошибочно считается сам фрагмент), то такие группы точек маркируются как подозрительные. Затем с помощью кластеризации (например, иерархической или методом DBSCAN) группируются пространственно близкие ключевые точки, и для полученных областей строятся ограничивающие прямоугольники или точные контуры [3].

Альтернативным дескриптором является SURF (Speeded-Up Robust Features), который работает быстрее SIFT за счёт использования интегральных изображений и приближённых производных Хессiana, но показывает несколько меньшую точность при сильных искажениях [4]. Для высокоразрешенных изображений и задачи обнаружения множественных дублированных областей иногда применяют дескрипторы KAZE и AKAZE, которые строятся на основе нелинейной диффузии и лучше сохраняют границы объектов [5]. В последние годы исследователи также адаптируют методы машинного обучения: например, обучают отображение ключевых точек в компактное пространство признаков с помощью сверточных нейронных сетей (CNN), что позволяет быстрее находить соответствия на больших изображениях [6].

Основным преимуществом методов поиска ключевых точек является их инвариантность к повороту, масштабированию и небольшому изменению перспективы, что крайне важно для обнаружения сору-move подделок, где вставленный фрагмент часто подвергается таким преобразованиям. Кроме того, методы дают хорошую интерпретируемость: пара найденных кластеров ключевых точек наглядно показывает, откуда и куда был скопирован объект [7]. Они также устойчивы к сжатию JPEG при умеренных коэффициентах качества (выше 70–80).

Тем не менее, методы поиска ключевых точек имеют и серьёзные ограничения. Во-первых, они практически не работают при гладких, однородных областях (небо, стена, гладкая поверхность), где недостаточно текстуры для выделения ключевых точек. В таких случаях дублированный фрагмент либо не обнаруживается вовсе, либо даёт ложные срабатывания [8]. Во-вторых, методы сильно зависят от плотности ключевых точек: при сильном сжатии JPEG (коэффициент качества ниже 60) большинство слабых ключевых точек пропадает, а сохранившиеся могут давать случайные совпадения. В-третьих, SIFT и SURF не предназначены для обнаружения splicing (вставка из другого изображения) или ретуширования, так как в этих типах подделок дублирование областей внутри одного изображения отсутствует [9]. В-четвёртых, вычислительная сложность $O(N^2)$ при попарном сравнении дескрипторов (где N – число ключевых точек) становится неприемлемой для изображений с высоким разрешением (миллионы пикселей). Для ускорения используют приближённые методы поиска ближайших соседей (FLANN, k-d деревья) или хеширование, но это всё равно не решает проблему полностью [10].

Существуют модификации метода, направленные на преодоление указанных недостатков. Например, подход, основанный на плотных SIFT-дескрипторах (dense SIFT), вычисляет признаки не только в ключевых точках, но и в каждой точке регулярной сетки, что позволяет работать с гладкими областями, однако значительно увеличивает объём вычислений [11]. Другой вариант – использование бинарных дескрипторов (ORB, BRISK) вместо SIFT, что уменьшает время сопоставления и требования к памяти, но ценой снижения инвариантности к масштабу и повороту. Для борьбы с ложными срабатываниями применяют геометрическую верификацию: после начального сопоставления дескрипторов оценивается аффинное преобразование между группами ключевых

точек, и пары, не укладывающиеся в единую модель преобразования, отбрасываются [12].

В контексте настоящей работы методы поиска ключевых точек рассматриваются как один из классических эталонов для сравнения. Разрабатываемый метод на основе сверточной нейронной сети с механизмом внимания не ориентирован исключительно на сору-move подделки, а призван обнаруживать более широкий спектр фальсификаций, включая splicing и ретушь, где ключевые точки неэффективны. Тем не менее, для оценки качества локализации предлагаемый метод будет сравниваться с SIFT-базированным детектором на наборе данных с сору-move подделками.

1.2.3. Методы на основе сверточной нейронной сети

Методы обнаружения фальсифицированных фрагментов на основе свёрточных нейронных сетей (CNN) в последние годы заняли доминирующее положение в области компьютерной криминалистики изображений. В отличие от классических подходов (анализ целостности или поиск ключевых точек), которые требуют ручного проектирования признаков, CNN автоматически извлекают иерархические представления из данных, обучаясь различать подлинные и поддельные области на больших размеченных наборах [1]. Способность сетей выявлять сложные статистические аномалии, невидимые для традиционных детекторов, обусловила их широкое применение для выявления вставки объектов, копирования-вставки, deepfake и ретуширования [2].

Первые работы по применению CNN для обнаружения подделок использовали простую архитектуру с несколькими свёрточными и полносвязными слоями, работавшую на входных изображениях фиксированного малого размера (например, 64×64 или 128×128). Такие сети классифицировали небольшие патчи как подлинные или поддельные, после чего для локализации фальсификации применялся скользящий оконный метод [3]. Хотя этот подход демонстрировал приемлемую точность на сбалансированных датасетах, он был вычислительно затратным и давал высокую долю ложноположительных срабатываний на границах объектов. Кроме того, сети, обученные на патчах, часто запоминали артефакты конкретного типа подделки (например, несогласованность шума при splicing) и плохо обобщались на другие типы фальсификаций [4].

Прорывом стало появление полностью свёрточных сетей (FCN – Fully

Convolutional Networks), которые на входе принимают изображение произвольного размера и на выходе выдают карту локализации той же пространственной размерности. Архитектура типа U-Net (симметричный энкодер-декодер с пропускными соединениями) стала стандартом для пиксельной сегментации подделанных областей [5]. Энкодер последовательно уменьшает пространственное разрешение, извлекая всё более абстрактные признаки, а декодер восстанавливает детализацию и формирует маску подделки. Пропускные соединения позволяют сохранить мелкие гранулярные признаки (например, границы вставленных объектов), которые иначе теряются при многократном субдискретизации [6]. Исследования показывают, что U-Net с 4-5 уровнями энкодера хорошо справляется с локализацией фальсифицированных фрагментов на изображениях среднего разрешения (512×512) и достигает значений IoU (Intersection over Union) до 0,75-0,80 на тестовых наборах типа CASIA [7].

Важным направлением является использование не RGB-изображений в качестве входа, а так называемых остаточных (noise residual) карт, полученных вычитанием из исходного изображения его сглаженной версии. Такой подход подавляет семантическое содержание (форму, текстуру объекта) и усиливает следы камеры и постобработки [8]. Сеть, обученная на остатках, оказывается более устойчивой к сжатию JPEG и изменениям контента, поскольку вынуждена фокусироваться на статистических аномалиях, а не на форме объектов. Например, метод Noiseprint использует CNN для извлечения камеро-специфичного «отпечатка шума», который затем подаётся в детектор аномалий для выявления вставленных областей [9].

Для борьбы с разнообразием типов подделок (copy-move, splicing, inpainting) и усложняющих обработок (сжатие, изменение размера) исследователи разрабатывают многозадачные и многомасштабные архитектуры. Один из подходов – использование параллельных ветвей сети, работающих на разных масштабах (image pyramid), с последующим объединением карт признаков [10]. Другой – применение механизмов внимания (attention modules), которые позволяют сети динамически взвешивать важность различных пространственных областей и каналов признаков. Например, сверточный блок внимания (CBAM – Convolutional Block Attention Module) последовательно применяет пространственное и канальное внимание, улучшая выделение границ подделки [11]. В рамках настоящей работы также исследуется влияние слоя внимания на каче-

ство обнаружения (часть 4.2).

Одной из ключевых проблем CNN-методов является их чувствительность к различиям между обучающими и тестовыми датасетами (domain shift). Сеть, обученная на изображениях с одними камерами и степенями сжатия, может резко терять точность при тестировании на других [12]. Для повышения обобщающей способности применяют методы аугментации (случайное JPEG-сжатие, добавление шума, изменения яркости и контраста), а также adversarial training, где сеть обучается одновременно на подлинных и сгенерированных подделках, устойчивых к детектированию. В последнее время активно развиваются методы адаптации признаков (feature adaptation), которые выравнивают распределения признаков из разных доменов с помощью градиентного реверса слоя (GRL) или вариационных автоэнкодеров [13].

Несмотря на высокие показатели качества, CNN-методы имеют и недостатки. Во-первых, они требуют больших размеченных наборов данных с пиксельной маской подделки, создание которых трудоёмко (требуется ручная разметка или генерация синтетических подделок). Во-вторых, многие модели «чёрный ящик»: сложно интерпретировать, на каком именно основании сеть отнесла область к подделанной. В-третьих, вычислительные затраты на обучение глубоких сетей (особенно с вниманием и адаптацией) высоки, и для работы в реальном времени часто требуется GPU-ускорение [14]. В настоящей работе предлагается компромиссная архитектура – сверточная сеть с умеренным числом параметров (около 5-7 миллионов), дополненная слоем пространственного внимания и слоем адаптации признаков, что позволяет сохранить высокую точность локализации при приемлемой скорости инференса.

1.3. Сравнительный анализ методов фальсифицированного фрагмента на изображении

1.3.1. Обоснование критериев сравнения методов

Для объективного сопоставления различных методов обнаружения фальсифицированного фрагмента на изображении необходимо определить систему критериев, отражающих как точность детекции, так и пригодность метода для практического применения. В научной литературе по судебной аналитике изображений отсутствует единый стандарт набора критериев, однако большинство

исследователей сходятся на том, что сравнение должно проводиться по нескольким независимым измерениям, охватывающим качественные, количественные и эксплуатационные характеристики [1, 2]. В настоящей работе предлагается использовать пять основных критериев: точность локализации фальсификации, робастность к постобработке, вычислительную эффективность, обобщающую способность на неизвестных типах подделок и интерпретируемость результатов.

Первым и наиболее важным критерием является точность локализации подделанного фрагмента. В отличие от бинарной классификации (подделка/подлинник), задача локализации требует указать границы изменённой области на пиксельном уровне. Для количественной оценки используются метрики IoU (Intersection over Union), F1-мера (гармоническое среднее между точностью и полнотой на уровне пикселей), а также коэффициент корреляции Мэтьюса (MCC) [3]. Высокое значение IoU (более 0,7) свидетельствует о том, что метод способен точно выделить форму вставленного объекта, что критически важно для судебной экспертизы. При обосновании этого критерия следует учитывать, что некоторые классические методы (например, анализ двойного сжатия JPEG) дают лишь бинарный ответ без локализации, поэтому их преимущество в скорости не компенсирует отсутствие пространственной информации [4].

Второй критерий – устойчивость к постобработке изображения. В реальных условиях фальсифицированное изображение почти всегда подвергается сжатию с потерями (JPEG), изменению размера, яркостно-контрастной коррекции или добавлению шума. Злоумышленник может намеренно применять такие операции для маскировки следов подделки [5]. Сравнение методов должно проводиться при разных коэффициентах качества JPEG (например, 95, 85, 75, 60) и разных коэффициентах масштабирования (0,8, 1,2). Метод считается высокоробастным, если его точность локализации снижается не более чем на 10–15

Третий критерий – обобщающая способность на неизвестных типах фальсификации и датасетах. Метод не должен «переобучаться» под конкретный датасет, например, запоминать артефакты сжатия или шум конкретных камер, использованных при создании обучающей выборки [9]. Для оценки обобщения применяется кросс-валидация: обучение на одном наборе данных (например, CASIA v2) и тестирование на другом (например, Columbia или COVERAGE). Также важна способность обнаруживать подделки, выполненные генеративны-

ми методами (GAN, диффузионные модели), даже если в обучающей выборке таких примеров не было. Исследования показывают, что модели, использующие остаточные карты (noise residuals) и адаптацию признаков, обобщаются лучше, чем модели, работающие непосредственно с RGB-пикселями [10].

1.3.2. Таблица сравнения методов

На основе обоснованных в п. 1.3.1 критериев (точность локализации, робастность к постобработке, вычислительная эффективность, обобщающая способность, интерпретируемость) проведём сравнительный анализ трёх основных классов методов обнаружения фальсифицированного фрагмента: аналитических методов целостности, дескрипторных методов на основе ключевых точек и методов на основе свёрточных нейронных сетей (включая их расширения с вниманием и адаптацией признаков). Для каждого критерия используется качественная шкала: «высокая», «средняя», «низкая», а также уточняющие комментарии. Результаты сведены в таблицу 1.1.

Таблица 1.1 – Сравнительная таблица методов

<i>Метод</i>	<i>Точность</i>	<i>Устойчивость к постобработке</i>	<i>Обобщающая способность</i>
Метод на основе анализа целостности изображений	Низкая/Средняя	Низкая	Низкая
Метод на основе поиска ключевых точек	Средняя	Средняя	Низкая
Однопоточная сверточная нейронная сеть	Средняя/Высокая	Средняя	Средняя
Многopotочная сверточная нейронная сеть	Высокая	Средняя/Высокая	Средняя/Высокая

На основе данных таблицы 1.1 можно сделать следующие выводы. Аналитические методы целостности обладают преимуществом в интерпретируемо-

сти и независимости от обучающих данных, однако их точность и робастность к постобработке остаются низкими, особенно при сжатии JPEG и изменении размера. Они рекомендуются в задачах, где важна объяснимость, а условия съёмки контролируются (например, судебная экспертиза изображений с известной камерой) [1, 4].

Дескрипторные методы (SIFT, SURF) показывают высокую точность локализации для сору-моуе подделок и остаются «золотым стандартом» для этого конкретного типа фальсификации. Их главные недостатки – непригодность для выявления splicing и inpainting, а также квадратичная вычислительная сложность, ограничивающая применение на высокоразрешенных изображениях [2, 5]. Тем не менее, благодаря инвариантности к повороту и масштабу, они сохраняют свою актуальность как эталон для сравнения.

Нейросетевые методы на основе CNN демонстрируют наилучшие показатели по точности локализации и робастности к постобработке, а также способны обнаруживать широкий спектр подделок, включая глубокие подделки (deepfake) [3, 6]. Их недостатками являются низкая интерпретируемость, высокая зависимость от размера и качества обучающей выборки, а также риск переобучения под конкретные домены. Для преодоления этих ограничений в последние годы разрабатываются гибридные решения: CNN с остаточными картами (повышение обобщения), с механизмами внимания (улучшение локализации и частичная интерпретируемость) и с адаптацией признаков (устойчивость к смене датасетов) [10, 11].

В контексте настоящей работы разрабатываемый метод относится к классу нейросетевых, но с добавлением слоя пространственного внимания и слоя адаптации признаков, что, согласно литературным данным, позволяет приблизить его к высокой интерпретируемости (за счёт визуализации карт внимания) и повысить обобщающую способность до уровня, сопоставимого с дескрипторными методами [12, 13]. Сравнение с аналогами по метрикам (IoU, F1, время инференса) будет приведено в части 4 (исследовательской) после экспериментального обучения модели.

1.4. Формализованная постановка задачи

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Farid H.* Digital Image Forensics // *Scientific American*. — 2008. — Июнь. — Т. 298. — С. 66—71. — DOI: 10.1038/scientificamerican0608-66.
2. *Verdoliva L.* Media Forensics and DeepFakes: An Overview // *IEEE Journal of Selected Topics in Signal Processing*. — 2020. — Т. 14, № 5. — С. 910—932. — DOI: 10.1109/JSTSP.2020.3002101.
3. *Birajdar G., Mankar V.* Digital image forgery detection using passive techniques: A survey // *Digital Investigation*. — 2013. — Окт. — Т. 10. — С. 226—245. — DOI: 10.1016/j.diin.2013.04.007.
4. *Lukás J., Fridrich J., Goljan M.* Detecting digital image forgeries using sensor pattern noise - art. no. 60720Y // *Proceedings of SPIE - The International Society for Optical Engineering*. — 2006. — Февр. — Т. 6072. — С. 362—372. — DOI: 10.1117/12.640109.
5. *Qureshi M. A., Deriche M.* A bibliography of pixel-based blind image forgery detection techniques // *Signal Processing: Image Communication*. — 2015. — Т. 39. — С. 46—74. — ISSN 0923-5965. — DOI: <https://doi.org/10.1016/j.image.2015.08.008>. — Режим доступа, URL: <https://www.sciencedirect.com/science/article/pii/S0923596515001393>.
6. *Piva A.* An Overview on Image Forensics // *International Scholarly Research Notices*. — 2013. — Т. 2013, № 1. — С. 496701. — DOI: <https://doi.org/10.1155/2013/496701>. — Режим доступа, URL: <https://onlinelibrary.wiley.com/doi/abs/10.1155/2013/496701>.
7. *Cozzolino D., Verdoliva L.* Noiseprint: a CNN-based camera model fingerprint // *CoRR*. — 2018.
8. Detection of GAN-Generated Fake Images over Social Networks / F. Marra [и др.] // — 04.2018. — С. 384—389. — DOI: 10.1109/MIPR.2018.00084.
9. Deep Learning for Multimedia Forensics / I. Amerini [и др.] // *Foundations and Trends in Computer Graphics and Vision*. — 2021. — Авг. — Т. 12. — С. 309—457. — DOI: 10.1561/06000000096.

ПРИЛОЖЕНИЕ А

Презентация