

РЕФЕРАТ

Расчетно-пояснительная записка к выпускной квалификационной работе «Метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети» содержит ?? страниц, 4 части, 16 рисунков, 4 таблиц, список используемых источников из ?? наименований и 1 приложений.

Ключевые слова: компьютерное зрение, глубокое обучение, сверточная нейронная сеть.

Объект разработки – метод обнаружения фальсифицированного фрагмента на изображении.

Цель работы: разработка и программная реализация метода автоматизированного определения области фальсифицированного фрагмента изображения с помощью двухпоточной свёрточной нейронной сети.

В первой части работы приведены обзор и сравнение существующих методов обнаружения фальсифицированного фрагмента на изображении.

Во второй части описан метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети, приведены IDEF0-диаграммы метода и схемы его алгоритмов.

В третьей части обоснован выбор средств разработки, приведена структура ПО, реализующий предложенный метод и описано взаимодействие пользователя с программным обеспечением..

В четвертой части выбраны метрики для оценки качества работы метода и приведены результаты исследования их зависимости от конфигурации нейронной сети и объемов передаваемых данных.

Разработанный метод может найти применение в области информационной безопасности и верификации медиаконтента в средствах массовой информации и социальных сетях. Это позволит своевременно выявлять и блокировать распространение дезинформации.

СОДЕРЖАНИЕ

РЕФЕРАТ	5
ВВЕДЕНИЕ	8
1 Аналитический раздел	9
1.1. Фальсификация изображений и задача её обнаружения	9
1.1.1. Понятие фальсификации изображений	9
1.1.2. Основные трудности и требования к методам обнаружения	10
1.2. Методы обнаружения фальсифицированного фрагмента на изображении	13
1.2.1. Методы на основе анализа целостности изображений	13
1.2.2. Методы поиска ключевых точек	15
1.2.3. Методы на основе сверточной нейронной сети	17
1.3. Сравнительный анализ методов фальсифицированного фрагмента на изображении	20
1.3.1. Обоснование критериев сравнения методов	20
1.3.2. Таблица сравнения методов	22
1.4. Формализованная постановка задачи	24
2 Конструкторский раздел	25
2.1. Структура программного обеспечения	25
2.2. Описание этапы работы алгоритма	25
2.2.1. Очистка и предобработка набора данных	25
2.2.2. Формирование матрицы признаков	26
2.2.3. Обучение классификатора	26
2.2.4. Классификации текстов	30
2.3. Метрики оценки качества классификации текстов	30
2.4. Функциональная схема обучения модели	32
2.5. Функциональная схема метода классификации	33
2.6. Описание используемого набора данных	34
3 Технологический раздел	36
3.1. Выбор средств реализации программного обеспечения	36

3.1.1. Выбор языка программирования	36
3.1.2. Выбор среды программирования	36
3.2. Формат входных и выходных данных	37
3.3. Руководство пользователя	37
3.4. Интерфейс пользователя	38
4 Исследовательский раздел	43
4.1. Технические характеристики	43
4.2. Влияние размера обучающей выборки	43
4.3. Влияние наличия стоп-слов в тексте	46
4.4. Влияние ядра метода опорных векторов	48
ЗАКЛЮЧЕНИЕ	51
ПРИЛОЖЕНИЕ А	52
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	52

ВВЕДЕНИЕ

В современном информационном обществе огромное количество новостей и статей публикуется каждый день. Чтобы эффективно обрабатывать и анализировать этот объем информации, важно иметь систему классификации новостей. Классификация позволяет автоматически определять тематику новости, ее важность, тональность и другие характеристики. Задача классификации новостей является актуальной и интересной задачей в области обработки естественного языка и машинного обучения. Она имеет широкий спектр применений, начиная от организации и ранжирования новостных потоков до автоматического анализа общественного мнения и выявления трендов.

Решение задачи классификации новостей может иметь большое практическое применение, включая создание интеллектуальных новостных агрегаторов, систем мониторинга общественного мнения, фильтрацию и организацию информации для пользователей. Это способствует улучшению доступа к информации, оптимизации процессов принятия решений и повышению качества новостных сервисов.

Однако, классификация новостей может быть сложной задачей из-за разнообразия тематик, стилей и тональностей новостных статей. Нередко встречаются случаи смешения нескольких тем в одной статье или субъективной интерпретации информации. Поэтому выбор правильного алгоритма и подхода, а также качество и разнообразие обучающих данных играют важную роль в достижении высокой точности классификации.

Цель работы — разработать метод классификации новостных текстов по тематикам с использованием опорных векторов. Для достижения поставленной цели необходимо выполнить следующие задачи:

- провести анализ предметной области, проанализировать предметную область и основные методы классификации текстов;
- разработать метод классификации новостных текстов по тематикам с помощью опорных векторов;
- разработать программное обеспечение, реализующее данный метод;
- оценить результаты работы метода в зависимости от различных параметров программного обеспечения.

1 Аналитический раздел

1.1. Фальсификация изображений и задача её обнаружения

1.1.1. Понятие фальсификации изображений

Под фальсификацией (подделкой) цифровых изображений понимается процесс внесения преднамеренных изменений в исходное изображение с целью искажения визуального содержания или смысла, который оно передаёт [1]. В отличие от обычной обработки (коррекция яркости, цветокоррекция, шумоподавление), фальсификация направлена на создание ложного представления о реальности, что может использоваться как в личных, так и в профессиональных или политических целях [2].

С развитием доступных графических редакторов (Adobe Photoshop, GIMP и др.) и методов глубокого обучения (глубокие подделки — deepfakes) возможности по созданию реалистичных подделок значительно расширились. В связи с этим задача обнаружения фальсификаций становится особенно актуальной в областях судебной экспертизы, журналистики, криминалистики и социальных медиа [3].

В современной литературе по компьютерному зрению принято выделять несколько основных типов фальсификации изображений [4—6]:

- Копирование-вставка (copy-move) — фрагмент изображения копируется и вставляется в другую область того же изображения, часто для сокрытия объектов или их дублирования.
- Вставка объектов из другого изображения (splicing) — часть одного изображения переносится в другое, создавая сцену, которой не существовало в действительности.
- Ретуширование (inpainting) — удаление или замена элементов с помощью заполнения области (например, удаление теней, людей, артефактов).
- Генерация полностью синтетических изображений — создание изображений с нуля с использованием генеративно-состязательных сетей (GAN) или диффузионных моделей.

— Deepfake — замена лица или мимики человека на видео и изображениях с использованием нейросетевых методов.

Цифровая фальсификация оставляет определённые статистические и семантические следы. Например, при копировании-вставке возникает повторяющаяся структура блоков, при вставке — нарушение согласованности шума датчика (PRNU) или освещения [7], а при ретушировании — аномалии в частотной области (артефакты сглаживания, некорректное сохранение JPEG) [8].

Важно отметить, что понятие фальсификации не включает в себя такие изменения, как сжатие с потерями, масштабирование или поворот, если они не направлены на введение в заблуждение зрителя. Однако в реальных условиях поддельное изображение часто подвергается дополнительным операциям (JPEG-сжатие, изменение размера, фильтрация), что усложняет его детектирование [9].

Таким образом, для обнаружения фальсифицированного фрагмента необходимо учитывать множество потенциальных аномалий на различных уровнях представления изображения: от пиксельного до семантического [10].

1.1.2. Основные трудности и требования к методам обнаружения

Задача обнаружения фальсифицированного фрагмента на изображении относится к классу задач пассивной судебной экспертизы изображений [1]. В отличие от активных методов (цифровая подпись, водяные знаки), пассивные методы не требуют предварительного внедрения вспомогательной информации, однако сталкиваются с рядом принципиальных трудностей, обусловленных как свойствами самих изображений, так и действиями злоумышленника [2].

К числу основных трудностей относятся:

1. Отсутствие эталонного («чистого») изображения. В большинстве практических сценариев (например, при проверке фотографий в СМИ или на интернет-платформах) исходное неизменённое изображение недоступно [3]. Поэтому метод должен выявлять аномалии исключительно на основе статистических и семантических характеристик самого анализируемого файла.

2. Разнообразие типов фальсификаций. Как отмечалось в п. 1.1.1, подделки могут быть выполнены методами copy-move, splicing, inpainting, deepfake и др. Каждый тип оставляет различные следы: повторяющиеся блоки, несоответствие шума сенсора, артефакты интерполяции или генеративные контуры [4]. Универсальный метод должен быть устойчивым к нескольким типам подделок.
3. Соккрытие следов подделки послеоперационной обработкой. Злоумышленник может применять к поддельному изображению сжатие JPEG, масштабирование, добавление шума, медианную фильтрацию или размытие [5]. Эти манипуляции намеренно затрудняют обнаружение артефактов, разрушая статистические аномалии, внесённые в момент фальсификации.
4. Разнородность исходных изображений. Метод не должен полагаться на фиксированные характеристики (размер, разрешение, цветовое пространство, модель камеры), так как изображения в реальных условиях поступают из самых разных источников [6]. Это требует инвариантности к разрешению, коэффициенту сжатия и уровню шума.
5. Ограничения по вычислительным ресурсам и времени. Применение метода в потоковых системах (социальные сети, новостные агрегаторы) требует быстрой обработки (миллисекунды на изображение) и работы с большими объёмами данных [7]. Слишком ресурсоёмкие модели неприменимы в реальном времени.
6. Отсутствие крупных универсальных размеченных наборов данных. Обучение методов на основе глубокого обучения требует большого количества подлинных и фальсифицированных изображений с пиксельной разметкой подделанных областей. Существующие датасеты (CASIA, COVERAGE, Columbia, NIST16) различаются по типам подделок, размерам и условиям создания, что затрудняет сравнение и обобщение [8].

В связи с перечисленными трудностями к современным методам обнаружения фальсифицированного фрагмента предъявляются следующие требования [9, 10]:

- Высокая точность (качество обнаружения): метод должен обеспечивать высокие значения метрик IoU (Intersection over Union), F1-меры и точности классификации пикселей на тестовых наборах, сбалансированных по типам подделок.
- Робастность (устойчивость): метод должен сохранять работоспособность после сжатия JPEG (коэффициент качества 70 и ниже), изменения размера (resampling), добавления шума и других типов постобработки.
- Обобщающая способность (generalization): обученная модель должна корректно работать на изображениях, взятых из датасетов, не участвовавших в обучении, и на неизвестных типах подделок.
- Вычислительная эффективность: время детекции одного изображения должно быть сопоставимо с временем его загрузки или публикации (целевые значения – не более 0,5 секунды на изображение разрешением 512×512 на современном GPU).
- Локализация подделанного фрагмента: метод должен не только выносить бинарное решение (подделка/подлинник), но и выдавать карту локализации с указанием границ изменённой области (пиксельная маска).
- Инвариантность к изображению: метод не должен зависеть от конкретной модели камеры, формата (JPEG, PNG, BMP) и цветовой схемы (RGB, YCbCr).

Таким образом, разработка практического метода обнаружения фальсифицированного фрагмента представляет собой сложную многокритериальную задачу, требующую компромисса между точностью, устойчивостью и скоростью работы. В настоящей работе предлагается метод на основе свёрточной нейронной сети с механизмом внимания и адаптации признаков, ориентированный на соблюдение перечисленных требований.

1.2. Методы обнаружения фальсифицированного фрагмента на изображении

1.2.1. Методы на основе анализа целостности изображений

Методы обнаружения фальсифицированного фрагмента на основе анализа целостности изображений (integrity-based methods) опираются на предположение, что любая модификация исходного изображения нарушает определённые статистические закономерности, присущие естественным («честным») изображениям. В отличие от методов поиска ключевых точек, которые фокусируются на локальных геометрических и текстурных особенностях, подходы на основе целостности анализируют непротиворечивость таких характеристик, как шум датчика (PRNU – photo-response non-uniformity), корреляция между цветовыми каналами, артефакты интерполяции при демозаике Байера, а также двукратное сжатие JPEG [1].

Одним из наиболее известных методов целостности является анализ шума датчика (sensor pattern noise). Каждая цифровая камера оставляет уникальный «отпечаток» – PRNU, который возникает из-за неоднородной чувствительности пикселей [2]. При вставке фрагмента из другого изображения (splicing) в области вставки нарушается согласованность PRNU: в подделанной области присутствует шум другой камеры. Метод вычисляет PRNU для анализируемого изображения (обычно с помощью вейвлет-фильтрации) и оценивает его корреляцию с эталонным шумом предполагаемой камеры. Если фрагмент изображения имеет статистически значимое расхождение в структуре шума, это свидетельствует о подделке [3]. Основное ограничение данного подхода – необходимость знать эталонный шум камеры, что в реальных условиях не всегда возможно.

Другое направление анализа целостности связано с детектированием двойного сжатия JPEG (double JPEG detection). Большинство цифровых изображений сохраняются в формате JPEG с потерями. Если злоумышленник редактирует изображение и сохраняет его повторно, возникает так называемое двойное сжатие с возможно разными таблицами квантования [4]. Статистический анализ гистограммы коэффициентов дискретного косинусного преобразования (DCT) позволяет выявить характерные периодические паттерны, возникающие при повторном квантовании. В частности, наличие двух пиков в распределении

DCT-коэффициентов для отдельных частотных полос является сильным индикатором модификации. Этот метод особенно эффективен для обнаружения операций копирования-вставки (copy-move), однако он не локализует точную область подделки, а лишь даёт бинарный ответ о вмешательстве [5].

К методам целостности также относится анализ согласованности освещения (illumination consistency). При вставке объекта из другого изображения часто возникает несоответствие направлений, интенсивности или цветовой температуры источников света на вставленном фрагменте и на окружающей области [6]. Ранние методы оценивали направление света по бликам на сферических объектах, современные – используют глубокие нейросети для моделирования карты освещения всего изображения. Например, сеть может предсказывать нормали поверхности и параметры освещения, после чего сравниваются статистические распределения освещённости в разных блоках. Несмотря на концептуальную привлекательность, этот подход чувствителен к форме объектов, текстуре и наличию теней, что ограничивает его практическое применение [7].

Отдельную группу составляют методы анализа корреляции между цветовыми каналами (color filter array – CFA). Большинство цифровых камер используют матрицу цветных фильтров (например, шаблон Байера), где каждый пиксель регистрирует только один цветовой канал (обычно зелёный, красный или синий), а недостающие значения восстанавливаются с помощью интерполяции (демозаики) [8]. Процесс интерполяции вносит корреляции между соседними пикселями и между цветовыми каналами. При вставке фрагмента из другого изображения (или при ретушировании) локальная структура CFA-интерполяции нарушается, так как вставленная область имеет свою историю обработки. Анализ локальной корреляции каналов (например, с помощью моделирования CFA-интерполяции и вычисления ошибки предсказания) позволяет выявить границы подделки. Данный метод хорошо локализует фрагменты, но теряет эффективность после сжатия JPEG или масштабирования, которые разрушают тонкие интерполяционные зависимости [9].

В последние годы методы анализа целостности всё чаще комбинируют с машинным обучением. Например, вместо явного моделирования шума датчика или CFA-интерполяции исследователи обучают свёрточные нейронные сети (CNN) на разности между исходным изображением и его фильтрованной версией (high-pass filtering) [10]. Сеть учится выделять неявные следы камеры или

постобработки, которые являются признаками нарушения целостности. Такие гибридные подходы демонстрируют более высокую робастность к сжатию и изменению размера по сравнению с классическими аналитическими методами, однако требуют больших размеченных наборов данных и вычислительных ресурсов.

Таким образом, методы на основе анализа целостности изображений предлагают прозрачную интерпретацию обнаружения подделок через физически обоснованные аномалии (шум, интерполяция, освещение, сжатие). Их главными преимуществами являются объяснимость и устойчивость к некоторым видам постобработки, а недостатками – зависимость от параметров исходной камеры (для PRNU и CFA) и снижение точности при сильном JPEG-сжатии. В рамках настоящей работы разрабатываемый метод заимствует идею анализа статистических аномалий на уровне признаков, извлекаемых свёрточной сетью, что частично наследует достоинства подходов целостности без их жёстких ограничений.

1.2.2. Методы поиска ключевых точек

Методы обнаружения фальсификации на основе поиска ключевых точек (keypoint-based methods) относятся к числу наиболее распространённых подходов для выявления атак типа «копирование-вставка» (copy-move). Идея заключается в том, что при копировании одного фрагмента изображения и вставке его в другое место того же самого изображения в подделке появляются две (или более) области с идентичным или очень похожим содержанием. Ключевые точки представляют собой локальные особенности, инвариантные к масштабу, повороту и частично к изменению освещения, что позволяет обнаруживать дублированные фрагменты даже после их геометрического преобразования [1].

Наиболее популярным дескриптором для таких задач является SIFT (Scale-Invariant Feature Transform), предложенный Лоу. SIFT-алгоритм выделяет характерные точки в масштабном пространстве, описывая каждую точку 128-мерным вектором, устойчивым к аффинным искажениям и изменению яркости [2]. При обнаружении copy-move подделки алгоритм сначала вычисляет SIFT-дескрипторы для всего изображения, после чего выполняет их попарное сравнение. Если два набора ключевых точек имеют высокую степень совпадения дескрипторов и при этом расстояния между соответствующими парами точек

превышают некоторый порог (иначе дубликатом ошибочно считается сам фрагмент), то такие группы точек маркируются как подозрительные. Затем с помощью кластеризации (например, иерархической или методом DBSCAN) группируются пространственно близкие ключевые точки, и для полученных областей строятся ограничивающие прямоугольники или точные контуры [3].

Альтернативным дескриптором является SURF (Speeded-Up Robust Features), который работает быстрее SIFT за счёт использования интегральных изображений и приближённых производных Хессiana, но показывает несколько меньшую точность при сильных искажениях [4]. Для высокоразрешенных изображений и задачи обнаружения множественных дублированных областей иногда применяют дескрипторы KAZE и AKAZE, которые строятся на основе нелинейной диффузии и лучше сохраняют границы объектов [5]. В последние годы исследователи также адаптируют методы машинного обучения: например, обучают отображение ключевых точек в компактное пространство признаков с помощью сверточных нейронных сетей (CNN), что позволяет быстрее находить соответствия на больших изображениях [6].

Основным преимуществом методов поиска ключевых точек является их инвариантность к повороту, масштабированию и небольшому изменению перспективы, что крайне важно для обнаружения сору-мове подделок, где вставленный фрагмент часто подвергается таким преобразованиям. Кроме того, методы дают хорошую интерпретируемость: пара найденных кластеров ключевых точек наглядно показывает, откуда и куда был скопирован объект [7]. Они также устойчивы к сжатию JPEG при умеренных коэффициентах качества (выше 70–80

Тем не менее, методы поиска ключевых точек имеют и серьёзные ограничения. Во-первых, они практически не работают при гладких, однородных областях (небо, стена, гладкая поверхность), где недостаточно текстуры для выделения ключевых точек. В таких случаях дублированный фрагмент либо не обнаруживается вовсе, либо даёт ложные срабатывания [8]. Во-вторых, методы сильно зависят от плотности ключевых точек: при сильном сжатии JPEG (коэффициент качества ниже 60) большинство слабых ключевых точек пропадает, а сохранившиеся могут давать случайные совпадения. В-третьих, SIFT и SURF не предназначены для обнаружения splicing (вставка из другого изображения) или ретуширования, так как в этих типах подделок дублирование обла-

стей внутри одного изображения отсутствует [9]. В-четвёртых, вычислительная сложность $O(N^2)$ при попарном сравнении дескрипторов (где N – число ключевых точек) становится неприемлемой для изображений с высоким разрешением (миллионы пикселей). Для ускорения используют приближённые методы поиска ближайших соседей (FLANN, k-d деревья) или хеширование, но это всё равно не решает проблему полностью [10].

Существуют модификации метода, направленные на преодоление указанных недостатков. Например, подход, основанный на плотных SIFT-дескрипторах (dense SIFT), вычисляет признаки не только в ключевых точках, но и в каждой точке регулярной сетки, что позволяет работать с гладкими областями, однако значительно увеличивает объём вычислений [11]. Другой вариант – использование бинарных дескрипторов (ORB, BRISK) вместо SIFT, что уменьшает время сопоставления и требования к памяти, но ценой снижения инвариантности к масштабу и повороту. Для борьбы с ложными срабатываниями применяют геометрическую верификацию: после начального сопоставления дескрипторов оценивается аффинное преобразование между группами ключевых точек, и пары, не укладывающиеся в единую модель преобразования, отбрасываются [12].

В контексте настоящей работы методы поиска ключевых точек рассматриваются как один из классических эталонов для сравнения. Разрабатываемый метод на основе сверточной нейронной сети с механизмом внимания не ориентирован исключительно на сору-move подделки, а призван обнаруживать более широкий спектр фальсификаций, включая splicing и ретушь, где ключевые точки неэффективны. Тем не менее, для оценки качества локализации предлагаемый метод будет сравниваться с SIFT-базированным детектором на наборе данных с сору-move подделками.

1.2.3. Методы на основе сверточной нейронной сети

Методы обнаружения фальсифицированных фрагментов на основе свёрточных нейронных сетей (CNN) в последние годы заняли доминирующее положение в области компьютерной криминалистики изображений. В отличие от классических подходов (анализ целостности или поиск ключевых точек), которые требуют ручного проектирования признаков, CNN автоматически извлекают иерархические представления из данных, обучаясь различать подлинные и

поддельные области на больших размеченных наборах [1]. Способность сетей выявлять сложные статистические аномалии, невидимые для традиционных детекторов, обусловила их широкое применение для выявления вставки объектов, копирования-вставки, deepfake и ретуширования [2].

Первые работы по применению CNN для обнаружения подделок использовали простую архитектуру с несколькими свёрточными и полносвязными слоями, работавшую на входных изображениях фиксированного малого размера (например, 64×64 или 128×128). Такие сети классифицировали небольшие патчи как подлинные или поддельные, после чего для локализации фальсификации применялся скользящий оконный метод [3]. Хотя этот подход демонстрировал приемлемую точность на сбалансированных датасетах, он был вычислительно затратным и давал высокую долю ложноположительных срабатываний на границах объектов. Кроме того, сети, обученные на патчах, часто запоминали артефакты конкретного типа подделки (например, несогласованность шума при splicing) и плохо обобщались на другие типы фальсификаций [4].

Прорывом стало появление полностью свёрточных сетей (FCN – Fully Convolutional Networks), которые на входе принимают изображение произвольного размера и на выходе выдают карту локализации той же пространственной размерности. Архитектура типа U-Net (симметричный энкодер-декодер с пропускными соединениями) стала стандартом для пиксельной сегментации подделанных областей [5]. Энкодер последовательно уменьшает пространственное разрешение, извлекая всё более абстрактные признаки, а декодер восстанавливает детализацию и формирует маску подделки. Пропускные соединения позволяют сохранить мелкие гранулярные признаки (например, границы вставленных объектов), которые иначе теряются при многократном субдискретизации [6]. Исследования показывают, что U-Net с 4-5 уровнями энкодера хорошо справляется с локализацией фальсифицированных фрагментов на изображениях среднего разрешения (512×512) и достигает значений IoU (Intersection over Union) до 0,75-0,80 на тестовых наборах типа CASIA [7].

Важным направлением является использование не RGB-изображений в качестве входа, а так называемых остаточных (noise residual) карт, полученных вычитанием из исходного изображения его сглаженной версии. Такой подход подавляет семантическое содержание (форму, текстуру объекта) и усиливает следы камеры и постобработки [8]. Сеть, обученная на остатках, оказывается бо-

лее устойчивой к сжатию JPEG и изменениям контента, поскольку вынуждена фокусироваться на статистических аномалиях, а не на форме объектов. Например, метод Noiseprint использует CNN для извлечения камеро-специфичного «отпечатка шума», который затем подаётся в детектор аномалий для выявления вставленных областей [9].

Для борьбы с разнообразием типов подделок (copy-move, splicing, inpainting) и усложняющих обработок (сжатие, изменение размера) исследователи разрабатывают многозадачные и многомасштабные архитектуры. Один из подходов – использование параллельных ветвей сети, работающих на разных масштабах (image pyramid), с последующим объединением карт признаков [10]. Другой – применение механизмов внимания (attention modules), которые позволяют сети динамически взвешивать важность различных пространственных областей и каналов признаков. Например, сверточный блок внимания (СВАМ – Convolutional Block Attention Module) последовательно применяет пространственное и канальное внимание, улучшая выделение границ подделки [11]. В рамках настоящей работы также исследуется влияние слоя внимания на качество обнаружения (часть 4.2).

Одной из ключевых проблем CNN-методов является их чувствительность к различиям между обучающими и тестовыми датасетами (domain shift). Сеть, обученная на изображениях с одними камерами и степенями сжатия, может резко терять точность при тестировании на других [12]. Для повышения обобщающей способности применяют методы аугментации (случайное JPEG-сжатие, добавление шума, изменения яркости и контраста), а также adversarial training, где сеть обучается одновременно на подлинных и сгенерированных подделках, устойчивых к детектированию. В последнее время активно развиваются методы адаптации признаков (feature adaptation), которые выравнивают распределения признаков из разных доменов с помощью градиентного реверса слоя (GRL) или вариационных автоэнкодеров [13].

Несмотря на высокие показатели качества, CNN-методы имеют и недостатки. Во-первых, они требуют больших размеченных наборов данных с пиксельной маской подделки, создание которых трудоёмко (требуется ручная разметка или генерация синтетических подделок). Во-вторых, многие модели «чёрный ящик»: сложно интерпретировать, на каком именно основании сеть отнесла область к подделанной. В-третьих, вычислительные затраты на обучение глубо-

ких сетей (особенно с вниманием и адаптацией) высоки, и для работы в реальном времени часто требуется GPU-ускорение [14]. В настоящей работе предлагается компромиссная архитектура – сверточная сеть с умеренным числом параметров (около 5-7 миллионов), дополненная слоем пространственного внимания и слоем адаптации признаков, что позволяет сохранить высокую точность локализации при приемлемой скорости инференса.

1.3. Сравнительный анализ методов фальсифицированного фрагмента на изображении

1.3.1. Обоснование критериев сравнения методов

Для объективного сопоставления различных методов обнаружения фальсифицированного фрагмента на изображении необходимо определить систему критериев, отражающих как точность детекции, так и пригодность метода для практического применения. В научной литературе по судебной аналитике изображений отсутствует единый стандарт набора критериев, однако большинство исследователей сходятся на том, что сравнение должно проводиться по нескольким независимым измерениям, охватывающим качественные, количественные и эксплуатационные характеристики [1, 2]. В настоящей работе предлагается использовать пять основных критериев: точность локализации фальсификации, робастность к постобработке, вычислительную эффективность, обобщающую способность на неизвестных типах подделок и интерпретируемость результатов.

Первым и наиболее важным критерием является точность локализации подделанного фрагмента. В отличие от бинарной классификации (подделка/подлинник), задача локализации требует указать границы изменённой области на пиксельном уровне. Для количественной оценки используются метрики IoU (Intersection over Union), F1-мера (гармоническое среднее между точностью и полнотой на уровне пикселей), а также коэффициент корреляции Мэтьюса (MCC) [3]. Высокое значение IoU (более 0,7) свидетельствует о том, что метод способен точно выделить форму вставленного объекта, что критически важно для судебной экспертизы. При обосновании этого критерия следует учитывать, что некоторые классические методы (например, анализ двойного сжатия JPEG) дают лишь бинарный ответ без локализации, поэтому их преимущество в ско-

рости не компенсирует отсутствие пространственной информации [4].

Второй критерий – робастность (устойчивость) к постобработке изображения. В реальных условиях фальсифицированное изображение почти всегда подвергается сжатию с потерями (JPEG), изменению размера, яркостно-контрастной коррекции или добавлению шума. Злоумышленник может намеренно применять такие операции для маскировки следов подделки [5]. Сравнение методов должно проводиться при разных коэффициентах качества JPEG (например, 95, 85, 75, 60) и разных коэффициентах масштабирования (0,8, 1,2). Метод считается высокоробастным, если его точность локализации снижается не более чем на 10–15

Третий критерий – вычислительная эффективность, которая включает время обработки одного изображения (инференс), объём оперативной памяти и возможность работы в реальном времени. Для потоковых систем (социальные сети, новостные агрегаторы) допустимое время детекции составляет не более 0,5-1 секунды на изображение разрешением 512×512 на стандартном GPU (например, NVIDIA GTX 1080) [7]. Для CPU-реализаций требования мягче – до 5 секунд. Методы поиска ключевых точек (SIFT, SURF) имеют сложность $O(N^2)$ и при высоком разрешении могут обрабатывать одно изображение за несколько секунд даже на GPU, тогда как компактные CNN (с числом параметров 1-5 миллионов) дают результат за 0,1-0,3 секунды. При этом более глубокие сети (более 20 миллионов параметров) могут быть неприменимы из-за ограничений по памяти [8].

Четвёртый критерий – обобщающая способность (generalization) на неизвестных типах подделок и датасетах. Метод не должен «переобучаться» под конкретный датасет, например, запоминать артефакты сжатия или шум конкретных камер, использованных при создании обучающей выборки [9]. Для оценки обобщения применяется кросс-валидация: обучение на одном наборе данных (например, CASIA v2) и тестирование на другом (например, Columbia или COVERAGE). Также важна способность обнаруживать подделки, выполненные генеративными методами (GAN, диффузионные модели), даже если в обучающей выборке таких примеров не было. Исследования показывают, что модели, использующие остаточные карты (noise residuals) и адаптацию признаков, обобщаются лучше, чем модели, работающие непосредственно с RGB-пикселями [10].

Пятый критерий – интерпретируемость результатов. В судебной и криминалистической практике недостаточно получить маску подделки; требуется объяснить, почему метод отнёс ту или иную область к фальсифицированной [11]. Интерпретируемость включает способность метода визуализировать признаки, на которых основано решение (например, карту активации класса (CAM), карту несоответствия шума или градиентного анализа). Методы на основе ключевых точек предоставляют прозрачную геометрическую интерпретацию (найденны пары совпадающих дескрипторов). Аналитические методы целостности также объяснимы (нарушение PRNU, аномалии в DCT-коэффициентах). Напротив, стандартные CNN часто работают как «чёрный ящик», что снижает доверие со стороны экспертов [12]. Поэтому при сравнении методов предпочтение отдаётся тем, которые встроены в гибридные схемы с визуализацией важности признаков (например, использование слоёв внимания, вычисление градиентных карт).

В рамках настоящей работы также учитываются дополнительные критерии: устойчивость к разным разрешениям входных изображений (инвариантность к масштабу), возможность работы с цветными и монохромными изображениями, а также чувствительность к параметрам настройки (чем меньше гиперпараметров требует метод, тем он практичнее) [13]. На основе перечисленных критериев в следующем подразделе (п. 1.3.2) будет построена сводная таблица сравнения трёх классов методов: аналитических (целостность), дескрипторных (ключевые точки) и нейросетевых (CNN), включая их модификации с вниманием и адаптацией признаков.

1.3.2. Таблица сравнения методов

На основе обоснованных в п. 1.3.1 критериев (точность локализации, робастность к постобработке, вычислительная эффективность, обобщающая способность, интерпретируемость) проведём сравнительный анализ трёх основных классов методов обнаружения фальсифицированного фрагмента: аналитических методов целостности, дескрипторных методов на основе ключевых точек и методов на основе свёрточных нейронных сетей (включая их расширения с вниманием и адаптацией признаков). Для каждого критерия используется качественная шкала: «высокая», «средняя», «низкая», а также уточняющие комментарии. Результаты сведены в таблицу 1.1.

Таблица 1.1 – Сравнительная таблица методов

<i>Метод</i>	<i>Точность</i>	<i>Устойчивость к постобработ- ке</i>	<i>Обобщающая способность</i>
Метод на основе анализа целостности изображений	Низкая/Средняя	Низкая	Низкая
Метод на основе поиска ключевых точек	Средняя	Средняя	Низкая
Однопоточная сверточная нейронная сеть	Средняя/Высокая	Средняя	Средняя
Многopotочная сверточная нейронная сеть	Высокая	Средняя/Высокая	Средняя/Высокая

На основе данных таблицы 1.1 можно сделать следующие выводы. Аналитические методы целостности обладают преимуществом в интерпретируемости и независимости от обучающих данных, однако их точность и робастность к постобработке остаются низкими, особенно при сжатии JPEG и изменении размера. Они рекомендуются в задачах, где важна объяснимость, а условия съёмки контролируются (например, судебная экспертиза изображений с известной камерой) [1, 4].

Дескрипторные методы (SIFT, SURF) показывают высокую точность локализации для сору-мове подделок и остаются «золотым стандартом» для этого конкретного типа фальсификации. Их главные недостатки – непригодность для выявления splicing и inpainting, а также квадратичная вычислительная сложность, ограничивающая применение на высокоразрешенных изображениях [2, 5]. Тем не менее, благодаря инвариантности к повороту и масштабу, они сохраняют свою актуальность как эталон для сравнения.

Нейросетевые методы на основе CNN демонстрируют наилучшие показатели по точности локализации и робастности к постобработке, а также способны обнаруживать широкий спектр подделок, включая глубокие подделки

(deepfake) [3, 6]. Их недостатками являются низкая интерпретируемость, высокая зависимость от размера и качества обучающей выборки, а также риск переобучения под конкретные домены. Для преодоления этих ограничений в последние годы разрабатываются гибридные решения: CNN с остаточными картами (повышение обобщения), с механизмами внимания (улучшение локализации и частичная интерпретируемость) и с адаптацией признаков (устойчивость к смене датасетов) [10, 11].

В контексте настоящей работы разрабатываемый метод относится к классу нейросетевых, но с добавлением слоя пространственного внимания и слоя адаптации признаков, что, согласно литературным данным, позволяет приблизить его к высокой интерпретируемости (за счёт визуализации карт внимания) и повысить обобщающую способность до уровня, сопоставимого с дескрипторными методами [12, 13]. Сравнение с аналогами по метрикам (IoU, F1, время инференса) будет приведено в части 4 (исследовательской) после экспериментального обучения модели.

1.4. Формализованная постановка задачи

2 Конструкторский раздел

В этом разделе описываются этапы работы алгоритма разрабатываемого метода, также рассматриваются функциональные схемы обучения модели и метода классификации. Также приводятся метрики, используемые для оценки качества работы обученной модели. Описывается используемый набор данных для обучения модели и рассматривается структура программного обеспечения.

2.1. Структура программного обеспечения

Разрабатываемый программный продукт состоит из следующих частей.

1. Модуль предобработки текстов — отвечает за очистку и предварительную обработку текстов.
2. Модуль классификации — отвечает за извлечение признаков из текстов, обучение модели и прогнозирование класса новых данных.
3. Модуль создания выборки данных — отвечает за создание файлов из скачанного набора данных.
4. Модуль пользовательского интерфейса — отвечает за предоставление пользовательского интерфейса.

Внутри модуля предобработки текстов реализованы токенизация, удаление стоп-слов и лемматизация.

2.2. Описание этапы работы алгоритма

2.2.1. Очистка и предобработка набора данных

Прежде всего, набор данных необходимо очистить и предварительно обработать, поскольку это необходимый этап, как упоминалось в предыдущем разделе. Очистка текста включает в себя преобразование текста в нижний регистр, удаление лишних пробелов и небуквенно-цифровых символов.

Предобработка текстовых данных состоит из трех этапов: токенизация, удаление стоп-слов и лемматизация.

После токенизации исходный текст преобразуется в массив, элементами которого являются отдельные слова этого текста (токены). Текст будет сохранен как массив слов в том же порядке, что и в исходном тексте.

После удаления стоп-слов массив токенов уменьшит количество элементов, но не сильно повлияет на результат обучения модели, поскольку стоп-слова при удалении не потеряют смысла исходного текста.

После процесса лемматизация массив токенов будет преобразован в массив, элементы которого являются словами в их начальной форме с соответствующим типом слова.

2.2.2. Формирование матрицы признаков

Для извлечения признаков из массива токенов используется матрица признаков с помощью метода TF-IDF.

Сначала из массива слов будет создан список уникальных слов (словарь). На основе этого словаря рассчитывается значение IDF каждого слова в словаре. Затем для каждого текста в наборе данных рассчитывается вектор значений TF-IDF. Значения IDF и TF-IDF рассчитываются по формулам, рассмотренным в предыдущем разделе. Из векторов признаков создается матрица признаков, в которой каждая строка соответствует одному вектору признака одного текста после нормализация.

Каждый вектор признака нормализуется по формуле:

$$\vec{v}_{norm} = \frac{\vec{v}}{\sqrt{\sum_{i=1}^n v_i^2}} = \left(\frac{v_1}{\sqrt{\sum_{i=1}^n v_i^2}}, \frac{v_2}{\sqrt{\sum_{i=1}^n v_i^2}}, \dots, \frac{v_n}{\sqrt{\sum_{i=1}^n v_i^2}} \right), \quad (2.1)$$

где $\vec{v} = (v_1, v_2, v_3, \dots, v_n)$ — вектор признака, $\sqrt{\sum_{i=1}^n v_i^2}$ — длина вектора $\vec{v}$, $\vec{v}_{norm}$ — нормализованный вектор признака $\vec{v}$.

2.2.3. Обучение классификатора

Для выполнения классификации был выбран метод опорных векторов, потому что этот метод является одним из применимых алгоритмов машинного обучения, который используется для различных задач классификации и особенно подходит для данных большого размера[svm21]. SVM — линейный классификатор, основан на разделении множества векторов из n-мерного пространства гиперплоскостью. Этот метод требует обучения перед классификацией.

Поскольку в размеченном наборе данных есть несколько тематик, необходимо использовать многоклассовый классификатор. Для создания многоклас-

сового классификатора используется подход ”один против всех”(англ. one and rest). Этот подход заключается в подборе одного классификатора на класс. Для каждого классификатора класс сопоставляется со всеми другими классами. Таким образом, задачи многоклассовой классификации преобразуется в бинарную кластеризацию.

Основная идея метода заключается в построении гиперплоскости, разделяющей объекты выборки. То есть нужно найти гиперплоскость, которая задается следующим уравнением:

$$(w, x) - b = 0, \quad (2.2)$$

где w — вектор, b — число.

Тогда очевидно, что документы одного класса должны удовлетворять $(w, x_i) \geq b$, а другого $(w, x_j) \leq b$. Зафиксируем гиперплоскость, тогда параллельные гиперплоскости, содержащие опорные вектора, будут выглядеть таким образом:

$$\begin{cases} (w, x) = b + \epsilon, \\ (w, x) = b - \epsilon. \end{cases} \quad (2.3)$$

Ниже, на рисунке 2.1, представлен принцип работы метода SVM.




Рисунок 2.1 – Принцип работы метода опорных векторов

Отклонение ϵ одно и тоже в силу того, что расстояние до опорных векторов будет одинаковым, иначе такая гиперплоскость точно не будет оптимальной.

После нормировки, а именно поделим вектор s и число d на ϵ , получается:

$$\begin{cases} (w', x) - b' = 1, \\ (w', x) - b' = -1. \end{cases} \quad (2.4)$$

Расстояние между двумя параллельными гиперплоскостями можно вычислить следующим образом:

$$dist = \frac{|b_1 - b_2|}{||w||}, \quad (2.5)$$

где b_1 — свободный член первой гиперплоскости, b_2 — свободный член второй гиперплоскости, $||w|| = w \cdot w$ — одинаков, вследствие параллельности гиперплоскостей.

Тогда несложно убедиться, что расстояние от параллельных гиперплоскостей до оптимальной гиперплоскости равно $\frac{1}{\|w\|}$. Теперь, чтобы найти оптимальную гиперплоскость, нужно решить следующую задачу оптимизации:

$$\begin{cases} \|w\| \rightarrow \min, \\ (w, x_i) - b \geq 1, \text{ если } y_i = 1, \\ (w, x_j) - b \leq -1, \text{ если } y_j = -1. \end{cases} \quad (2.6)$$

Или в более удобной записи:

$$\begin{cases} \|w\| \rightarrow \min, \\ y_i \cdot [(w, x_i) - b] \geq 1, y_i \in \{-1; 1\}. \end{cases} \quad (2.7)$$

Эта задача сводится к двойственной задаче поиска седловой точки функции Лагранжа. Но если в случае отсутствия линейной разделимости требуется ввести набор дополнительных переменных δ_i , характеризующих величину ошибки на объектах $x_i \in \{x_1, \dots, x_n\}$. Тогда задача оптимизации изменится следующим образом:

$$\begin{cases} \|w\| + \sum \delta_i \rightarrow \min, \\ y_i \cdot [(w, x_i) - b] \geq 1 - \delta_i, y_i \in \{-1; 1\}, \\ \delta_i \geq 0, i \in \{1, \dots, n\}. \end{cases} \quad (2.8)$$

Здесь, δ_i равно нулю в том случае, если соответствующее неравенство выполняется и без него. То есть δ_i является минимально возможным значением, при котором неравенство будет выполнено. Решая эти задачи, можно получить вектор s , который и нужен для построения гиперплоскости.

Ниже, на рисунке 2.2, представлен вывод правил настройки весов.




Рисунок 2.2 – Вывод правил настройки весов

2.2.4. Классификации текстов

На данном этапе обученная модель получает на вход новостной текст. Этот текст необходимо очистить, предварительно обработать и извлечь признаки, используя те же этапы, что и для набора обучающих данных, чтобы получить соответствующие признаки. Входной текст преобразуется в вектор признаков и с помощью обученной модели прогнозирует тематику исходного новостного текста.

2.3. Метрики оценки качества классификации текстов

Показатели критериев оценки качества классификации, будут базироваться на следующих основных метриках результатов классификации на тестовой выборке.

- TP (англ. True Positive) — истинный положительный результат. Верные данные, классифицированные как верные.

- TN (англ. True Negative) — истинный отрицательный результат. Неверные данные, классифицированные как неверные.
- FP (англ. False Positive) — ложный положительный результат. Верные данные, классифицированные как неверные.
- FN (англ. False Negative) — ложный отрицательный результат. Неверные данные, классифицированные как верные.

Для оценки качества модели, обученного на обучающей и тестовой выборках из набора данных, используются следующие две метрики: аккуратность и F1-мера.

Метрики аккуратности (англ. Accuracy) — один из наиболее простых, а поэтому и распространенной метрикой. Она показывает количество правильно поставленных меток класса (суммы истинно положительных и истинно отрицательных результатов) от общего количества данных и считается следующим образом:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}. \quad (2.9)$$

F1-мера — это показатель оценки, который измеряет качество работы модели классификации. Он сочетает в себе оценки точности и полноты модели.

Точность модели (англ. Precision) — это показатель оценки модели и производительности, который соответствует доле значений, которые фактически принадлежат положительному классу, среди всех значений, которые, по прогнозам, принадлежат этому классу. Точность также известна как положительная прогностическая ценность (англ. positive predictive value, PPV). Оценка F1 использует точность, чтобы получить долю истинно положительных записей среди общего числа записей, классифицированных как положительные с помощью модели машинного обучения. Точность модели рассчитывается следующим образом:

$$Precision = \frac{TP}{TP + FP}. \quad (2.10)$$

Полноты модели (англ. Recall) — это показатель оценки модели и производительности, который соответствует доле значений, которые, по прогнозам, относятся к положительному классу, среди всех значений, которые действительно принадлежат к положительному классу (включая ложно отрицательные). F1-мера использует полноты, чтобы получить долю истинно положительных запи-

сей среди общего числа фактически положительных записей. Полноты модели рассчитывается следующим образом:

$$Recall = \frac{TP}{TP + FN}. \quad (2.11)$$

Значение F1-меры рассчитывается как гармоническое среднее значений точности и полноты модели, по следующей формуле:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{TP}{TP + \frac{1}{2}(FP + FN)}. \quad (2.12)$$

2.4. Функциональная схема обучения модели

Для обучения модели используется метод SVM, а для метода извлечения признаков из набора текстов используется метод TF-IDF. На входе поступает набор новостных текстов с соответствующей меткой для обучения, а на выходе — обученная модель на этом наборе.

Ниже, на рисунке 2.3 представлена функциональная схема обучения модели (с помощью SVM) в виде IDEF0-диаграммы. На этой схеме отображены этапы создания обучающей и тестовой выборок, очистки и предобработки текстов, извлечения признаков и выполнения многоклассовой классификации для обучающей выборки.




Рисунок 2.3 – Функциональная схема обучения модели

2.5. Функциональная схема метода классификации

Ниже, на рисунке 2.4 представлена функциональная схема метода классификации в виде IDEF0-диаграммы. На входе поступает новостной текст для классификации, а выходе — прогнозируемое название тематика этого текста.

На этой схеме отображены этапы очистки и предобработки входного текста, извлечения признаков и выполнения распознавания тематика текста, использующего обученную модель.




Рисунок 2.4 – Функциональная схема метода классификации

2.6. Описание используемого набора данных

Для обучения модели было решено использовать набор данных News dataset from Lenta.Ru [kaggle_data]. Этот набор данных содержит более 800 тысяч новостей на русском языке, соответствующих более чем 20 тематикам, с сентября 1999 года по декабрь 2019 года. Источник новостей — сайт lenta.ru [lenta], российское новостное интернет-издание, основанное в 1999 году. В наборе данных для каждой новости сохраняются текст, заголовок, тематик, дата публикации и ссылка на источник. Этот набор данных можно скачать с сайта Kaggle [kaggle] — система организации конкурсов по исследованию данных, а также социальная сеть специалистов по обработке данных и машинному обучению.

После скачивания набора данных необходимо выполнить этап фильтрации данных, чтобы сохранить набор данных в виде файла CSV и создать наборы обучения для будущего использования.

Ниже, на рисунке 2.5, представлены примеры некоторых строк в наборе данных.

url	title	text	topic	tags	date
https://lenta.ru/news/1914/09/16/hungarinn/	1914. Русские войска вступили в пределы Венгрии	Бои у Сопочкина и Друскеник закончились отступлением германцев. Неприятель, приблизившись с севера к...	Библиотека	Первая мировая	1914/09/16
https://lenta.ru/news/1914/09/16/lermontov/	1914. Празднование столетия М.Ю. Лермонтова отложено	Министерство народного просвещения, в виду происходящих чрезвычайных событий, признало соответствен...	Библиотека	Первая мировая	1914/09/16
https://lenta.ru/news/1914/09/17/nesteroff/	1914. Das ist Nesteroff!	Штабс-капитан П. Н. Нестеров на днях, увидев в районе Желтиева, в Галиции, летящий над нашим распо...	Библиотека	Первая мировая	1914/09/17
https://lenta.ru/news/1914/09/17/bulldogn/	1914. Бульдог-голец под Льежем	Фотограф-корреспондент Daily Mirror рассказывает случай, который порадует всех друзей животных. Лейт...	Библиотека	Первая мировая	1914/09/17
https://lenta.ru/news/1914/09/18/zver/	1914. Под Люблином пойман швабский зверь	Лица, приехавшие в Варшаву из Люблина, передают, что туда доставлен	Библиотека	Первая мировая	1914/09/18

Рисунок 2.5 – Примеры некоторых строк в наборе данных

Вывод

В этом разделе были описаны этапы работы алгоритма разрабатываемого метода, также были рассмотрены функциональные схемы обучения модели и метод классификации. Также были приведены метрики, используемые для оценки качества работы обученной модели. Был описан используемый набор данных для обучения модели и была рассмотрена структура программного обеспечения.

3 Технологический раздел

В этом разделе приводится выбор языка программирования и средства программирования и рассматриваются необходимые библиотеки, которые используются для разработки программного обеспечения. Также описывается формат входных и выходных данных. Также приводятся описание пользовательского интерфейса и руководство пользователя для установки и использования программного обеспечения.

3.1. Выбор средств реализации программного обеспечения

3.1.1. Выбор языка программирования

Для реализации программного обеспечения был использован язык программирования Python[python]. Этот выбор обусловлен следующими причинами:

- это язык программирования высокого уровня, имеет простой синтаксис;
- наличие библиотек с открытым исходным кодом, позволяющих работать с естественным языком, выполнять классификации методом SVM и визуализировать данные;
- имеется навыки использования данного языка программирования, что сократить время написания программы.

3.1.2. Выбор среды программирования

Для разработки программы использовалась среда Visual Studio Code [vscode] в качестве среды разработки по следующим причинам:

- доступна бесплатная версия;
- имеет множество утилит, упрощающих написание кода;
- имеется навыки программирования при помощи данной среды, что сократить время написания программы.

Библиотека scikit-learn используется для работы с машинным обучением, потому что она предоставляет множество различных инструментов для разных

задач машинного обучения, включая кластеризацию, регрессию, кластеризацию, обучение и тестирование моделей, а также предварительную обработку данных, и так далее.

Для создания пользовательского интерфейса используется фреймворк Qt с помощью библиотеки PyQt5. Кроме того, в процессе разработки программного обеспечения библиотека pandas также используется для анализа набора данных, а библиотеки nltk и rumorphy2 — для очистки и предварительной обработки текстов.

3.2. Формат входных и выходных данных

Для модуля создания выборки данных входными данными является набор данных, скачанный с сайта kaggle.com, а выходные данные представляют собой файлы с указанным количеством строк для каждой темы.

На этапе обучения модели входными данными является файл, который создается из набора новостных текстов, в формате файла CSV. Каждая строка соответствует новости, состоящему из двух частей: текста и тематика новости. Каждый файл содержит определенное количество текста по каждой тематике.

На этапе классификации входными данными является текст или текстовый файл (в формате файла TXT), содержащий текст. Текст должен быть на русском языке, не менее 10 слов.

Результатом модуля классификации является прогнозируемое название тематика входного текста или содержимого файла и выводятся на пользовательский интерфейс программного обеспечения.

3.3. Руководство пользователя

Для запуска разработанного программного обеспечения требуется установить интерпретатор для Python и используемые библиотеки. Используемые в разработке библиотеки, которые необходимы для запуска ПО, приведены в файле requirements.txt, который находится в корневом каталоге проекта. С помощью пакетного менеджера pip все зависимости можно установить или обновить, запустив в терминале команду, приведенную в листинге 3.1.

Листинг 3.1 – Установка всех необходимых библиотек

```
1 pip install -r requirements.txt
```

Для работы библиотеки nltk необходимо скачать библиотеки. Для установки библиотеки nltk и скачивания библиотек нужно в коде программы выполнить команды, приведенные в листинге 3.2

Листинг 3.2 – Установка словарей nltk

```
1 import nltk  
2 nltk.download()
```

Для создания выборки необходимо разместить папку с файлом исходного набора данных внутри корневого каталога проекта и запустить скрипт dataset.py. Скрипт может запущен из графического интерфейса среды разработки, либо командой из терминала, приведенную в листинге 3.3.

Листинг 3.3 – Команда для создания обучающих выборок

```
1 python dataset.py
```

Чтобы обучить модель на заранее созданных размеченных выборках и предсказать тематик входного текста или текстового файла, пользователь может воспользоваться графическим интерфейсом приложения. Для открытия приложения необходимо запустить скрипт main.py посредством интерфейса среды разработки или командой в терминале, приведенную в листинге 3.4.

Листинг 3.4 – Команда для запуска приложения

```
1 python main.py
```

В результате разработанное программное обеспечение может установить тематик текста или выдвинуть предположение, что может быть тематикой.

3.4. Интерфейс пользователя

Пользовательский интерфейс, который представлен на рисунке 3.1, был разработан с помощью программы Qt Designer. Интеграция с кодом на Python осуществлена посредством с помощью библиотеки PyQt5, которая предоставляет различные классы для работы с объектами пользовательского интерфейса.

Метод классификации новостных текстов по тематику
с помощью метода опорных векторoa (SVM)

Обучение классификатора

Файл для обучения классификатора: data100.csv

Обучить классификатор Обновить выбранный файл

Классификация текстов

Введите новостной текст или загрузите из файла (*.txt) Выберите файл

Определить тематик

Тематик исходного текста:

Рисунок 3.1 – Пользовательского интерфейса ПО

Пользовательский интерфейс программного обеспечения состоит из 2 частей. В верхней части находится функционал обучения модели. В этом окне пользователь может выбрать файл для обучения модели из поля выбора. Каждый файл содержит определенное количество текста по каждой тематике. Пользователь может обновить содержимое этих файлов с помощью кнопки «Обновить выбранного файла». При нажатии на кнопку «Обучить модель» выбранная выборка разбивается на две части: 80% корпуса — обучающая выборка, 20% — тестовая. Программа сообщит, когда модель завершит обучение, как показано на рисунке 3.2.




Рисунок 3.2 – Модель готова

В нижней части находится функционал предсказания тематика текста. Если пользователь попытается определить тематик, не обучив сначала модель, будет возвращена ошибка, как показано на рисунке 3.3.




Рисунок 3.3 – Ошибка, возникающая в случае, если модель не обучена

Пользователь может ввести текст в поле ввода или выбрать файл. Программа поддерживает только txt файлы (текстовые файлы). При нажатии на кнопку «Выбрать файл» открывается файловая система компьютера, в которой необходимо выбрать интересующий текстовый файл. Когда пользователь выбирает файл, его содержимое отображается в текстовом поле. Если пользователь нажимает кнопку «Определить тематик», когда вводимый текст пуст или имеет неверный формат, будет возвращена ошибка, как показано на рисунке 3.4.




Рисунок 3.4 – Ошибка, возникающая в случае, если текстовое поле пусто

Если входной текст не пуст, то запускается алгоритм классификации. После того, как модель завершит работать, на экран будет выведено название наиболее вероятного тематика, как показано на рисунке 3.5.

Рисунок 3.5 – Результат работы классификации

Вывод

В этом разделе были приведены выбор языка программирования и средства программирования и рассмотрены необходимые библиотеки, которые ис-

пользуются для разработки программного обеспечения. Также был описан формат входных и выходных данных. Также были приведены описание пользовательского интерфейса и руководство пользователя для установки и использования программного обеспечения.

4 Исследовательский раздел

4.1. Технические характеристики

Технические характеристики устройства, на котором выполнялись исследования разработанного метода:

- операционная система Window 10 Home Single Language [**window**];
- память 8 Гб;
- процессор 11th Gen Intel(R) Core(TM) i5-1135G7 2.42 ГГц, 4 ядра [**cpu**].

Во время выполнения исследований устройство было подключено к сети электропитания, нагружено приложениями окружения и самой системой замера.

Для проведения исследований разработанного метода используются выборки, созданные на основе текстов по 5 темам: Наука и техника, Спорт, Культура, Экономика и Мир. Количество текста по каждой тематике в каждой выборке используется одинаковое. Исходная выборка разбивается на обучающую (80% объема) и тестовую (20%) выборки.

Как отмечалось раньше, метрики аккуратности и F1-меры используются в качестве метрики для оценки качества классификатора.

4.2. Влияние размера обучающей выборки

Обучающая выборка — это набор данных, который используется для обучения модели машинного обучения. Она представляет собой подмножество общего набора данных, которое содержит примеры, сопоставленные с соответствующими целевыми значениями или метками. Размер обучающей выборки — фактор, влияющий на качество классификатора.

Для проведения данного исследования было проведено сравнение зависимости времени обучения и качества классификатора от количества текстов на обучающей выборке.

Результаты проведенного исследования приведены в таблицах 4.1 и 4.2.

Таблица 4.1 – Замеры времени обучения от размера выборки

<i>Количество текстов в выборке</i>	<i>Время обучения классификатора (с.)</i>
50	0.03
100	0.08
200	0.23
500	1.59
1000	5.67
2000	21.29
3000	47.39
4000	82.76
5000	135.10

Таблица 4.2 – Зависимость качества классификатора от размера выборки

<i>Количество текстов в выборке</i>	<i>Точность на тестовой выборке</i>	<i>F1-мера</i>
50	0.2	0.27
100	0.9	0.89
200	0.9	0.90
500	0.91	0.92
1000	0.917	0.93
2000	0.92	0.935
3000	0.94	0.937
4000	0.942	0.94
5000	0.943	0.943

Ниже, на рисунках 4.1 и 4.2, представлены данные из таблиц 4.1 и 4.2 соответственно в виде графика.




Рисунок 4.1 – График зависимости времени обучения от размера выборки




Рисунок 4.2 – График зависимости качества классификатора от размера выборки

На основании полученных результатов можно сделать вывод, что количество текстов в обучающей выборке влияет на время обучения и качество классификатора. При использовании выборок с меньшим количеством текста классификатор будет обучаться за меньшее время, но с низкой точностью. По мере увеличения количества текстов в обучающей выборке точность классификатора также увеличивается. Стоит отметить, что увеличение количества текстов увеличивает время обучения, но существенно не увеличивает точность классификатора после того, как количество текстов достигнет 1000.

Таким образом, можно обучить классификатор на выборке из 1000 текстов для оптимизации времени обучения и качества классификатора.

4.3. Влияние наличия стоп-слов в тексте

На этапе предварительной обработки текста происходит процесс удаления стоп-слов. Как отмечалось ранее, стоп-слова — это текстовые шумы или неинформативные слова, которые встречаются в большом количестве, но не имеют семантического значения и при игнорировании этих слов исходное предложение не теряет своего смысла.

Для проведения данного исследования было проведено сравнение зависимости качества классификатора от наличия процесса удаления стоп-слов на этапе предварительной обработки текстов.

Результаты проведенного исследования приведены в таблице 4.3.

Таблица 4.3 – Зависимость качества классификатора от наличия стоп-слов

<i>Количество текстов</i>	<i>Точность на тестовой выборке (Без)</i>	<i>Точность на тестовой выборке (С)</i>	<i>F1-мера (Без)</i>	<i>F1-мера (С)</i>
50	0.2	0.2	0.27	0.27
100	0.9	0.95	0.89	0.94
200	0.9	0.90	0.90	0.90
500	0.92	0.93	0.92	0.93
1000	0.92	0.91	0.92	0.91
5000	0.943	0.933	0.94	0.93

Ниже, на рисунках 4.3 и 4.4, представлены данные из таблицы 4.3 в виде графика.




Рисунок 4.3 – График зависимости точности классификатора от наличия стоп-слов




Рисунок 4.4 – График зависимости F1-меры от наличия стоп-слов

На основании полученных результатов можно сделать вывод, что наличие стоп-слов в тексте обучающей выборки не сильно влияет на качество классификатора. В обучающих выборках с небольшим количеством текста (с 50 до 500 текстов) с стоп-словами обученные на них классификаторы имеют несколько более высокую точность, чем классификаторы, обученные на обучающих выборках без стоп-слов (на 1-2%). Но в обучающих выборках с большим количеством текстов (1000 или 5000 текстов) классификаторы, обученные на обучающих выборках без стоп-слов, имеют более высокую точность (на 1%).

4.4. Влияние ядра метода опорных векторов

Ядро (kernel) в методе опорных векторов определяет функцию, которая вычисляет скалярное произведение двух векторов в пространстве признаков. Оно позволяет проецировать данные в более высокомерное пространство, где они могут быть линейно разделимыми, даже если исходное пространство не является линейно разделимым.

Для проведения этого исследования было проведено сравнение зависимости качества классификатора от ядра метода опорных векторов при использовании следующих ядер: линейное, полиномиальное, Гауссово RBF и сигмоидальное.

Ниже, на рисунках 4.5 и 4.6, представлены результаты проведенного исследования




Рисунок 4.5 – График зависимости точности классификатора от ядер




Рисунок 4.6 – График зависимости F1-меры от ядер

Из полученных результатов можно сделать вывод, что зависимости точности и F1-меры классификатора от различных ядер совпадают. Классификатор с полиномиальным ядром имеет наименьшее качество, а классификаторы с другими ядрами имеют примерно одинаковую точность.

Вывод

В этом разделе были описаны технические характеристики устройства для проведения исследований и приведены исследования разработанного метода. Из полученных результатов исследований можно сделать вывод, что при увеличении количества текстов в обучающей выборке время обучения классификатора будет быстро увеличиваться, но точность классификатора возрастает незначительно для обучающих выборок с большим количеством текстов. Результаты также показывают, что процесс удаления стоп-слов на этапе предварительной обработки текста не сильно влияет на качество классификатора. Использование различных ядер для классификатора показывает, что использование линейного ядра, гауссовского ядра RBF и сигмоидального ядра приводит к получению высокоточного классификатора.

ЗАКЛЮЧЕНИЕ

В рамках настоящей работы был разработан, реализован и исследован метод классификации новостных текстов по тематикам с использованием опорных векторов. Все поставленные задачи были выполнены.

Был проведен анализ предметной области. Были рассмотрены методы очистки и предварительной обработки текста. Был проведен обзор методов извлечения признаков из текста.

Был рассмотрены и проанализированы основные методы классификации текстов. Была представлена формализованная постановка задачи в виде IDEF0-диаграммы.

Были описаны этапы работы алгоритма разрабатываемого метода, также были рассмотрены функциональные схемы обучения классификатора и метод классификации.

Были приведены метрики, используемые для оценки качества работы обученного классификатора. Был описан используемый набор данных для обучения классификатора и была рассмотрена структура программного обеспечения.

Были приведены выбор языка программирования и средства программирования и рассмотрены необходимые библиотеки, которые используются для разработки программного обеспечения. Также был описан формат входных и выходных данных. Также были приведены описание пользовательского интерфейса и руководство пользователя для установки и использования программного обеспечения.

Были описаны технические характеристики устройства для проведения исследований и приведены исследования разработанного метода

Для реализованного метода можно предложить следующие развития:

- ускорение работы метода.
- добавление возможности работы с различными языками.

ПРИЛОЖЕНИЕ А

Презентация