

РЕФЕРАТ

Расчетно-пояснительная записка к выпускной квалификационной работе «Метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети» содержит ?? страниц, 4 части, 13 рисунков, 4 таблиц, список используемых источников из ?? наименований и 1 приложений.

Ключевые слова: компьютерное зрение, глубокое обучение, сверточная нейронная сеть.

Объект разработки – метод обнаружения фальсифицированного фрагмента на изображении.

Цель работы: разработка и программная реализация метода автоматизированного определения области фальсифицированного фрагмента изображения с помощью двухпоточной свёрточной нейронной сети.

В первой части работы приведены обзор и сравнение существующих методов обнаружения фальсифицированного фрагмента на изображении.

Во второй части описан метод обнаружения фальсифицированного фрагмента на изображении с использованием сверточной нейронной сети, приведены IDEF0-диаграммы метода и схемы его алгоритмов.

В третьей части обоснован выбор средств разработки, приведена структура ПО, реализующий предложенный метод и описано взаимодействие пользователя с программным обеспечением..

В четвертой части выбраны метрики для оценки качества работы метода и приведены результаты исследования их зависимости от конфигурации нейронной сети и объемов передаваемых данных.

Разработанный метод может найти применение в области информационной безопасности и верификации медиаконтента в средствах массовой информации и социальных сетях. Это позволит своевременно выявлять и блокировать распространение дезинформации.

СОДЕРЖАНИЕ

РЕФЕРАТ	5
ВВЕДЕНИЕ	7
1 Аналитический раздел	8
1.1. Фальсификация изображений и задача её обнаружения .	8
1.1.1. Понятие фальсификации изображений	8
1.1.2. Основные трудности и требования к методам обнаружения .	9
1.2. Методы обнаружения фальсифицированного фрагмента на изображении	11
1.2.1. Методы на основе анализа целостности изображений	11
1.2.2. Методы поиска ключевых точек	13
1.2.3. Метод на основе сверточной нейронной сети	14
1.3. Сравнительный анализ методов фальсифицированного фрагмента на изображении	16
1.3.1. Обоснование критериев сравнения методов	16
1.3.2. Таблица сравнения методов	17
1.4. Формализованная постановка задачи	19
2 Конструкторский раздел	20
2.1. Требования и ограничения к разрабатываемому методу .	20
2.2. Описание разрабатываемого метода	21
2.2.1. Декомпозиция разрабатываемого метода	21
2.2.2. Алгоритмы предобработки и извлечения признаков	21
2.2.3. Структура разрабатываемой сверточной нейронной сети . . .	24
2.3. Структура разрабатываемого программного обеспечения	28
2.4. Набор данных для обучения модели	29
3 Исследовательский раздел	30
3.1. Метрики оценки качества модели	30
3.2. Влияние слоя внимания на качество модели	31
3.3. Влияние слоя адаптации признаков на качество модели .	33

3.4. Влияние объема передаваемых данных на качество работы метода	34
3.5. Влияние качества изображения на качество модели . . .	36
ЗАКЛЮЧЕНИЕ	38
ПРИЛОЖЕНИЕ А	39
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	39

ВВЕДЕНИЕ

В современном информационном обществе огромное количество новостей и статей публикуется каждый день. Чтобы эффективно обрабатывать и анализировать этот объем информации, важно иметь систему классификации новостей. Классификация позволяет автоматически определять тематику новости, ее важность, тональность и другие характеристики. Задача классификации новостей является актуальной и интересной задачей в области обработки естественного языка и машинного обучения. Она имеет широкий спектр применений, начиная от организации и ранжирования новостных потоков до автоматического анализа общественного мнения и выявления трендов.

Решение задачи классификации новостей может иметь большое практическое применение, включая создание интеллектуальных новостных агрегаторов, систем мониторинга общественного мнения, фильтрацию и организацию информации для пользователей. Это способствует улучшению доступа к информации, оптимизации процессов принятия решений и повышению качества новостных сервисов.

Однако, классификация новостей может быть сложной задачей из-за разнообразия тематик, стилей и тональностей новостных статей. Нередко встречаются случаи смешения нескольких тем в одной статье или субъективной интерпретации информации. Поэтому выбор правильного алгоритма и подхода, а также качество и разнообразие обучающих данных играют важную роль в достижении высокой точности классификации.

Цель работы — разработать метод классификации новостных текстов по тематикам с использованием опорных векторов. Для достижения поставленной цели необходимо выполнить следующие задачи:

- провести анализ предметной области, проанализировать предметную область и основные методы классификации текстов;
- разработать метод классификации новостных текстов по тематикам с помощью опорных векторов;
- разработать программное обеспечение, реализующее данный метод;
- оценить результаты работы метода в зависимости от различных параметров программного обеспечения.

1 Аналитический раздел

1.1. Фальсификация изображений и задача её обнаружения

1.1.1. Понятие фальсификации изображений

Под фальсификацией (подделкой) цифровых изображений понимается процесс внесения преднамеренных изменений в исходное изображение с целью искажения визуального содержания или смысла, который оно передаёт. В отличие от обычной обработки (коррекция яркости, цветокоррекция, шумоподавление), фальсификация направлена на создание ложного представления о реальности, что может использоваться как в личных, так и в профессиональных или политических целях [1].

С развитием доступных графических редакторов (Adobe Photoshop, GIMP и др.) и методов глубокого обучения возможности по созданию реалистичных подделок значительно расширились. В связи с этим задача обнаружения фальсификаций становится особенно актуальной в областях журналистики, криминалистики и социальных медиа[2].

В современной литературе по компьютерному зрению принято выделять несколько основных типов фальсификации изображений[3].

- Копирование-вставка (copy-move) — фрагмент изображения копируется и вставляется в другую область того же изображения, часто для сокрытия объектов или их дублирования.
- Вставка объектов из другого изображения (splicing) — часть одного изображения переносится в другое, создавая сцену, которой не существовало в действительности.
- Ретуширование (inpainting) — удаление или замена элементов с помощью заполнения области (например, удаление теней, людей, артефактов).
- Генерация полностью синтетических изображений — создание изображений с нуля с использованием генеративно-состязательных сетей (GAN) или диффузионных моделей.
- Deepfake — замена лица или мимики человека на видео и изображениях с использованием нейросетевых методов.

Цифровая фальсификация оставляет определённые статистические и семантические следы. Например, при копировании-вставке возникает повторяющаяся структура блоков, при вставке — нарушение согласованности шума датчика или освещения, а при ретушировании — аномалии в частотной области (артефакты сглаживания, некорректное сохранение JPEG)[4].

Важно отметить, что понятие фальсификации не включает в себя такие изменения, как сжатие с потерями, масштабирование или поворот, если они не направлены на введение в заблуждение зрителя. Однако в реальных условиях поддельное изображение часто подвергается дополнительным операциям (JPEG-сжатие, изменение размера, фильтрация), что усложняет его обнаружение[5].

Таким образом, для обнаружения фальсифицированного фрагмента необходимо учитывать множество потенциальных аномалий на различных уровнях представления изображения: от пиксельного до семантического.

1.1.2. Основные трудности и требования к методам обнаружения

Задача обнаружения фальсифицированного фрагмента на изображении относится к классу задач пассивной судебной экспертизы изображений. В отличие от активных методов (цифровая подпись, водяные знаки), пассивные методы не требуют предварительного внедрения вспомогательной информации, однако сталкиваются с рядом принципиальных трудностей, обусловленных как свойствами самих изображений, так и действиями злоумышленника[6].

К числу основных трудностей относятся.

1. Отсутствие эталонного («чистого») изображения. В большинстве практических сценариев (например, при проверке фотографий в СМИ или на интернет-платформах) исходное неизменённое изображение недоступно. Поэтому метод должен выявлять аномалии исключительно на основе статистических и семантических характеристик самого анализируемого файла.
2. Разнообразие типов фальсификаций. Как отмечалось в п. 1.1.1, подделки могут быть выполнены методами copy-move, splicing, inpainting, deepfake и др. Каждый тип оставляет различные следы: повторяющиеся блоки,

несоответствие шума сенсора, артефакты интерполяции или генеративные контуры. Универсальный метод должен быть устойчивым к нескольким типам подделок [7].

3. Соккрытие следов подделки послеоперационной обработкой. Злоумышленник может применять к поддельному изображению сжатие JPEG, масштабирование, добавление шума, медианную фильтрацию или размытие [5]. Эти манипуляции намеренно затрудняют обнаружение артефактов, разрушая статистические аномалии, внесённые в момент фальсификации.
4. Разнородность исходных изображений. Метод не должен полагаться на фиксированные характеристики (размер, разрешение, цветовое пространство, модель камеры), так как изображения в реальных условиях поступают из самых разных источников [8]. Это требует инвариантности к разрешению, коэффициенту сжатия и уровню шума.
5. Ограничения по вычислительным ресурсам и времени. Применение метода в потоковых системах (социальные сети, новостные агрегаторы) требует быстрой обработки (миллисекунды на изображение) и работы с большими объёмами данных. Слишком ресурсоёмкие модели неприменимы в реальном времени.

В связи с перечисленными трудностями к современным методам обнаружения фальсифицированного фрагмента предъявляются следующие требования [9]:

- Высокая точность: метод должен обеспечивать высокие значения метрик IoU, F1-меры и точности классификации пикселей на тестовых наборах, сбалансированных по типам подделок.
- Робастность (устойчивость): метод должен сохранять работоспособность после сжатия JPEG, изменения размера, добавления шума и других типов постобработки.
- Обобщающая способность: обученная модель должна корректно работать на изображениях, взятых из датасетов, не участвовавших в обучении, и на неизвестных типах подделок.

- Локализация фрагмента: метод должен не только выносить бинарное решение, но и выдавать карту локализации с указанием границ изменённой области (пиксельная маска).
- Инвариантность к изображению: метод не должен зависеть от конкретной модели камеры, формата (JPEG, PNG, BMP) и цветовой схемы (RGB, YCbCr).

Таким образом, разработка практического метода обнаружения фальсифицированного фрагмента представляет собой сложную многокритериальную задачу, требующую компромисса между точностью, устойчивостью и скоростью работы.

1.2. Методы обнаружения фальсифицированного фрагмента на изображении

1.2.1. Методы на основе анализа целостности изображений

Методы обнаружения фальсифицированного фрагмента на основе анализа целостности изображений опираются на предположение, что любая модификация исходного изображения нарушает определённые статистические закономерности, присущие естественным изображениям. В отличие от методов поиска ключевых точек, которые ориентированы преимущественно на выявление атак сору-move, подходы на основе целостности анализируют непротиворечивость таких физически обоснованных характеристик, как шум датчика (PRNU), артефакты двойного сжатия JPEG и корреляции, вносимые интерполяцией цветных фильтров (CFA). Каждый из этих трёх методов имеет собственную область эффективности и ограничения [2].

Метод на основе анализа шума датчика (PRNU)

Каждая цифровая камера оставляет уникальный «отпечаток» – фотоотклик неравномерности (photo-response non-uniformity, PRNU), возникающий из-за неоднородной чувствительности пикселей [4]. При вставке фрагмента из другого изображения (splicing) в подделанной области нарушается согласованность PRNU: появляется шум другой камеры или его отсутствие. Метод вычисляет PRNU анализируемого изображения (обычно с помощью вейвлет-фильтрации или использования фильтра высоких частот) и оценивает его кор-

реляцию с эталонным шумом предполагаемой камеры. Если фрагмент изображения имеет статистически значимое расхождение в структуре шума, это свидетельствует о подделке [4]. Достоинства метода: высокая интерпретируемость (шумовая карта наглядно показывает границы вставки) и хорошая точность для изображений высокого разрешения без постобработки. Главный недостаток – необходимость знания эталонного PRNU камеры, что в реальных сценариях часто невозможно. Кроме того, сильное сжатие JPEG или масштабирование разрушают тонкую структуру PRNU, делая метод неэффективным [10].

Метод на основе двойного сжатия JPEG (Double JPEG)

Большинство цифровых изображений сохраняются в формате JPEG с потерями. Если злоумышленник редактирует изображение и сохраняет его повторно, возникает так называемое двойное сжатие с возможно разными таблицами квантования. При этом гистограмма коэффициентов дискретного косинусного преобразования (DCT) для отдельных частотных полос приобретает характерные периодические пики. Метод анализирует гистограммы DCT-коэффициентов и выявляет наличие двух различных стадий квантования. В наиболее развитой форме метод не только определяет факт двойного сжатия, но и оценивает параметры первого сжатия [11]. Достоинства: работает без какой-либо априорной информации об исходной камере, устойчив к умеренным атакам. Недостатки: метод даёт в основном бинарный ответ и плохо локализует точную область вставки; кроме того, если злоумышленник сохранил подделку без сжатия (в формате PNG) или использовал тот же коэффициент качества, двойное сжатие может быть не обнаружено.

Метод на основе анализа интерполяции цветных фильтров (CFA)

Большинство цифровых камер используют матрицу цветных фильтров Байера, где каждый пиксель регистрирует только один цветовой канал (зелёный, красный или синий), а недостающие цветовые значения восстанавливаются с помощью демозаики. Процесс интерполяции вносит корреляции между соседними пикселями и между цветовыми каналами. При вставке фрагмента из другого изображения или при ретушировании локальная структура CFA-интерполяции нарушается, так как вставленная область имеет свою историю обработки. Метод моделирует ожидаемый процесс интерполяции для данной модели камеры или строит универсальную модель и вычисляет ошибку предсказания пикселя по соседним. В областях, где CFA-интерполяция нарушена,

ошибка предсказания статистически значимо выше. Достоинства метода: возможность локализации подделки на уровне пикселей без необходимости знать эталонный PRNU. Недостатки: высокая чувствительность к сжатию JPEG, а также к масштабированию. Метод эффективен только для изображений, поступивших напрямую с камеры и сохранённых в формате без потерь или с минимальным сжатием [12].

1.2.2. Методы поиска ключевых точек

Методы обнаружения фальсификации на основе поиска ключевых точек (keypoint-based methods) являются одним из наиболее эффективных подходов для выявления атак типа «копирование-вставка» (сору-move). Основная идея заключается в том, что при копировании фрагмента изображения и вставке его в другое место того же изображения в подделке появляются две или более области с идентичным или очень похожим содержанием. Ключевые точки представляют собой локальные особенности, инвариантные к масштабу, повороту и частично к изменению освещения, что позволяет обнаруживать дублированные фрагменты даже после их геометрического преобразования [13]. Наибольшее распространение в задачах криминалистики изображений получили SIFT (Scale-Invariant Feature Transform) и SURF (Speeded-Up Robust Features) [14].

Метод SIFT

Дескриптор SIFT, предложенный Лоу в 2004 году, стал золотым стандартом для обнаружения сору-move подделок [15]. Алгоритм включает следующие этапы: построение масштабного пространства, локализацию экстремумов разности гауссиан (DoG), отбраковку низкоконтрастных и граничных точек, назначение ориентации на основе градиентов и формирование 128-мерного дескриптора для каждой ключевой точки. При обнаружении подделки вычисляются SIFT-дескрипторы для всего изображения, затем выполняется их попарное сравнение (обычно с использованием отношения расстояний до ближайшего и второго ближайшего соседа). Пары ключевых точек с высокой степенью совпадения дескрипторов группируются в кластеры с помощью алгоритмов иерархической кластеризации или DBSCAN, после чего для каждой группы строится ограничивающий прямоугольник или точный контур подозрительной области [16]. SIFT демонстрирует высокую устойчивость к повороту, масштабированию и небольшому изменению перспективы, а также к сжатию JPEG при ко-

эфициентах качества выше 70 %. Однако его вычислительная сложность относительно высока: извлечение дескрипторов и особенно их попарное сравнение может занимать несколько секунд на изображении среднего разрешения [17].

Метод SURF

Для ускорения обработки был предложен дескриптор SURF, который использует интегральные изображения и приближённые детерминанты матрицы Гессе для быстрого обнаружения ключевых точек [18]. SURF формирует 64-мерный или 128-мерный дескриптор на основе распределения гауссовых вейвлет-ответов в окрестности точки. По сравнению с SIFT, SURF работает в несколько раз быстрее при сопоставимой точности для большинства типов сору-моуе подделок. Однако SURF уступает SIFT при сильных аффинных искажениях и при низкой освещённости. В задачах обнаружения фальсификаций SURF часто выбирают для систем реального времени или для обработки больших массивов изображений, когда время критичнее максимальной точности[19].

Оба метода практически не работают на гладких, однородных областях, где недостаточно текстуры для выделения ключевых точек. В таких случаях дублированный фрагмент не обнаруживается [20]. Кроме того, SIFT и SURF не предназначены для выявления splicing (вставка объекта из другого изображения) или ретуширования, поскольку при этих типах подделок отсутствует дублирование областей внутри одного изображения. Наконец, при сильном сжатии JPEG количество ключевых точек резко уменьшается, а ложные совпадения возрастают, что требует применения дополнительных методов геометрической верификации. Несмотря на указанные ограничения, SIFT и SURF остаются эталонными методами для обнаружения сору-моуе подделок и используются для сравнения с более современными нейросетевыми подходами[21].

1.2.3. Метод на основе сверточной нейронной сети

Методы обнаружения фальсифицированных фрагментов на основе свёрточных нейронных сетей (CNN) в последние годы заняли доминирующее положение в области компьютерной криминалистики изображений. В отличие от классических подходов (анализ целостности или поиск ключевых точек), которые требуют ручного проектирования признаков, CNN автоматически извлекают иерархические представления из данных, обучаясь различать подлинные

и поддельные области на больших размеченных наборах. Способность сетей выявлять сложные статистические аномалии, невидимые для традиционных детекторов, обусловила их широкое применение для выявления вставки объектов, копирования-вставки и так далее [22].

Первые работы по применению CNN для обнаружения подделок использовали простую архитектуру с несколькими свёрточными и полносвязными слоями, работавшую на входных изображениях фиксированного малого размера (например, 64×64 или 128×128). Такие сети классифицировали небольшие патчи как подлинные или поддельные, после чего для локализации фальсификации применялся скользящий оконный метод [23]. Хотя этот подход демонстрировал приемлемую точность на сбалансированных датасетах, он был вычислительно затратным и давал высокую долю ложноположительных срабатываний на границах объектов. Кроме того, сети, обученные на патчах, часто запоминали артефакты конкретного типа фальсификации и плохо обобщались на другие типы фальсификаций.

Прорывом стало появление полностью свёрточных сетей (FCN — Fully Convolutional Networks), которые на входе принимают изображение произвольного размера и на выходе выдают карту локализации той же пространственной размерности. Архитектура типа U-Net (симметричный энкодер-декодер с пропускными соединениями) стала стандартом для пиксельной сегментации подделанных областей [24]. Энкодер последовательно уменьшает пространственное разрешение, извлекая всё более абстрактные признаки, а декодер восстанавливает детализацию и формирует маску подделки. Пропускные соединения позволяют сохранить мелкие гранулярные признаки, которые иначе теряются при многократном субдискретизации [25].

Важным направлением является использование не RGB-изображений в качестве входа, а так называемых остаточных карт, полученных вычитанием из исходного изображения его сглаженной версии. Такой подход подавляет семантическое содержание и усиливает следы камеры и постобработки. Сеть, обученная на остатках, оказывается более устойчивой к сжатию JPEG и изменениям контента, поскольку вынуждена фокусироваться на статистических аномалиях, а не на форме объектов [26].

Для борьбы с разнообразием типов подделок и усложняющих обработок исследователи разрабатывают многозадачные и многомасштабные архитекту-

ры. Один из подходов – использование параллельных ветвей сети, работающих на разных масштабах, с последующим объединением карт признаков [10]. Другой – применение механизмов внимания, которые позволяют сети динамически взвешивать важность различных пространственных областей и каналов признаков.

Одной из ключевых проблем CNN-методов является их чувствительность к различиям между обучающими и тестовыми датасетами. Сеть, обученная на изображениях с одними камерами и степенями сжатия, может резко терять точность при тестировании на других. Для повышения обобщающей способности применяют методы аугментации, где сеть обучается одновременно на подлинных и сгенерированных подделках, устойчивых к детектированию. В последнее время активно развиваются методы адаптации признаков, которые выравнивают распределения признаков из разных доменов с помощью градиентного реверса слоя или вариационных автоэнкодеров.

Несмотря на высокие показатели качества, CNN-методы имеют и недостатки. Во-первых, они требуют больших размеченных наборов данных с пиксельной маской подделки, создание которых трудоёмко. Во-вторых, многие модели «чёрный ящик»: сложно интерпретировать, на каком именно основании сеть отнесла область к подделанной. В-третьих, вычислительные затраты на обучение глубоких сетей высоки, и для работы в реальном времени часто требуется GPU-ускорение [2].

1.3. Сравнительный анализ методов фальсифицированного фрагмента на изображении

1.3.1. Обоснование критериев сравнения методов

Для объективного сопоставления различных методов обнаружения фальсифицированного фрагмента на изображении необходимо определить систему критериев, отражающих как точность детекции, так и пригодность метода для практического применения. В настоящей работе предлагается использовать три основных критериев: точность локализации фальсификации, устойчивость к постобработке и обобщающую способность на неизвестных типах подделок.

Первым и наиболее важным критерием является точность локализации подделанного фрагмента. В отличие от бинарной классификации, задача лока-

лизации требует указать границы изменённой области на пиксельном уровне. Высокое значение точности свидетельствует о том, что метод способен точно выделить форму вставленного объекта.

Второй критерий — устойчивость к постобработке изображения. В реальных условиях фальсифицированное изображение почти всегда подвергается сжатию с потерями, изменению размера или добавлению шума. Злоумышленник может намеренно применять такие операции для маскировки следов подделки [5]. Сравнение методов должно проводиться при разных коэффициентах качества JPEG.

Третий критерий — обобщающая способность на неизвестных типах фальсификации и датасетах. Метод не должен «переобучаться» под конкретный датасет. Для оценки обобщения применяются обучение на одном наборе данных и тестирование на другом.

1.3.2. Таблица сравнения методов

На основе обоснованных в п. 1.3.1 критериев (точность локализации, робастность к постобработке, вычислительная эффективность, обобщающая способность, интерпретируемость) проведём сравнительный анализ трёх основных классов методов обнаружения фальсифицированного фрагмента: аналитических методов целостности, дескрипторных методов на основе ключевых точек и методов на основе свёрточных нейронных сетей (включая их расширения с вниманием и адаптацией признаков). Для каждого критерия используется качественная шкала: «высокая», «средняя», «низкая», а также уточняющие комментарии. Результаты сведены в таблицу 1.1.

Таблица 1.1 – Сравнительная таблица методов

<i>Метод</i>	<i>Точность</i>	<i>Устойчивость к постобработке</i>	<i>Обобщающая способность</i>
Метод на основе анализа целостности изображений	Низкая/Средняя	Низкая	Низкая
Метод на основе поиска ключевых точек	Средняя	Средняя	Низкая
Однопоточная сверточная нейронная сеть	Средняя/Высокая	Средняя	Средняя
Многopotочная сверточная нейронная сеть	Высокая	Средняя/Высокая	Средняя/Высокая

На основе данных таблицы 1.1 можно сделать следующие выводы. Методы на основе анализа целостности изображений обладают преимуществом в интерпретируемости и независимости от обучающих данных, однако их точность и робастность к постобработке остаются низкими, особенно при сжатии JPEG и изменении размера. Они рекомендуются в задачах, где важна объяснимость.

Методы на основе поиска ключевых точек (SIFT, SURF) показывают высокую точность локализации для сору-move подделок. Их главные недостатки — непригодность для выявления splicing и inpainting, а также вычислительная сложность, ограничивающая применение на высокоразрешенных изображениях.

Нейросетевые методы на основе CNN демонстрируют наилучшие показатели по точности локализации и робастности к постобработке, а также способны обнаруживать широкий спектр подделок. Их недостатками являются низкая интерпретируемость, высокая зависимость от размера и качества обучающей выборки.

1.4. Формализованная постановка задачи

В настоящей работе проектируется метод обнаружения фальсифицированного фрагмента на изображении с помощью свёрточной нейронной сети, а именно — двухпоточной архитектуры с слоями вниманий и адаптацией признаков. Набор данных для обучения должен быть подготовлен — должно быть установлено уникальное соответствие между входным изображением и бинарной маской. Набор данных должен быть предварительно обработан и извлечены признаки. Обученная модель используется для распознавания границ фальсифицированного фрагмента и выдачи маски локализации.

Ниже, на рисунке 1.1, представлена IDEF0-диаграмма нулевого уровня.




Рисунок 1.1 – IDEF0-диаграмма нулевого уровня

2 Конструкторский раздел

В данном разделе сформулированы требования к разрабатываемому методу и разрабатываемому программному обеспечению. Разработан метод обнаружения фальсифицированного фрагмента на изображениях с использованием сверточной нейронной сети. Описаны основные этапы разработки в виде детализированной диаграммы IDEF0 и схема архитектуры разрабатываемой нейронной сети, а также изложены особенности предлагаемого метода. Спроектировано программное обеспечение для реализации разрабатываемого метода.

2.1. Требования и ограничения к разрабатываемому методу

К разрабатываемому методу предъявляются следующие требования.

- Метод должен базироваться на использовании сверточных нейронных сетей с необходимыми модификациями.
- Принимать на вход изображения в форматах PNG, JPG, JPEG, BMP с размером от 216×216 до 1024×1024 включительно.
- Метод должен быть применим для работы с различными типами сцен, а также различными освещением.

К разрабатываемому программному обеспечению предъявляются следующие требования.

- Возможность загрузки изображений в формате PNG, JPG, JPEG или BMP.
- Возможность обработки как RGB – изображений.
- Возможность просмотра информации по процессу обучения модели.
- Возможность просмотра значения метрик качества модели.
- Разрабатываемое ПО должно корректно реагировать на любые действия пользователя.

2.2. Описание разрабатываемого метода

2.2.1. Декомпозиция разрабатываемого метода

Ниже, на рисунке 2.1, представлена IDEF0-диаграмма разрабатываемого метода первого уровня.




Рисунок 2.1 – IDEF0-диаграмма первого уровня

2.2.2. Алгоритмы предобработки и извлечения признаков

Основная цель предварительной обработки изображений перед их подачей в сверточную нейронную сеть (CNN) — повысить качество и информативность данных, чтобы улучшить детектирование артефактов, характерных для глубокого подделки. Этот этап помогает устранить шумы, нормализовать изображения, выделить ключевые признаки и минимизировать влияние вариаций освещения, масштаба и ракурса. В результате CNN может более эффективно фокусироваться на различиях между реальными и синтетическими изображениями, повышая точность обнаружения [27].

Ниже, на рисунке 2.2, представлены шаги предобработка изображения.



Рисунок 2.2 – Шаги предобработка изображения

Для извлечения признаков из изображений используются карты шумовых признаков. Ниже на рисунку 2.3 показан алгоритм извлечения карты шумовых признаков.




Рисунок 2.3 – Алгоритм извлечения признаков.

После завершения предварительной обработки запускается итеративный алгоритм выделения шумовых признаков. На вход подаётся нормализованное изображение. Оно сжимается с качеством 95% — это создаёт потери, характерные для сжатия. Затем вычисляется попиксельная разность между исходным нормализованным изображением и его сжатой версией. Полученная разность

усиливается — значение ошибки увеличивается. После усиления проверяется, достигнут ли заданный порог отображения. Если порог не достигнут, цикл повторяется: снова вычисляется разность. Как только порог оказывается превышен, алгоритм формирует итоговую карту шумовых признаков. Таким образом, метод многократно накапливает и усиливает малые искажения, обусловленные сжатием, что позволяет выделить слабые артефакты, которые в дальнейшем могут служить характерными признаками для обнаружения.

Эта предобработка позволяет CNN сосредоточиться на анализе наиболее значимых для обнаружения подделок областей, повышая точность модели.

2.2.3. Структура разрабатываемой сверточной нейронной сети

Разрабатываемая сверточная нейронная сеть представляет собой многоуровневую архитектуру, специально спроектированную для эффективного извлечения признаков из изображений. Модель сочетает в себе последовательную обработку через блоки свёртки, слои адаптации признаков и механизмы внимания.

Общая структура сети показана ниже, на рисунке 2.4.




Рисунок 2.4 – Общая структура сети.

Как видно из общей схемы, нормализованное входное изображение последовательно проходит через четыре блока свёртки и уменьшения размерности. После каждого блока следует слой адаптации признаков. Параллельно в нижней ветви сети расположены последовательные слои внимания, которые усиливают важные признаки перед дальнейшей обработкой. Блок свёртки и уменьшения

размерности является основным строительным элементом сети. Его детальная структура представлена на следующем рисунке 2.5.




Рисунок 2.5 – Блок свёртки и уменьшения размерности.

Каждый блок состоит из четырёх последовательных слоёв:

- Слой свёртки;
- Слой нормализации;
- Слой активации ReLU;
- Слой уменьшения размерности.

После каждого блока уменьшения размерности применяется слой адаптации признаков, который использует механизм остаточного соединения для сохранения важной информации.




Рисунок 2.6 – Слой адаптации признаков.

В нижней части архитектуры находятся слои внимания, реализующие механизм канального внимания. Слой внимания включает глобальный пулинг, два полносвязных слоя с активациями ReLU и Sigmoid, а также операцию масштабирования, что позволяет динамически перераспределять веса по каналам карты признаков. Их структура представлена ниже.




Рисунок 2.7 – Слой внимания.

Такая продуманная комбинация блоков уменьшения/увеличения размерности, остаточных соединений и модулей внимания обеспечивает эффективное извлечение как низкоуровневых, так и высокоуровневых признаков, делая модель более устойчивой и точной.

2.3. Структура разрабатываемого программного обеспечения

Разрабатываемое программное обеспечение состоит из двух модулей:

- модуль, реализующий метод обнаружения фальсифицированного фрагмента на изображениях с использованием сверточной нейронной сети;
- пользовательское приложение, производящее обнаружение фальсифицированного фрагмента на изображениях на основе разработанного метода, а так же предоставляющее возможность обучения модели, используемой в предыдущем модуле.

Модуль CNN модели

В данном модуле происходит только обучение и сохранение модели. Модуль должен быть использован либо при первоначальном обучении модели.

Результатом работы модуля является файл, содержит в себе обученную модель, т.е. ее структуру и весовые коэффициенты соответствующих связей. Это необходимо для того, чтобы не тратить время на обучение модели при повторном использовании, так как процесс обучения может занимать продолжительный период времени в зависимости от некоторых факторов.

На рисунке 2.8 представлена схема работы с модулем CNN модели.




Рисунок 2.8 – Схема работы с модулем CNN модели

Модуль пользовательского приложения

Данный модуль позволяет пользователю загружать изображение для последующего анализа. Результатами работы модуля являются прогнозируемая маска и изображение с отмеченным фрагментом.

На рисунке 2.9 представлена схема работы с модулем пользовательского приложения.



Рисунок 2.9 – Схема работы с модулем пользовательского приложения

2.4. Набор данных для обучения модели

Для обучения и оценки модели использовался широко известный в области цифровой криминалистики набор данных CASIA v2.0. Данный датасет был считается одним из наиболее крупных и сложных публичных наборов данных для задач обнаружения и локализации различных типов манипуляций с изображениями[28].

CASIA v2.0 содержит 5123 поддельных изображений и соответственные бинарные маски. Поддельные изображения включают два основных типа манипуляций: *copy-move* (копирование и вставка внутри одного изображения) и *splicing* (вставка объектов из других изображений). Изображения имеют различное разрешение и представлены в нескольких форматах: JPEG, TIFF и BMP. Важной особенностью датасета является наличие постобработки поддельных областей (размытие, сжатие, поворот, масштабирование), что делает задачу локализации значительно более сложной и приближенной к реальным условиям.

Применение CASIA v2.0 позволило модели обучаться на разнообразных сценариях подделок, различных текстурах, освещении и постобработках, что существенно повышает обобщающую способность сети. Перед обучением изображения проходили этап нормализации и предварительной аугментации для повышения устойчивости модели к вариациям условий съёмки и сжатия.

Использование именно этого датасета обеспечивает возможность объективного сравнения результатов предлагаемой модели с существующими современными подходами в области *image forgery localization*.

3 Исследовательский раздел

3.1. Метрики оценки качества модели

Поскольку задача обнаружения фальсифицированного фрагмента на изображении формулируется как задача сегментации на уровне пикселей, оценка качества модели должна учитывать как классификационную точность, так и пространственное соответствие предсказанных и истинных областей сфальсифицированного. В связи с этим для оценки качества метода используется комплекс метрик, специализированных для задач локализации аномалий.

Базой для вычисления всех показателей служат следующие понятия, определяемые на уровне каждого пикселя тестовой выборки:

- TP (англ. True Positive) — количество пикселей, корректно классифицированных как принадлежащих области сфальсифицированных;
- TN (англ. True Negative) — количество пикселей, корректно классифицированных как принадлежащих фону;
- FP (англ. False Positive) — количество пикселей, ошибочно отнесённых к области сфальсифицированных;
- FN (англ. False Negative) — количество пикселей области сфальсифицированных, пропущенных моделью.

Точность на уровне пикселей отражает долю правильно классифицированных пикселей от общего числа пикселей в тестовой выборке:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}. \quad (3.1)$$

Данная метрика удобна для общей оценки, однако при сильном дисбалансе классов (область подделки обычно занимает менее 5-10 % площади изображения) она может давать завышенные результаты за счёт доминирования класса фона.

Для более объективной оценки качества выделения целевой области используются точность (Precision) и полнота (Recall):

$$Precision = \frac{TP}{TP + FP}. \quad (3.2)$$

$$Recall = \frac{TP}{TP + FN}. \quad (3.3)$$

На основе этих показателей вычисляется F1-мера, представляющая собой гармоническое среднее точности и полноты:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} = \frac{2TP}{2TP + FP + FN}. \quad (3.4)$$

F1-мера устойчива к дисбалансу классов и широко применяется в задачах обнаружения локальных артефактов, поскольку учитывает как пропущенные ложные пиксели, так и ложные срабатывания на фоне.

Ключевой метрикой пространственного соответствия является коэффициент пересечения над объединением (англ. Intersection over Union, IoU):

$$IoU = \frac{TP}{TP + FP + FN}. \quad (3.5)$$

IoU измеряет степень перекрытия предсказанной маски подделки с эталонной разметкой и является стандартом де-факто в задачах сегментации. Значение $IoU = 1$ указывает на идеальное совпадение границ, а $IoU=0$ — на полное отсутствие пересечения.

Все метрики вычисляются на уровне пикселей для каждой тестовой пары «изображение – маска», после чего усредняются по всей тестовой выборке. Такой комплексный подход (F1-мера и IoU) обеспечивает всестороннюю оценку способности сверточной нейронной сети локализовывать фальсифицированные фрагменты при различных объёмах и конфигурациях входных данных. В дальнейшем эти две метрики будут использоваться как основные для анализа результатов всех экспериментов.

3.2. Влияние слоя внимания на качество модели

Целью данного исследования является изучение эффективности использования слоев внимания в реализованной модели сверточной нейронной сети.

Для проведения этого исследования было выполнено сравнительное тестирование двух конфигураций модели: с использованием слоев внимания и без них. Все остальные компоненты архитектуры оставались неизменными. Эксперимент проводился на одной и той же тестовой выборке, что обеспечило объективность сравнения. Результаты эксперимента представлены в таблице 3.1.

Таблица 3.1 – Зависимость точности от конфигураций

<i>Конфигурация</i>	<i>Значение $F1$</i>	<i>Значение IoU</i>
С использованием слоев внимания	0.9042	0.8252
Без использования слоев внимания	0.6784	0.5133

Примеры результатов обнаружения модели при различных конфигурациях слоев внимания представлены на рисунке 3.1.




Рисунок 3.1 – Зависимость качества модели от конфигураций слоев внимания.

На основании полученных результатов можно сделать вывод, что добавление слоев внимания приводит к существенному приросту обеих ключевых метрик. Данный результат подтверждает высокую эффективность механизма внимания для задачи обнаружения фальсифицированных фрагментов. Поскольку область подделки обычно занимает малую долю изображения, большинство каналов признаков содержит информацию о нормальном фоне. Без механизма внимания модель «размазывает» внимание по всем каналам, что приводит к высокому уровню ложноположительных срабатываний (FP) и пропуску мелких деталей подделки (FN). Слой внимания позволяет модели фокусироваться на

высокочастотных артефактах, характерных для фальсифицированных областей. Это особенно важно при решении задачи сегментации с сильным дисбалансом классов. Таким образом, использование слоев внимания значительно повышает качество модели, делая её более чувствительной к локальным артефактам подделки.

3.3. Влияние слоя адаптации признаков на качество модели

Целью данного исследования является изучение эффективности использования слоев адаптации признаков в реализованной модели сверточной нейронной сети.

Для проведения этого исследования было выполнено сравнительное тестирование трёх конфигураций модели: без использования слоев адаптации признаков, со слоями адаптации в виде единых блоков свёртки и со слоями адаптации в виде остаточных блоков. Все остальные компоненты архитектуры оставались неизменными. Эксперимент проводился на одной и той же тестовой выборке. Результаты эксперимента представлены в таблице 3.2.

Таблица 3.2 – Зависимость точности от конфигураций

<i>Конфигурация</i>	<i>Значение F1</i>	<i>Значение IoU</i>
Без использования слоев адаптации признаков	0.6829	0.6011
Слои адаптации признаков как единые блоки свёртки	0.7653	0.7139
Слои адаптации признаков как остаточные блоки	0.9042	0.8252

Примеры результатов обнаружения модели при различных конфигурациях слоев адаптации признаков представлены на рисунке 3.2.

На основании полученных результатов можно сделать вывод, что отказ от слоев адаптации признаков приводит к значительному снижению качества, использование простых сверточных блоков даёт умеренное улучшение, наилучшие результаты достигаются при реализации слоев адаптации в виде остаточных блоков. Основная причина такого различия заключается в природе признаков, поступающих из ветви извлечения признаков. Эти признаки содержат высокочастотные детали, которые при прямом объединении с семантическими кар-



Рисунок 3.2 – Зависимость качества модели от конфигураций слоев адаптации признаков.

тами основной ветви создают значительные помехи. Это приводит к размытию границ предсказанной маски и высокому уровню ложноположительных результатов на фоне. При использовании единых сверточных блоков качество улучшается, но всё ещё наблюдается потеря мелких деталей. Остаточные блоки обеспечивают чёткие, точные границы маски и минимальное количество ложных срабатываний даже на сложных текстурах фона. Таким образом, слои адаптации признаков, реализованные в виде остаточных блоков, являются оптимальным решением. Они эффективно фильтруют помехи, сохраняют важную высокочастотную информацию и обеспечивают наилучшее качество локализации фальсифицированных фрагментов при сильном дисбалансе классов.

3.4. Влияние объема передаваемых данных на качество работы метода

Целью данного исследования является изучение зависимости точности метода обнаружения фальсифицированного фрагмента от объема передаваемых данных. Поскольку в рамках используемой архитектуры сверточной нейронной сети основным фактором, определяющим объем обрабатываемой информации, выступает пространственное разрешение входного изображения, в эксперименте рассматривались изображения различных размеров: 384×256 , 640×480 и 800×600 пикселей. Большее число пикселей соответствует больше-

му объему данных, поступающих на вход сети.

Тестирование проводилось на единой тестовой выборке. Все компоненты модели, включая слои внимания и адаптации признаков, оставались неизменными. В качестве оцениваемых показателей использовались усредненные по каждой размерной группе значения F1-меры и IoU. Результаты эксперимента представлены ниже в таблице 3.3.

Таблица 3.3 – Зависимость точности от размеров входного изображения

<i>Размер изображения</i>	<i>Значение F1</i>	<i>Значение IoU</i>
384×256	0.9305	0.8887
640×480	0.9270	0.8792
800×600	0.5834	0.5190

На основании полученных результатов можно сделать вывод, что при умеренном объеме передаваемых данных (разрешения 384×256 и 640×480) модель демонстрирует стабильно высокое качество локализации: средняя F1-мера превышает 0,92, а средний IoU — 0,87. Это свидетельствует о том, что в пределах исследованного диапазона, характерного для многих практических сценариев, эффективность метода практически не зависит от объема данных. Однако при переходе к изображениям большего размера 800×600, то есть при значительном увеличении объема передаваемой информации, наблюдается резкое падение обеих метрик: средняя F1-мера снижается до 0,5834, а средний IoU — до 0,5190. Такое ухудшение объясняется тем, что текущая архитектура сети ориентирована на определенный пространственный масштаб признаков, и при избыточном объеме данных высокочастотные артефакты подделки либо маскируются обилием фоновых деталей, либо требуют более глубокого анализа, не обеспеченного существующей конфигурацией.

Таким образом, проведенный эксперимент подтверждает, что реализованный метод сохраняет высокую эффективность для объемов передаваемых данных, соответствующих разрешениям приблизительно до 640×480. Дальнейшее повышение качества на данных большего объема может быть достигнуто путем модификации архитектуры с целью адаптации к высокоразрешающим изображениям.

3.5. Влияние качества изображения на качество модели

Целью данного исследования является изучение влияния качества изображений на точность разработанного метода.

Для проверки устойчивости модели был проведен эксперимент по сжатию входных изображений по стандарту JPEG. Поскольку в реальных условиях изображения часто подвергаются сжатию, важно оценить, как изменение коэффициента качества влияет на точность локализации. Исследование проводилось при варьировании качества от 0.85 до 1, а результаты по метрикам F1-score и IoU представлены на рисунке 3.3.




Рисунок 3.3 – Зависимость качества модели от качества изображений.

На основании полученных результатов можно сделать вывод, что точность разработанного метода существенно зависит от уровня сжатия JPEG входного изображения. При высоком качестве изображения (коэффициент JPEG равен 100) модель демонстрирует наилучшие результаты. Однако с увеличением степени сжатия (уменьшением коэффициента качества JPEG) наблюдается устойчивое снижение обеих метрик. Данная зависимость свидетельствует о достаточной чувствительности модели к потерям информации, вызванным JPEG-компрессией, которая является одним из наиболее распространённых видов постобработки в реальных условиях. Тем не менее, даже при сильном сжатии модель сохраняет приемлемый уровень точности локализации, что подтверждает её определённую робастность. Полученные результаты указывают на необходимость дальнейшего совершенствования архитектуры, в частности, путём введе-

ния дополнительных механизмов устойчивости к JPEG-артефактам.

Вывод

В ходе исследования разработанной сверточной нейронной сети были выбраны и обоснованы основные метрики оценки качества локализации фальсифицированного фрагмента — F1-мера и IoU. Эксперименты показали, что использование слоя внимания значительно повышает точность модели. Наилучшие результаты достигаются при применении слоёв адаптации признаков в виде остаточных блоков, которые эффективно фильтруют шум и сохраняют важную информацию. Исследование влияния объема передаваемых данных показало стабильные высокие результаты на изображениях разрешений до 640×480 и заметное снижение качества при переходе к большим объемам (800×600). Кроме того, установлено, что качество работы модели сильно зависит от степени сжатия JPEG: при коэффициенте 100 достигаются максимальные значения метрик, однако даже при сильном сжатии (JPEG = 80) модель сохраняет приемлемую точность. Полученные результаты подтверждают эффективность предложенного подхода и указывают на необходимость дальнейшего повышения робастности к постобработке изображений.

ЗАКЛЮЧЕНИЕ

В рамках настоящей работы был разработан, реализован и исследован метод классификации новостных текстов по тематикам с использованием опорных векторов. Все поставленные задачи были выполнены.

Был проведен анализ предметной области. Были рассмотрены методы очистки и предварительной обработки текста. Был проведен обзор методов извлечения признаков из текста.

Был рассмотрены и проанализированы основные методы классификации текстов. Была представлена формализованная постановка задачи в виде IDEF0-диаграммы.

Были описаны этапы работы алгоритма разрабатываемого метода, также были рассмотрены функциональные схемы обучения классификатора и метод классификации.

Были приведены метрики, используемые для оценки качества работы обученного классификатора. Был описан используемый набор данных для обучения классификатора и была рассмотрена структура программного обеспечения.

Были приведены выбор языка программирования и средства программирования и рассмотрены необходимые библиотеки, которые используются для разработки программного обеспечения. Также был описан формат входных и выходных данных. Также были приведены описание пользовательского интерфейса и руководство пользователя для установки и использования программного обеспечения.

Были описаны технические характеристики устройства для проведения исследований и приведены исследования разработанного метода

Для реализованного метода можно предложить следующие развития:

- ускорение работы метода.
- добавление возможности работы с различными языками.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Farid H.* Digital Image Forensics // Scientific American. — 2008. — ИЮНЬ. — Т. 298. — С. 66—71. — DOI: 10.1038/scientificamerican0608-66.
2. *Verdoliva L.* Media Forensics and DeepFakes: An Overview // IEEE Journal of Selected Topics in Signal Processing. — 2020. — Т. 14, № 5. — С. 910—932. — DOI: 10.1109/JSTSP.2020.3002101.
3. *Birajdar G., Mankar V.* Digital image forgery detection using passive techniques: A survey // Digital Investigation. — 2013. — ОКТ. — Т. 10. — С. 226—245. — DOI: 10.1016/j.diin.2013.04.007.
4. *Lukás J., Fridrich J., Goljan M.* Detecting digital image forgeries using sensor pattern noise // Proceedings of SPIE - The International Society for Optical Engineering. — 2006. — Февр. — Т. 6072. — С. 362—372. — DOI: 10.1117/12.640109.
5. *Qureshi M. A., Deriche M.* A bibliography of pixel-based blind image forgery detection techniques // Signal Processing: Image Communication. — 2015. — Т. 39. — С. 46—74. — ISSN 0923-5965. — DOI: <https://doi.org/10.1016/j.image.2015.08.008>. — Режим доступа, URL: <https://www.sciencedirect.com/science/article/pii/S0923596515001393>.
6. *Piva A.* An Overview on Image Forensics // International Scholarly Research Notices. — 2013. — Т. 2013, № 1. — С. 496701. — DOI: <https://doi.org/10.1155/2013/496701>. — Режим доступа, URL: <https://onlinelibrary.wiley.com/doi/abs/10.1155/2013/496701>.
7. *Cozzolino D., Verdoliva L.* Noiseprint: a CNN-based camera model fingerprint // CoRR. — 2018.
8. Detection of GAN-Generated Fake Images over Social Networks / F. Marra [и др.] //. — 04.2018. — С. 384—389. — DOI: 10.1109/MIPR.2018.00084.
9. Deep Learning for Multimedia Forensics / I. Amerini [и др.] // Foundations and Trends in Computer Graphics and Vision. — 2021. — АВГ. — Т. 12. — С. 309—457. — DOI: 10.1561/06000000096.

10. Determining Image Origin and Integrity Using Sensor Noise / M. Chen [и др.] // IEEE Transactions on Information Forensics and Security. — 2008. — Т. 3, № 1. — С. 74—90. — DOI: 10.1109/TIFS.2007.916285.
11. *Bianchi T., Piva A.* Detection of Nonaligned Double JPEG Compression Based on Integer Periodicity Maps // IEEE Transactions on Information Forensics and Security. — 2012. — Т. 7, № 2. — С. 842—848. — DOI: 10.1109/TIFS.2011.2170836.
12. Image Forgery Localization via Fine-Grained Analysis of CFA Artifacts / P. Ferrara [и др.] // IEEE Transactions on Information Forensics and Security. — 2012. — Т. 7, № 5. — С. 1566—1577. — DOI: 10.1109/TIFS.2012.2202227.
13. *Lowe D.* Distinctive Image Features from Scale-Invariant Keypoints // International Journal of Computer Vision. — 2004. — Нояб. — Т. 60. — С. 91—110. — DOI: 10.1023/B%3AVISI.0000029664.99615.94.
14. An Evaluation of Popular Copy-Move Forgery Detection Approaches / V. Christlein [и др.] // IEEE Transactions on Information Forensics and Security. — 2012. — Дек. — Т. 7. — С. 1841—1854. — DOI: 10.1109/tifs.2012.2218597.
15. *Lowe D.* Object Recognition from Local Scale-Invariant Features // Proceedings of the IEEE International Conference on Computer Vision. — 2001. — Янв. — Т. 2.
16. Geometric tampering estimation by means of a SIFT-based forensic analysis / I. Amerini [и др.] //. — 04.2010. — С. 1702—1705. — DOI: 10.1109/ICASSP.2010.5495485.
17. Copy-Move Forgery Detection: Survey, Challenges and Future Directions / N. Abd Warif [и др.] // Journal of Network and Computer Applications. — 2016. — Сент. — Т. 75. — DOI: 10.1016/j.jnca.2016.09.008.
18. *Bay H., Tuytelaars T., Van Gool L.* SURF: Speeded up robust features // Т. 3951. — 07.2006. — С. 404—417. — DOI: 10.1007/11744023_32.
19. Going deeper into copy-move forgery detection: Exploring image telltales via multi-scale analysis and voting processes / E. Silva [и др.] // JOURNAL OF VISUAL COMMUNICATION AND IMAGE REPRESENTATION. — 2015. — Т. 29. — С. 16.

20. *Zhu Y., Shen X., Chen H.* Copy-move forgery detection based on scaled ORB // *Multimedia Tools and Applications*. — 2016. — T. 75, № 6. — C. 3221—3233.
21. *Farhan M. H., Shaker K., Al-Janabi S.* Copy-move forgery detection in digital image forensics: A survey // *Multimedia Tools and Applications*. — 2024. — T. 83, № 28. — C. 70603—70635.
22. *Bayar B., Stamm M. C.* A Deep Learning Approach to Universal Image Manipulation Detection Using a New Convolutional Layer //. — Association for Computing Machinery, 2016. — C. 5—10. — DOI: 10.1145/2909827.2930786.
23. *Zhang R., Isola P., Efros A. A.* Colorful Image Colorization //. — Springer International Publishing, 2016. — C. 649—666.
24. *Ronneberger O., Fischer P., Brox T.* U-Net: Convolutional Networks for Biomedical Image Segmentation //. — Springer International Publishing, 2015. — C. 234—241.
25. Learning Rich Features for Image Manipulation Detection / P. Zhou [и др.] //. — 2018. — C. 1053—1061. — DOI: 10.1109/CVPR.2018.00116.
26. *Fridrich J., Kodovsky J.* Rich Models for Steganalysis of Digital Images // *IEEE Transactions on Information Forensics and Security*. — 2012. — T. 7, № 3. — C. 868—882. — DOI: 10.1109/TIFS.2012.2190402.
27. Customized Convolutional Neural Network for Accurate Detection of Deep Fake Images in Video Collections / D. Gura [и др.] // *Computers, Materials & Continua*. — 2024. — T. 79. — C. 1—10.
28. *Jing D., Wei W.* CASIA Image Tampering Detection Evaluation Database //. — 2013.

ПРИЛОЖЕНИЕ А

Презентация